



T.C.
SELÇUK ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

YENİ BİR BİYOLOJİK İLHAMLI
METASEZGİSEL OPTİMİZASYON METODU:
YAPAY ALG ALGORİTMASI

Sait Ali UYMAZ

DOKTORA TEZİ

Bilgisayar Mühendisliği Anabilim Dalı

Aralık-2015
KONYA
Her Hakkı Saklıdır

TEZ KABUL VE ONAYI

Sait Ali UYMAZ tarafından hazırlanan “Yeni Bir Biyolojik İlhamlı Metasezgisel Optimizasyon Metodu: Yapay Alg Algoritması” adlı tez çalışması 14/12/2015 tarihinde aşağıdaki jüri tarafından oy birliği ile Selçuk Üniversitesi Fen Bilimleri Enstitüsü Bilgisayar Mühendisliği Anabilim Dalı’nda DOKTORA TEZİ olarak kabul edilmiştir.

Jüri Üyeleri

Başkan

Prof.Dr. Ahmet ARSLAN

Danışman

Doç.Dr. Gülay TEZEL

Üye

Doç.Dr. Süleyman TOSUN

Üye

Doç.Dr. Harun UĞUZ

Üye

Yrd.Doç.Dr. Ömer Kaan BAYKAN

İmza


.....


.....

.....

.....

.....

Yukarıdaki sonucu onaylarım.


Prof. Dr. Aşır GENÇ
FBE Müdürü

Bu tez çalışması Selçuk Üniversitesi Bilimsel Araştırma Projeleri Koordinatörlüğü tarafından 13101019 numaralı proje ile desteklenmiştir.

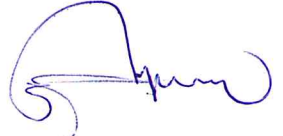
Doç.Dr. Esra YEL bu tez çalışmasının ikinci danışmanıdır.

TEZ BİLDİRİMİ

Bu tezdeki bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve tez yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

DECLARATION PAGE

I hereby declare that all information in this document has been obtained and presented in accordance with academic rules and ethical conduct. I also declare that, as required by these rules and conduct, I have fully cited and referenced all material and results that are not original to this work.



Sait Ali UYMAZ

Tarih: 14.12.2015

ÖZET

DOKTORA TEZİ

YENİ BİR BİYOLOJİK İLHAMLI METASEZGİSEL OPTİMİZASYON METODU: YAPAY ALG ALGORİTMASI

Sait Ali UYMAZ

Selçuk Üniversitesi Fen Bilimleri Enstitüsü
Bilgisayar Mühendisliği Anabilim Dalı

Danışman: Doç.Dr. Gülay TEZEL
2. Danışman: Doç.Dr. Esra YEL

2015, 101 Sayfa

Jüri

Doç.Dr. Gülay TEZEL
Prof.Dr. Ahmet ARSLAN
Doç.Dr. Süleyman TOSUN
Doç.Dr. Harun UĞUZ
Yrd.Doç.Dr. Ömer Kaan BAYKAN

Bu çalışmada hareketli mikro alglerin karakteristik özellikleri ve yaşam davranışlarından esinlenilerek yapay alg algoritması (AAA) adında yeni bir biyolojik ilhamlı metasezgisel optimizasyon algoritması sunulmuştur. AAA evrimsel süreç, adaptasyon süreci ve helisel hareket süreci adında 3 temel bölümden oluşmaktadır. Helisel hareket süreci, alglerin sıvı içindeki helisel hareketleri ve ışığa yakın olma davranışları, evrimsel süreç, alglerin mitoz bölünme ile üremeleri ve adaptasyon süreci ise alglerin bulundukları çevreye adapte olmaları gibi temel özellikleri üzerine modellenmiştir. AAA'nın etkinliğini doğrulamak için CEC'05 test fonksiyonlarında ve basınçlı tank tasarım optimizasyon problemi üzerinde performans testleri yapılmıştır. Test sonuçları literatürde bulunan metasezgisel algoritmalar ile kıyaslanmış ve performans analizi yapılmıştır. AAA'ya çoklu ışık kaynağı hareketi (MLS) uygulanarak geliştirilmiş yapay alg algoritması (AAA_{ML}) sunulmuştur. AAA ve AAA_{ML} yöntemlerinin etkinlikleri ve verimliliklerini doğrulamak için CEC'13 test fonksiyonları ve CEC'11 gerçek dünya optimizasyon problemleri üzerinde testler yapılmıştır. Test sonuçları literatürde iyi bilinen algoritmaların geliştirilmiş ve hibrit sürümleri ile kıyaslanmış ve detaylı performans analizleri yapılmıştır. Yapılan detaylı performans testleri ve analizler AAA ve geliştirilmiş sürümü AAA_{ML}'nin sürekli optimizasyon için tutarlı, etkin ve verimli yöntemler olduğunu göstermiştir.

Anahtar Kelimeler: Biyolojik ilhamlı, gerçek dünya problemleri, metasezgisel, optimizasyon, yapay alg algoritması.

ABSTRACT

Ph.D THESIS

A NOVEL BIO-INSPIRED METAHEURISTIC OPTIMIZATION METHOD: ARTIFICIAL ALGAE ALGORITHM

Sait Ali UYMAZ

**THE GRADUATE SCHOOL OF NATURAL AND APPLIED SCIENCE OF
SELÇUK UNIVERSITY
THE DEGREE OF DOCTOR OF PHILOSOPHY
IN COMPUTER ENGINEERING**

Advisor: Assoc.Prof.Dr. Gülay TEZEL

Co-advisor: Assoc.Prof.Dr. Esra YEL

2015, 101 Pages

Jury

Assoc.Prof.Dr. Gülay TEZEL

Prof.Dr. Ahmet ARSLAN

Assoc.Prof.Dr. Süleyman TOSUN

Assoc.Prof.Dr. Harun UĞUZ

Asst.Prof.Dr. Ömer Kaan BAYKAN

In this study, a novel bio-inspired metaheuristic optimization algorithm called artificial algae algorithm (AAA) inspired by the living behaviors and characteristics of microalgae is introduced. AAA consists of three main processes called helical movement, evolutionary and adaptation processes. Helical movement process is based on helical movement of algae in the medium and the algal tendency to get closer to the light. Evolutionary process is based on reproduction by mitotic division. Adaptation process is based on their adaptation to the environment. To verify the effectiveness and efficiency of AAA, performance tests were performed on CEC'05 benchmark functions and pressure vessel design optimization problem. Test results were compared with meta-heuristic algorithms in the literature and performance analyses were conducted. AAA was modified by implementing multi-light source movement and artificial algae algorithm with multi-light source (AAA_{ML}) version was established. To verify the effectiveness and efficiency of AAA and AAA_{ML}, experiments were performed on CEC'13 benchmark functions and CEC'11 real-world optimization problems. Test results were compared with well-known improved and hybrid methods and detailed performance analyses were performed. Those performance tests and analyses indicated that AAA and AAA_{ML} are consistent, effective and efficient methods for continuous optimization.

Keywords: Artificial algae algorithm, bio-inspired, metaheuristic, optimization, real-world optimization problems.

ÖNSÖZ

Bu çalışmanın yürütülmesi sırasında desteğini esirgemeyen danışmanlarım Doç.Dr. Gülay TEZEL ile Doç.Dr. Esra YEL'e ve tez izleme komitemde yer alan hocalarım Doç.Dr. Süleyman TOSUN'a ve Yrd.Doç.Dr. Ömer Kaan BAYKAN'a, çalışmalarım sırasında yardım ve desteklerini esirgemeyen Selçuk Üniversitesi Bilgi İşlem Daire Başkanlığı'nda çalışan iş arkadaşlarıma saygı ve teşekkürlerimi sunarım.

Yoğun çalışmalarım esnasında gösterdikleri sabır, anlayış ve desteklerinden dolayı aileme, eşim Berat Banu UYMAZ'a ve kızım Dilem UYMAZ'a teşekkür ederim.

Selçuk Üniversitesi Bilimsel Araştırma Projeleri Koordinatörlüğü'ne 13101019 numaralı proje desteğinden dolayı teşekkürlerimi sunarım.

Sait Ali UYMAZ
KONYA-2015

İÇİNDEKİLER

ÖZET	iv
ABSTRACT.....	v
ÖNSÖZ	vi
İÇİNDEKİLER	vii
SİMGELER VE KISALTMALAR	ix
1. GİRİŞ	1
2. KAYNAK ARAŞTIRMASI	4
2.1. Algler	14
2.1.1. Alglerin büyüme karakteristiği	16
2.1.2. Alg ve ışık	17
2.1.3. Çevre koşullarındaki değişiklikler	18
3. MATERYAL VE YÖNTEM.....	20
3.1. Yapay Alg Algoritması (AAA).....	20
3.1.1. Evrimsel süreç.....	21
3.1.2. Adaptasyon	22
3.1.3. Helisel hareket	23
3.1.4. AAA'nın çalışma adımları.....	25
3.1.5. AAA'nın sözde kodu ve akış şeması	26
3.2. Çoklu Işık Kaynağı ile Yapay Alg Algoritması (AAAML)	29
3.2.1. Çoklu-ışık kaynağı hareketi (MLS)	29
3.2.2. Yeni adaptasyon operatörü	30
3.3. Algoritmaların Test Edilmesi.....	33
3.3.1. Test Fonksiyonları	34
3.3.2. Gerçek Dünya Optimizasyon Problemleri	39
3.4. Performans Değerlendirme Kriterleri	42
4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA.....	45
4.1. Test Fonksiyonlarında Performans Değerlendirmesi	45
4.1.1. CEC'05 test fonksiyonlarında AAA'nın performans değerlendirilmesi.....	45
4.1.2. CEC'13 test fonksiyonlarında AAA ve AAAML'nin performans değerlendirilmesi.....	67
4.2. Gerçek Dünya Optimizasyon Problemlerinde Performans Değerlendirmesi	85
4.2.1. Basınçlı tank tasarım optimizasyon probleminde AAA'nın performans değerlendirilmesi.....	85
4.2.2. CEC'11 gerçek dünya optimizasyon problem setinde AAA ve AAAML'nin performans değerlendirilmesi	88
5. SONUÇLAR VE ÖNERİLER	91

5.1. Sonular	91
5.2. neriler	94
KAYNAKLAR	95
ZGEMİŐ	101

SİMGELER VE KISALTMALAR

Simgeler

A_p	: AAA'da adaptasyon parametresi
D	: Problem boyutu
e	: AAA'da enerji kaybı parametresi
f	: Amaç fonksiyonu
G	: AAA'da alg kolonilerinin büyüklükleri
g	: Eşitsizlik kısıt fonksiyonu
h	: Eşitlik kısıt fonksiyonu
K	: Yapay alg kolonisinin yarı doygunluk sabiti
N	: Popülasyondaki alg koloni sayısı
S	: Yapay alg kolonisinin besin konsantrasyonu
X	: Dizayn vektörü
α	: Anlamlılık düzeyi
Δ	: AAA'da kesme kuvveti katsayısı
τ	: AAA'da alg kolonilerinin sürtünme yüzey alanları
μ	: Spesifik büyüme hızı
μ_{max}	: Maksimum spesifik büyüme hızı

Kısaltmalar

AAA	: Yapay alg algoritması (Artificial algae algorithm)
AAA _{ML}	: Çoklu ışık kaynağı ile yapay alg algoritması (Artificial algae algorithm with multi-light source)
ABC	: Yapay arı kolonisi algoritması (Artificial bee colony algorithm)
ACO	: Karınca koloni algoritması (Ant colony optimization algorithm)
ACO _R	: Sürekli etki alanları için karınca koloni algoritması (Ant colony optimization for continuous domains)
AdaptDE	: Adaptif diferansiyel evrim algoritması (Adaptive differential evolution algorithm)
AIS	: Yapay bağışıklık sistemi (Artificial immune system)
AMopGA	: Adaptif tek eşli çiftler genetik algoritma (Adaptive monogamous pairs genetic algorithm)
BA	: Arılar algoritması (Bees algorithm)
BFOA	: Bakteri yiyecek arama algoritması (Bacterial foraging optimization algorithm)
CDASA	: Sürekli diferansiyel karınca iz mekanizması algoritması (Continuous differential ant-stigmergy algorithm)
CEC'05	: 2005 IEEE evrimsel hesaplama kongresi (2005 IEEE Congress on Evolutionary Computation)
CEC'11	: 2011 IEEE evrimsel hesaplama kongresi (2011 IEEE Congress on Evolutionary Computation)
CEC'13	: 2013 IEEE evrimsel hesaplama kongresi (2013 IEEE Congress on Evolutionary Computation)
CS	: Guguk kuşu arama algoritması (Cuckoo search algorithm)
DASA	: Diferansiyel karınca iz mekanizması algoritması (Differential ant-stigmergy algorithm)
DE	: Diferansiyel evrim algoritması (Differential evolution algorithm)

EAs	: Evrimsel algoritmalar (Evolutionary algorithms)
ED-DE	: Diferansiyel evrim ve dağılımın tahmini algoritması (Estimation of distribution and differential evolution)
EPSDE	: Uyumlu diferansiyel evrim algoritması (Ensemble differential evolution algorithm)
FA	: Ateşböceği algoritması (Firefly algorithm)
FFO	: Meyve sineği optimizasyon algoritması (Fruit fly optimization)
FPA	: Çiçek tozlaşma algoritması (Flower pollination algorithm)
GA	: Genetik algoritma (Genetic algorithm)
GSA	: Yerçekimi arama algoritması (Gravitational search algorithm)
HS	: Harmoni arama algoritması (Harmony search algorithm)
HS _{POP}	: Popülasyon temelli harmoni arama algoritması (Population-based harmony search algorithm)
IEEE	: Elektrik ve elektronik mühendisleri enstitüsü (The institute of electrical and electronics engineers)
KHO	: Karides sürüsü optimizasyon algoritması (Krill herd optimization)
LB	: Problem boyutları için alt sınır değerleri (Lower bounds)
MAPE	: Ortalama mutlak hata yüzdesi (Mean Absolute Percentage Error)
MBO	: Göçmen kuşlar optimizasyon algoritması (Migration bird optimization)
MBOA	: Kral kelebek optimizasyon algoritması (Monarch butterfly optimization algorithm)
MLS	: Çoklu ışık kaynağı hareketi (Multi-light source movement)
MopGA	: Tek eşli çiftler genetik algoritma (Monogamous pairs genetic algorithm)
MPC	: Çoklu-ebeveyn çaprazlama (Multi-parent crossover)
MSE	: Ortalama karesel hata (Mean Square Error)
MUEDA	: Öz adaptif karma dağılım tabanlı tek-değişkenli dağılım tahmini algoritması (self-adaptive mixed distribution based uni-variate estimation of distribution algorithm)
NFEs	: Fonksiyon hesaplama sayısı (Number of function evaluations)
No	: Numara
Ort.	: Ortalama değer
p-Değeri	: Null (H ₀) hipotezini tahmini reddetme olasılığı
PSO	: Parçacık sürü optimizasyonu (Particle swarm optimization algorithm)
RMSE	: Kök ortalama karesel hata (Root mean square error)
SA	: Benzetimli tavlama algoritması (Simulated annealing algorithm)
SaDE	: Öz adaptif diferansiyel evrim algoritması (Self adaptive differential evolution)
SPSO	: Standart PSO algoritması
SPSOABC	: Standart PSO ve ABC hibrit yöntemi
SPX	: Tek yönlü çaprazlama ile çoklu ebeveyn rekombinasyonu (Multi-parent recombination with simplex crossover)
SSA	: Sosyal örümcek algoritması (Social spider algorithm)
Std.	: Standart sapma (Standard deviation)
T	: İşaretili sıralamaların toplamalarının en küçüğü
TC	: Üçgensel çaprazlama (Triangular crossover)
TS	: Tabu arama algoritması (Tabu search algorithm)
UB	: Problem boyutları için üst sınır değerleri (Upper bounds)
UNDX	: Tek-modlu dağıtım çaprazlama (Uni-modal distribution crossover)
W	: Kazanan (Winner)

1. GİRİŞ

Optimizasyon bir problemin en uygun çözümünü bulma işlemidir. Amaç ise kaynakları minimum tutarak kazancı maksimum yapmaktır. Optimizasyon, mühendislik problemlerinden iş planlamaya, internet yönlendirmeden tatil planlamaya kadar hemen hemen her alanda kullanılmaktadır. Faaliyetlerin tümü belirli bir hedefe ulaşmak veya zaman, kalite, kâr gibi parametreleri optimize etmek için çalışır. Zaman ve para gibi kaynaklar gerçek dünya uygulamalarında daima kısıtlı olduğu için bu değerli kaynaklar çeşitli sınırlamalar altında en uygun şekilde kullanılmak zorundadır. Bu nedenle probleme en uygun optimizasyon yöntemini seçmek önemlidir. Gerçek dünya problemlerinin karmaşıklığı her mümkün çözüm ya da kombinasyonun aranmasını imkânsız kılar. Kaynakların kısıtlı olmasından dolayı gerçek dünya uygulamalarında kullanılan matematiksel model yaklaşımları problemleri basitleştirerek ya da varsayımlar yapıp sınırlandırarak çözüm yoluna giderler (Sarker ve Newton, 2007). Sonuç olarak, orijinal problem için kabul edilebilir gerçek bir çözüm, problemin değiştirilmiş modelinden elde edilen çözümlerden önemli ölçüde farklılıklar gösterebilir. Matematiksel model yaklaşımlarından farklı olarak, sezgisel metotlar çözüm uzayının etkili bir şekilde aranmasına imkân verir ve kaliteli çözümler sunar. Bu nedenle, matematiksel model yaklaşımından elde edilen çözümler arasındaki tutarsızlığı azaltarak gerçekçi bir problem çözümü elde etmek için sezgisel metotlar kullanılmaktadır (Yang, 2010).

Tarih boyunca özellikle insanlık tarihinin ilk zamanlarında problem çözmek için insanların yaklaşımı daima sezgisel, diğer bir deyişle -deneme yanılma- olmuştur. Birçok önemli keşif yaratıcı fikirler ve deneme yanılma yoluyla yapılmıştır. Aslında canlıların günlük öğrenme deneyimleri ağırlıklı olarak sezgiseldir. Sezgisel yaklaşımlar doğadaki kısıtlı kaynakları kullanmakta oldukça verimli yöntemlerdir. Bu yöntemlerin başarısı araştırmacıların bu alana olan ilgisini arttırmıştır. Araştırmacılar çözüm yaklaşımlarını geliştirmek için birçok farklı disiplinden faydalanarak daha esnek ve daha verimli algoritmalar geliştirmeyi amaçlamışlardır (Yang, 2010).

Doğadaki canlıların hayatta kalma çabaları, besin arama davranışları, birbirleri ile iletişimleri, yaşadıkları ortam ile etkileşimleri aslında en büyük optimizasyon problemi olan doğanın dengesinin korunması amacıyla canlıların geliştirdikleri çözümlerdir. 1950'lerden sonra araştırmacıların bu alana ilgileri artmış ve Darwin'in evrim teorisinden insanın bağışıklık ve sinir sistemine, kuşların, balıkların ve

karıncaların sürü olarak davranışlarından tek hücreli mikro organizmaların besin arama davranışlarına kadar birçok biyolojik yaşamdan esinlenmişlerdir (Yang, 2010; Gao, 2012). Çalışmalar kaynakları her zaman en verimli şekilde kullanan (özellikle zaman) ve tüm problemler için kaliteli çözümler üretebilen bir algoritmaya sahip olmak içindir (Wolpert ve Macready, 1997).

Sezgisel metotlar optimumu garanti etmeyen “yaklaşık hesap” yaklaşımlarıdır (Sarker ve Newton, 2007). Sezgisel metotlarda amaç makul bir zamanda kabul edilebilir kaliteli çözümler bulmaktır. Bu metotların çoğu matematiksel yöntemler gibi probleme özel olmasalar da farklı problemlere adaptasyonları oldukça zordur. Araştırmacılar genel amaçlı, daha esnek ve performansı yüksek yöntemler geliştirmek için içerisinde sezgisel yöntemlerin de kullanıldığı metasezgisel kavramını öne sürmüşlerdir. Metasezgisel, probleme yüksek kaliteli çözümler sağlamak için sezgisellere rehberlik etmek amacıyla tasarlanan, göreceli birkaç değişiklik ile farklı problemlere kolaylıkla adapte edilebilen genel amaçlı bir stratejidir (Blum ve Roli, 2003).

20.yy ortalarından itibaren optimizasyon alanında çalışan bilim adamları genel amaçlı, daha esnek ve performansı yüksek yöntemler geliştirmek için biyoloji, fizik, nöroloji ve diğer disiplinlerden ilham alarak birçok sezgisel ve metasezgisel yöntem geliştirmişlerdir (Yang, 2010). Son 20 yılda karmaşık optimizasyon problemlerinin çözümü için ilham kaynağı olarak özellikle biyolojinin kullanılmasına olan ilgi artmıştır. Biyolojik ilhamlı hesaplama algoritmaları, öncelikle doğal biyolojik sistemlerden faydalı benzetmeleri bulmak, davranışları daha iyi anlamak ve taklit etmek yoluyla modellenmiştir. Genellikle bu alandaki çalışmaların çoğu matematik ve mühendislik araçlarının inşasından ziyade doğal olayların simülasyonuna odaklanmıştır (Yang, 2010; Brownlee, 2011; Gao, 2012).

Sezgisel ve metasezgisel metotlar üzerine yapılan çalışmalar problemlere her zaman daha kaliteli çözümler bulmak ve daha tutarlı sonuçlar elde etmek üzerine yoğunlaşmıştır. Bu nedenle optimizasyon alanındaki çözüm yöntemlerine yapılan her katkı doğadaki kaynakların daha verimli kullanılması ve birçok mühendislik alanında karşılaşılan çözümü zor problemler için harcanan çabanın azaltılması için büyük önem taşır.

Bu noktadan hareketle, daha önce üzerinde çalışılmayan hareketli mikro alglerin karakteristik özellikleri ve yaşam davranışlarından esinlenilerek farklı problemlerde tutarlı ve kaliteli çözümler sunan bir algoritma ile kaynak kullanımını daha verimli hale getirmek mümkündür. Fotosentetik bir canlı türü olan mikroalglerden esinlenerek yeni

bir biyolojik ilhamlı metasezgisel algoritma geliştirilmesi, performansının test edilmesi ve iyileştirilmesi bu tezin amacıdır.

Bu çalışmada karar parametreleri sürekli ve reel değerler alan optimizasyon problemlerinin çözümü için, daha önce üzerinde çalışılmayan mikroalglerden esinlenilerek biyolojik ilhamlı bir metasezgisel algoritma olan Yapay Alg Algoritması (AAA) geliştirilmiştir. AAA, mikroalglerin karakteristik özellikleri ve yaşam davranışlarından esinlenilerek ortaya konulmuştur. AAA alglerin sıvı içindeki helisel hareketleri, ışığa yakın olma davranışları, mitoz bölünme ile üremeleri ve bulundukları çevreye adapte olmaları gibi temel özellikleri üzerine modellenmiştir.

Tezin organizasyonu aşağıda belirtildiği gibidir:

2. bölümde optimizasyon problemlerinin çözümünde uygulanan yöntemlerin tarihçesi genel olarak özetlenmiştir. Özellikle sezgisel yaklaşımlar ve doğadan ilham alınarak geliştirilen metotların tanıtımı kronolojik sırada verilmiştir. Bu bölümde ayrıca optimizasyon kavramı ile ilgili genel bilgilendirme yapılmıştır. Son olarak algoritmanın geliştirilmesinde ilham alınan canlı türü alglerin genel karakteristikleri ve yaşam davranışları hakkında bilgiler verilmiştir.

3. bölümde AAA ve geliştirilmiş sürümü AAA_{ML} 'nin modellenmesi, tanıtılması, matematiksel formülleri ve kodlanması anlatılmıştır. Devamında algoritmaların performansını ölçmek için kullanılan optimizasyon problemleri ve problem setleri ile performans değerlendirilmesinde kullanılan ölçütler ve metotlar tanıtılmıştır.

Algoritmaların genel performans testleri, test sonuçlarının analizleri ve bulguların değerlendirilmesi 4. bölümde yapılmıştır.

5. bölümde ise bu çalışmada elde edilen sonuçlar değerlendirilmiş ve gelecekte yapılabilecek çalışmalar konusunda öneriler sunulmuştur.

2. KAYNAK ARAŞTIRMASI

Optimizasyon, bir problemi çözmek veya bir amaca ulaşmak için eldeki kaynakları en verimli şekilde kullanmaktır. Optimizasyon mühendislik, imalat ve planlama gibi birçok alanda kullanılmaktadır. Teknolojik gelişmeler ve kaynakların azalması problemlerin karmaşıklığının ve optimizasyona olan ihtiyacın artmasına sebep olmaktadır (Yang, 2010).

Matematiksel optimizasyon veya programlama, matematiksel araçları kullanarak, problemleri planlama ve tasarlama çalışmasıdır. Günümüzde, bilgisayar simülasyonları çeşitli etkin arama algoritmaları ile bu optimizasyon problemlerinin çözümü için vazgeçilmez bir araç haline gelmiştir (Yang, 2010).

Problemleri planlama ve tasarlama işleminde ilk adım karar parametrelerinin ve hedefe ulaştıracak maliyet (amaç, skor) fonksiyonunun tanımlanmasıdır. Ayrıca probleme bağlı olarak varsa eşitlik veya eşitsizlik sınırlarının da belirlenmesi gerekir (Karaboğa, 2004).

Optimizasyon problemleri birçok şekilde formüle edilebilir. Şimdiye kadar doğrusal olmayan optimizasyon problemleri için kullanılan en yaygın formülasyon Denklem 2.1–2.4’de verilmiştir.

$$\text{Minimize veya Maksimize } f_i(x), \quad (i = 1, 2, \dots, M) \quad (2.1)$$

$$h_j(x) = 0, \quad (j = 1, 2, \dots, J) \quad (2.2)$$

$$g_k(x) \leq 0, \quad (k = 1, 2, \dots, K) \quad (2.3)$$

$$X = (x_1, x_2, x_3, \dots, x_d) \quad (2.4)$$

burada f_i , h_j ve g_k genel doğrusal olmayan fonksiyonlar, integraller veya diferansiyel eşitlikler olabilir. Dizayn vektör X , d boyutlu uzayda sürekli, ayrık veya ikisinin karışımı olabilir. f_i fonksiyonları maliyet ya da amaç fonksiyonları olarak adlandırılır. Eğer $M > 1$ ise optimizasyon çok amaçlıdır.

Matematiksel olarak, optimizasyon g_k eşitlikleri veya h_j eşitsizlikleri gibi bir dizi kısıtlama altında, maliyet ya da amaç fonksiyonu (f_i) tarafından atanan bazı sıralı değerleri, maksimize ya da minimize eden ve sıklıkla karar değişkenleri olarak anılan X parametrelerinin bir kombinasyonunu araştırmak olarak tanımlanır.

Kısıtlar, karar değişkenlerinin sınırlarını sağlayabilir ya da genellikle karar değişkenleri uzayında uygulanabilirliği ve uygulanabilir alanları tanımlayabilir (Blum ve Roli, 2003).

Optimizasyon problemlerinin çözümü için çeşitli yöntemler geliştirilmiştir. Bu yöntemler deterministik ve stokastik yöntemler olarak gruplandırılabilir. Klasik algoritmalar deterministiktir ve aynı başlangıç noktaları ile hep aynı yolu izlerler. Modern optimizasyon algoritmaları ise sezgiseldirler yani rastgeleliğe sahiptirler. Her zaman optimumu bulma garantisi vermezler ama kaliteli çözümler sunarlar. Bu nedenle daha yüksek oranda kaliteli çözümler bulabilmek için sezgisel algoritmalar üzerine çalışmalar devam etmektedir.

Sezgisel, makul bir süre içinde karmaşık bir sorun için kabul edilebilir pratik çözümler üretmek amacıyla deneme-yanılma yöntemi kullanan bir yaklaşık çözüm metodudur. Glover ve Laguna (1997)'nin çalışmasında literatüre kazandırılan metasezgisel kavramı ise farklı problemlere kolayca adapte edilebilen, çözüm uzayını daha etkin aramayı sağlayacak temel sezgisel yöntemleri birleştirmeye çabalayan bir üst stratejidir.

Metasezgisel algoritmalarda amaç en iyi ya da en iyiye yakın çözümleri bulmak için arama uzayını en verimli en hızlı şekilde aramaktır. Bunu sağlamak için yerel optimumlardan kaçınacak çeşitli mekanizmalara sahiptir ve aramaya rehberlik etmek amacıyla arama esnasında elde edilen bilgiyi hafızada tutarlar.

Herhangi bir metasezgisel algoritmanın iki temel bileşeni vardır:

1. Yoğunlaştırma (intensification) ya da Sömürü (exploitation) : Bölgede bulunan mevcut en iyi çözüm bilgisini kullanarak yerel bölgede aramaya odaklanma.
2. Çeşitlendirme (diversification) ya da Keşif (exploration) : Küresel ölçekte arama uzayını keşfedene kadar çeşitli çözümler üretme.

Bu, en iyi çözümlerin seçimi için bir kombinasyondur. En iyinin seçimi optimuma yakınsayan çözümleri sağlarken rastgelelik yoluyla çeşitlendirme yerel optimuma sıkışıp kalmayı azaltır ve aynı zamanda çözümün çeşitliliğini de artırır. Bu iki bileşenin iyi kombinasyonu genellikle genel optimuma ulaşılmasını sağlar (Yang, 2010).

Kesin çözüm yaklaşımları yani klasik optimizasyon yöntemleri ile büyük ve karmaşık problemlerin çözümünde karşılaşılan problemler (ihtiyaç duyulan hesaplama sürelerinin çok uzun olması, problemlerin model parametrelerinin belirlenmesinin zor

olması, kullanılan yöntemin anlaşılmasının zorluğu ve problem bağımlı olması) araştırmacıları en iyi çözüm yerine iyi çözümleri daha hızlı bulabilen, anlaşılması kolay, farklı problemlere adapte edilebilen yöntemler üzerine çalışmaya yöneltmiştir. Son 50-60 yılda bu özelliğe sahip çeşitli yöntemler geliştirilmiştir.

Sezgisel ya da metasezgisel yöntemlerin ilk kullanıldıkları zamanı kesin olarak belirtmek zor olsa da, Alan Turing'in ikinci dünya savaşında Bletchley Park'da Alman enigma şifrelerini kırması sezgisel algoritmaların kullanıldığı muhtemel ilk çalışma olmuştur. Turing'in çoğu zaman çalışması beklenen fakat doğru çözümü bulması için garantisi olmayan ancak çok büyük başarı elde eden arama yöntemi sezgisel arama olarak adlandırılmıştır (Yang, 2010).

1960'lar ve 1970'ler evrimsel algoritmaların geliştirilmesi için iki önemli on yıl olmuştur. İlk olarak Michigan Üniversitesi'nde John Holland ve çalışma arkadaşları tarafından 1960 ve 1970'lerde genetik algoritma (GA) geliştirilmiştir. 1962'ye kadar Holland uyarlanabilir bir sistem üzerine çalışmıştır ve böyle bir sistem modelleme için çaprazlama ve rekombinasyon manipülasyonu ilk defa kullanılmıştır. Holland genetik algoritmanın geliştirilmesini özetleyen kitabını 1975'de yayınlamıştır (Holland, 1975). Holland'ın bu çalışmasında doğadaki evrimsel süreçten esinlenerek geliştirilen sezgisel bir optimizasyon algoritması sunulmuştur. Bu algoritma temelde topluluğun nesilden nesile geçmesi sırasında en iyilerin hayatta kalması ilkesine dayanır. Genetik algoritma problemlere tek bir çözüm üretmek yerine birden fazla çözüm üretir. Her çözüm topluluğun bir bireyidir. Bireylerden uygunluk değerlerine göre sonraki nesillere çaprazlama yoluyla aktarılan yeni bireyler oluşturulur. Yeni nesillerde iyi çözümler üreten bireyler çoğalırken kötü çözümler üreten bireyler azalır. Yeni nesildeki bireyler, çeşitliliği sağlamak ve yerel optimumlardan kaçınmak için belirli oranda mutasyona uğratılır. Bu evrimsel süreç tekrarlanarak en iyi çözümün bulunabileceği gösterilmiştir. Bu çalışmada kıyaslamalar için kullanılan genetik tabanlı adaptif tek eşli çiftler genetik algoritma (Adaptive monogamous pairs genetic algorithm – AMopGA), Lim ve Ark. (2015) tarafından önerilmiştir. Bu yöntem, Lim ve Khader (2013) tarafından önerilen tek eşli çiftler genetik algoritma (Monogamous pairs genetic algorithm – MopGA) metodu üzerine adaptif eş bağı uygulanarak genişletilmiştir. AMopGA dört temel uyarılma içerir. Bunlar:

1. Uyarlanabilir mutasyon oranı
2. Uyarlanabilir eş bağı imtiyazı ve aldatma oranı
3. Uyarlanabilir çaprazlama operatörleri seçimi

4. Umut verici bölgelere doğru arama ve çeşitliliği sağlamak için aldatma sırasında elit bireye Levy mutasyonu uygulanması

1983 yılında bir optimizasyon tekniği olarak, S. Kirkpatrick, C. D. Gellat ve M. P. Vecchi tarafından çığır açan, metallerin tavlama işleminden esinlenilen benzetimli tavlama (SA) algoritması geliştirilmiştir (Kirkpatrick ve ark., 1983). Bu çalışmada metallerin tavlama işlemi ile problemlere çözüm arama işlemleri arasındaki benzerlikten ilham alınarak geliştirilmiş tavlama benzetimi algoritması tanıtılmıştır. Bu algoritma ile her adımda daha iyi çözümü arayan gradyan temelli klasik tekniklerin yerel minimumlara takılma sorunlarını aşmak için bir yöntem geliştirilmiştir. Bu yöntem ile her yeni çözüm gittikçe azalan bir ihtimalle bir önceki çözümden kötü olsa da kabul edilebilir. Kötü bir çözümün kabul edilebilme olasılığı sıcaklık parametresi ile belirlenir. Sıcaklık başlangıçta çok yüksek bir değerle başlar. Bu şekilde kötü çözümlerin kabul edilebilme olasılığı artar ve yerel çözümlerden kaçınma sağlanabilir. Her bir hesaplama adımında sıcaklık belirlenen bir fonksiyona göre azaltılır ve kötü çözümlerin kabul edilebilme olasılığı düşer. Bu şekilde ise global optimum çözüme yakınsama sağlanır. Ayrıca Kirkpatrick ve ark. (1983) yaptıkları çalışmalarında, geliştirilen algoritmayı zor optimizasyon problemlerinden olan gezgin satıcı problemi üzerine uyarlamış ve algoritmanın başarısını göstermişlerdir.

Metasezgisel kavramının ilk kullanımı 1986 yılında Fred Glover'in tabu arama (TS) algoritmasını sunduğu çalışma olmuştur. Bu algoritma ile komşuluk arama yaklaşımına hafıza kullanımı eklenerek üst bir arama stratejisi oluşturulmuştur. Algoritma bölgesel en iyi çözümlerin ileride daha iyi çözümlerin bulunabilmesi için tabu listesinde tutulması ve bu tabu listesinin esnek olarak kullanılması mantığına dayanır. Algoritmanın başarısı tabu listesi yani bölgesel çözümlerden kaçınabilmek için oluşturulan yasaklama listesine hangi çözümlerin gireceği ve hangi çözümlerin çıkarılacağına iyi yönetilmesine ve listenin büyüklüğünün en uygun şekilde belirlenmesine bağlıdır (Glover ve Laguna, 1997).

İnsan vücudundaki doğal bağışıklık sisteminden esinlenilerek oluşturulan Yapay bağışıklık sistemi (AIS) üzerine ilk çalışmalar 1980'li yılların ortalarında yapılmıştır (Farmer ve ark., 1986) ve gelişimi 1990'lı yıllarda gözlenmiştir (Kephart, 1994; Dasgupta, 1999). Doğal bağışıklık sistemi kendine özel hücreler (lenfositler) ile vücuda giren yabancı hücreleri tanır ve onları etkisiz hale getirir. Optimizasyon problemlerinin çözümünde yapay bağışıklık sisteminin klonal seçim mekanizması kullanılır. Klonal

seim mekanizmasının prensibi popölasyondaki en iyi birey ya da bireylerin antijen olarak belirlenmesi ve antijene en fazla benzeyen bireylerin hayatta kalması, diğerklerinin ölmesidir. Yapay bağışıklık sisteminde bölgesel araştırma yeteneğini arttırmak için klonal seim ve yerel optimumlardan kaçınmak için ise somatik mutasyon uygulanır (Farmer ve ark., 1986).

Doğada yaşayan bir canlı türünün birbirleriyle iletişim kurarak oluşturdıkları davranış modelini yani sürü davranışlarını temel alarak oluşturulan ilk metasezgisel yöntem karınca koloni algoritmasıdır (ACO). Bu algorithmada kimyasal mesajlaşma gibi feromonu kullanarak birbirleri ile iletişim kuran karıncaların sürü zekâsından esinlenilmiştir. Karınca koloni algoritması Dorigo (1992) tarafından optimizasyon ve doğal algorithmlar tezinde sunulmuş ve gezgin satıcı probleminde test edilmiştir. Karıncalar geçtikleri yollara feromonu bırakarak kendisinden sonra gelen karıncaların yol bulmalarını kolaylaştırır. Yapay karıncaların hareketi de bu esasa dayanır. Her karınca geçtiğı yola kat ettiğı mesafe ile ters orantılı olarak feromon bırakır. Popölasyondaki diğerkarıncalar yollarını belirlerken bu feromon miktarından faydalanır. Her çevrimde çözüm yollarının feromon miktarı güncellenir ve belirli bir oranda feromon buharlaşması ile de yerel optimumlara takılma önlenir (Dorigo, 1992). Ayrıca Socha ve Dorigo (2008) yaptıkları çalışmalarında karınca koloni algoritmasını sürekli optimizasyon problemleri için uyarlamışlardır. Yaptıkları çalışmada karınca koloni algoritmasının temelinde büyük yapısal değışiklik yapılmadan sürekli etki alanları için karınca koloni algoritması (ACO_R) önerilmiştir. Ayrıca sürekli deęerler alan optimizasyon problemleri için geliştirilen ACO tabanlı diğerkbir yöntem ise Korosec ve Silc (2013) tarafından önerilen sürekli diferansiyel karınca iz mekanizması algoritmasıdır (Continuous differential ant-stigmergy algorithm – CDASA). CDASA, Korosec ve Ark. (2012) tarafından önerilen ACO tabanlı yüksek boyutlu gerek deęerler alan optimizasyon problemleri için diferansiyel karınca iz mekanizması algoritmasının (Differential ant-stigmergy algorithm – DASA) geliştirilmiş bir sürümüdür.

Sürü davranışlarından esinlenilen bir diğerkalgoritma ise Amerikan sosyal psikoloęu James Kennedy ve mühendis Russell C. Eberhart tarafından 1995 yılında geliştirilen paracık sürü optimizasyonudur (PSO). Paracık sürü optimizasyonu kuş ve balık sürülerinin sosyal davranışlarından esinlenilerek geliştirilmiştir. Bu algoritma temelinde ajan olarak nitelendirilen her bireyin davranışlarını sürüdeki en iyi bireyin davranışı ve ajanın kendisinin daha önceki en iyi davranışını taklit etmesi üzerine

dayanır. Başlangıçta her birey rastgele hareket eder ve uygunluk değerleri hesaplanır. Bireylerin o ana kadar buldukları çözüme en yakın (yerel en iyi) değerler ve popülasyondaki tüm bireyler içinde o ana kadar bulunan çözüme en yakın (global en iyi) değer hafızada tutulur. Her bireyin daha sonraki hareketleri hafızada tutulan yerel ve global en iyi değerlere göre belirlenir. Parçacık sürü algoritmasının gerçekleştirilmesi kolay, anlaşılır ve belirlenmesi gereken başlangıç parametreleri azdır (Kennedy ve Eberhart, 1995). Bu nedenle PSO literatürde çok yaygın olarak kullanılmaktadır ve orijinal PSO'nun çok çeşitli varyasyonları mevcuttur (Liua ve ark., 2005; Chen ve Chi, 2010). Ayrıca literatürde orijinal PSO'ya çok yakın fakat çeşitli geliştirmeler içeren standart PSO algoritmaları (SPSO) mevcuttur. Zambrano-Bigiarini ve ark. (2013) yaptıkları çalışmada, Clerc (2009), Clerc (2010) ve Clerc (2012) çalışmalarında geliştirilen üç adet SPSO algoritmasını tanıtmışlardır.

Storn ve Price (1997) tarafından geliştirilen diferansiyel evrim (DE) algoritması popülasyon tabanlı evrimsel bir algoritmadır ve bu algoritma gerçek değerli parametreler kullanır. Diferansiyel evrim algoritması tipik bir evrimsel algoritmadır ve başlangıçta oluşturulan vektör olarak adlandırılan popülasyon bireyleri mutasyon, rekombinasyon ve seleksiyon işlemlerine maruz kalır. Mutasyon işlemi, popülasyon içinden seçilen vektöre çözüm uzayından rastgele seçilmiş iki vektörün farkının eklenmesi ile gerçekleştirilir. Rekombinasyon işleminde ise belirlenen bir başlangıç parametresi ile yeni vektörün parametrelerinin mutasyona uğramış bireyden mi yoksa popülasyondan seçilen mutasyona uğramayan bireyden mi seçileceğinin belirlenmesidir. Seleksiyon işlemi, ebeveyn vektör ile yeni oluşan çocuk vektörün uygunluk fonksiyonuna verilmesi ve çözüme en uygun değeri veren vektörün bir sonraki popülasyona dâhil edilmesidir (Storn ve Price, 1997). Literatürde DE algoritması tabanlı geliştirilmiş birçok yöntem önerilmiştir. Bu çalışmadaki kıyaslamalarda kullanılan Wang ve ark. (2011) tarafından önerilen diferansiyel evrim ve dağılımın tahmini (Estimation of distribution and differential evolution – ED–DE) algoritması, Mallipeddi ve Suganthan (2011) çalışmalarında önerilen uyumlu diferansiyel evrim algoritması (Ensemble differential evolution algorithm – EPSDE) ve Asafuddoula ve ark. (2011) tarafından önerilen adaptif diferansiyel evrim algoritması (an adaptive differential evolution algorithm – AdaptDE) bu yöntemler arasındadır.

ED–DE metodu, iki aşamalı topluluk fikrini uygulayarak gerçekleştirilen bir algoritmadır. ED–DE iki etkili evrimsel algoritmanın birleştirilmesi ile oluşturulmuştur. Birleştirilen algoritmalar Wang ve Li (2009) çalışmalarında önerilen öz adaptif karma

dağılım tabanlı tek-değişkenli dağılım tahmini algoritması (Self-adaptive mixed distribution based uni-variate estimation of distribution algorithm – MUEDA) ve Qin ve ark. (2009) yalındaki çalışmalarında önerilen öz adaptif diferansiyel evrim (Self adaptive differential evolution – SaDE) algoritmasıdır (Wang ve ark., 2011). EPSDE, diferansiyel evrim algoritmasını, mutasyon ve çaprazlama stratejileri ile birlikte kullanır. EPSDE temelde birleşik kontrol parametrelerinin bir havuzu ile beraber mutasyon ve çaprazlama stratejilerinin bir havuzundan oluşur (Mallipeddi ve Suganthan, 2011). AdaptDE geliştirilmiş bir adaptif diferansiyel evrim (DE) algoritmasıdır. Diferansiyel evrim algoritmasının verimliliğini arttırmak için geliştirilen bu metot adaptif parametre kontrol stratejileri, merkez tabanlı diferansiyel üstel çaprazlama ve bir yerel arama ile hibritleşme içerir (Asafuddoula ve ark., 2011).

21. yüzyılın başlarında ilk olarak Geem ve ark. (2001) su dağıtımı, taşıma modelleme ve zamanlama gibi çeşitli optimizasyon problemlerinin çözümünde yaygın olarak kullanılan harmoni arama (HS) algoritmasını geliştirmişlerdir. Harmoni arama algoritmasında bir orkestradaki müzisyenlerin müzik yaparken aralarındaki uyumdan esinlenilmiştir. Algoritmanın çalışma prensibi genetik algoritmaya benzetmekle beraber yeni bireylerin oluşturulmasında genetik algoritmanın çaprazlama işleminde iki birey, harmoni aramada ise tüm bireyler kullanılır. Algoritma başlangıçta rastgele değerler alan vektörlerden üretilen harmoni belleğinin oluşturulması ile başlar. Yeni vektörün oluşturulması esnasında vektörün her bir parametresi başlangıçta belirlenen harmoni belleği dikkate alma oranına göre bellekteki vektörlerden birinden veya tamamen rastgele olarak seçilir. Seçilen her bir vektör parametresi ses perdesi ayarlama oranına göre belirli oranda değişikliğe uğrar. Yeni oluşturulan harmoni vektörünün en kötü harmoniden daha iyi sonuç vermesi durumunda, en kötü harmoni vektörü bellekten çıkarılır ve yeni harmoni vektörü onun yerine atanır (Geem ve ark., 2001). Mukhopadhyay ve ark. (2008) yılında önerdikleri çalışmada harmoni arama algoritması üzerine birkaç değişiklik ile popülasyon temelli harmoni arama algoritmasını (HS_{POP}) sunmuşlardır. HS_{POP} algoritması keşif yeteneğini arttırmak için her yinelemede bir tek harmoni vektör yerine vektörlerin bir popülasyonunu üretir. Ayrıca bu algorithmada rastgele oluşturulan *bw* parametresi yerine güncel popülasyonun standart sapması kullanılmıştır.

Passino (2002)'de bakterilerin grup olarak yiyecek arama davranışlarından esinlendiği bakteri yiyecek arama algoritmasını (BFOA) geliştirmiştir. Bakteri yiyecek arama algoritmasında *E.coli* ve *M.xanthus* gibi bakterilerin çevresindeki kimyasal

değişiklikleri algılayan ve belirli sinyaller ile uzağa ya da yakına doğru hareket eden (besinin çok olduğu bölgelere yaklaşan, zararlı maddelerden kaçınan) '*chemotaxis*' davranışlarından esinlenilmiştir. Algoritmanın yiyecek arama süreci 4 aşamadan meydana gelir: '*chemotaxis*' (kimya göçümü), '*swarming*' (sürü davranışı), '*reproduction*' (çoğalma), ve '*elimination and dispersal*' (eleme ve dağılma). '*Chemotaxis*' ile bakterinin yuvarlanma ve yüzme hareketi sağlanır. '*Swarming*' ile hücreden hücreye itme ve çekme sinyallerinin modellenmesi sağlanır. '*Reproduction*' ile en uygun çözümü veren maliyeti düşük sağlıklı bakterilerin kendini kopyalama yoluyla çoğaltması ve aynı oranda maliyeti yüksek sağlıksız bakterilerin ölmesi sağlanır. '*Elimination and dispersal*' ile de belirli oranda bakterinin bulunduğu ortamdan dağılması yani çeşitliliğin artırılması sağlanır (Passino, 2002; Dang ve ark., 2008).

Karaboğa (2005) çalışmasında arıların yiyecek arama davranışlarını modelleyerek yapay arı kolonisi (ABC) algoritmasını geliştirmiştir. Algoritmanın modelinde bazı kabuller yapılmıştır. Yapay arı kolonisinde 3 tip arı bulunmaktadır: işçi arılar, gözcü arılar ve kâşif arılar. Her nektar kaynağı için sadece bir işçi arı bulunmaktadır yani nektar kaynağı sayısı ile işçi arı sayısı eşittir. Başlangıçta işçi arılar nektar kaynaklarına gönderilir. Kaynakların nektar miktarı hesaplanır. Burada nektar miktarı kaynağın ifade ettiği çözümün kalitesidir. Gözcü arılar kalitesine göre belirlediği kaynağı seçer ve o kaynağın komşuluğunda bir kaynağın nektarını almaya başlar. Eğer bir kaynak başlangıçta belirlenen bir limit parametresi sayısınca gelişmemişse kaynak terkedilir ve kaynaktaki arı kâşif arıya dönüşerek rastgele araştırma yapar (Karaboğa, 2005). El-Abd (2013) çalışmasında ABC algoritması ile SPSO algoritmasını birleştirerek SPSOABC adında yeni bir hibrit metot önermiştir. Bu metotta hibritleştirme parçacıkların kişisel en iyilerini geliştirmek için SPSO içine bir ABC bileşeni dâhil edilerek gerçekleştirilmiştir. Her bir çevrimde, her bir aday çözüm için hız (velocity), ABC güncelleme eşitliği kullanarak oluşturulmuştur. Hız üretildiğinde, problemin boyutu ve komşu parçacık rastgele seçilmiştir. Bu işlem sonucu daha iyi bir çözüm bulunduğunda parçacığın yeni aday çözümü kişisel en iyi değeri ile yer değiştirilir.

Arıların yiyecek toplama davranışlarından esinlenen diğer bir algoritma ise Pham ve ark. (2006) tarafından önerilen arılar algoritmasıdır (BA). Bu algoritmada kâşif arılar sürekli besin kaynağı ararlar. Kovana döndükten sonra, kâşif arılar diğer arılar ile iletişim biçimi olarak sallanma dansı olarak bilinen bir dans gerçekleştirirler. Bu

dansların içerdği bilgi, besin kaynaklarına arıları göndermek için koloniye yardımcı olur. Koloninin daha verimli yiyecek toplayabilmesi için umut verici besin kaynaklarına daha fazla arı gönderilir.

Yang (2008)'deki çalışmasında ateşböceklerinin yanıp-sönen ışıklarından esinlenerek ateşböceği algoritmasını (FA) geliştirmiştir. Ateşböcekleri 'biyoluminesans' yani 'canlı bir organizma tarafından kimyasal bir reaksiyon esnasında kimyasal enerjinin ışık enerjisine dönüştürülerek ışık üretilmesi ve ışık yayılması' ile bir sinyalizasyon sistemine sahiptir. Bu sinyalizasyonun iki temel fonksiyonu vardır. Bunlar çiftleşme eşini çekmek ve potansiyel avını çekmektir. Geliştirilen algoritma üç temel kural üzerine dayandırılmıştır (Yang, 2008);

- Tüm ateşböcekleri aynı cinsiyete sahiptir, böylece bir ateşböceği türüne bakmadan diğer ateşböcekleri için çekici olacaktır.
- Çekicilik onların parlaklıkları ile orantılıdır, böylece her bir çift ateşböceği için, daha az parlak olan daha parlak olana doğru hareket eder. Ateşböceklerinin aralarındaki mesafe arttıkça parlaklıkları da azalır. Eğer bir ateşböceğinden daha parlak bir ateşböceği yoksa rastgele hareket eder.
- Bir ateşböceğinin parlaklığı amaç fonksiyonun çözüm uzayı ile belirlenir veya etkilenir.

Rashedi ve ark. (2009) ağırlık ve kütle etkileşimleri kanununa dayalı yer çekimi arama algoritmasını (GSA) geliştirmişlerdir. Algoritmada kütle olarak adlandırılan bir dizi birey ağırlık ve kütle etkileşimleri kanunlarının simülasyonu ile optimum çözümü bulmak için görevlendirilir. Kütlelerin ağırlıkları amaç fonksiyonundan dönen değerlere göre hesaplanır. Her kütlenin hareketi popülasyondaki diğer kütlelerin çekimleri sonucu oluşur. Kütleleri büyük olan yani iyi sonuçlar bulan bireylerin çekim kuvveti fazla olur. Her yineleme sonucunda bireylerin kütle ağırlıkları güncellenir. Durdurma kriteri sağlandığında en büyük kütleyle sahip bireyin çözümü optimum çözüm olarak kabul edilir (Rashedi ve ark., 2009).

2009 da Cambridge Üniversitesinden Xin She Yang ve India Raman Mühendislik Fakültesinden Suash Deb guguk kuşlarının yumurtalama ve yuva seçme davranışları ile 'levy' uçuşlarına dayalı verimli bir guguk kuşu arama (CS) algoritmasını tanıtmışlardır. Guguk kuşu arama bazı guguk kuşu türlerinin kuluçka asalaklığı üzerine dayandırılmıştır. Buna ek olarak bu algoritma basit yön bağımsız rastgele yürüyüşlerden ziyade Levy uçuşu hareketi ile güçlendirilmiştir. Guguk kuşu aramasının basitçe tanımı için üç temel kural kullanılmıştır (Yang ve Deb, 2009):

- Her bir guguk kuşu her seferinde bir yumurta bırakır ve rastgele seçilen bir yuvanın içine yumurtasını koyar.

- Yüksek kaliteli yumurtalar ile en iyi yuvalar gelecek nesillere taşınır.

Mevcut ana yuvaların sayısı sabittir ve bir guguk kuşu tarafından yerleştirilen yumurta $[0,1]$ arasında bir olasılıkla bir ana kuş tarafından keşfedilir. Bu durumda ana kuş ya yumurtadan kurtulur ya da sadece yuvayı terk eder ve tamamen yeni bir yuva inşa eder.


Yang (2012) yaptığı çalışmada çiçeklerdeki tozlaşma süreçlerinden ilham alarak çiçek tozlaşma algoritmasını (FPA) sunmuştur.

Bunun yanında, teknoloji ve mühendislik alanında optimizasyona duyulan ihtiyacın artmasından dolayı yaygın olarak üstünde çalışılan optimizasyon algoritmalarının yanında çok sayıda yeni algoritma örneğin Karides sürüsü optimizasyon (Krill herd optimization – KHO) algoritması (Gandomi ve Alavi, 2012), Göçmen kuşlar optimizasyon (Migration bird optimization – MBO) algoritması (Duman ve ark., 2012), Meyve sineği optimizasyon (Fruit fly optimization – FFO) algoritması (Pan, 2012), Sosyal örümcek algoritması (Social spider algorithm (SSA) (Yu ve Li, 2015) ve Kral kelebek optimizasyon algoritması (Monarch butterfly optimization algorithm – MBOA) (Wang ve ark., 2015) önerilmiştir.

Son yirmi yılda farklı disiplinlerden ilham alınarak çok sayıda sezgisel metot geliştirilmiştir. Özellikle biyolojiden ilham alınan algoritmalar üzerine çalışmalar yoğunluk kazanmıştır. Bu ilginin ana nedeni bu algoritmaların esnek ve çok yönlü olmalarıdır. Optimizasyon son yirmi yılda yapılan ilerlemeye rağmen hala çok geniş bir araştırma konusudur çünkü optimizasyon birçok temel bilimde karşılaşılan problemlerin çözümünde sıklıkla kullanılmaktadır. Özellikle mühendislik ve endüstri uygulamalarının çoğunda kaynaklar (para, zaman, hammadde, işgücü ve enerji gibi) en verimli şekilde kullanılarak amaca (düşük maliyet, maksimum kâr, yüksek kapasite kullanımı ve verimlilik gibi) ulaşmak hedeflenir. Doğa ilhamlı algoritmalar üzerindeki ilginin hala devam etmesinin sebebi ise optimizasyon alanındaki ihtiyaçların artarak devam etmesi ve şimdiye kadar araştırmacıların doğal sistemlerin sadece çok karakteristik olaylarından ve canlılarından ilham almış olmasıdır. Daha fazla algoritma geliştirmek için doğada ilham alınacak çok daha fazla sistem vardır. Çünkü doğal sistemler milyonlarca yıldır birçok zorlu problemi çözmektedir (Yang ve ark., 2013).

2.1. Algler

Algler (mavi-yeşil algler/cyanobacteria haricindekiler) çok çeşitli türleri bulunan fotosentetik ökaryot canlılardır. Aynı çekirdek zarları ve klorofilleri bulunur. Tek hücreli algler (mikroalgler) fitoplankton olarak adlandırılır (Şekil 2.1). Deniz yosunları da denilen çok hücreli algler (makroalgler) makro bitkiler görünümünde ve metrelerce uzunluğunda olabilir. Bu çalışmada ilham alınan algler mikroalgler olduğu için ileriki kısımlarda algler ifadesi ile mikroalgler kastedilmektedir ve onların yaşam özelliklerinden söz edilmiştir.



Şekil 2.1. Yaşam ortamına dağılmış halde bulunan alg kolonileri

Algler, deniz, tatlı su ve karasal ekosistemler, hatta buzullar gibi çok çeşitli ortamlarda yaşayabilirler. Ayrıca kaplıcalar ve tuzlu sular gibi zorlu ortamlara da uyum sağlayabilirler. (Graham ve Wilcox, 2000).

Büyük bir çoğunluğu ototrof olan algler kendi organik besinlerini ve enerjilerini inorganik karbon (çoğunlukla CO₂ veya sudaki bikarbonat) ve H₂O'dan elde ederler. İçerdikleri klorofil-*a* ve *b* pigmentleri katalizörlüğünde güneş enerjisinden Reaksiyon (Denklem 2.5) uyarınca gerekli enerjiyi sağlarlar ve bu işlem sırasında oksijen açığa çıkarırlar (Arceivala ve ark., 1970).



Bütün alg türlerinin hücresel kompozisyonları, biyokimyasal mekanizmaları ve sonuçta büyüme için ihtiyaç duydukları temel (C, H, O, P, N) ve eser element (metal)

kompozisyonları benzerdir (Buhr ve Miller, 1983). Bunların yanısıra çok çeşitli organik bileşiklerin de farklı sistemlerde ve farklı koşullarda alg büyümesini destekleyebildikleri bilinmektedir. Heterotrofik şartlarda büyüyen algler, karbonlu bileşikleri parçalayarak büyürler ve azot kaynağı olarak NH_4^+ , NO_3^- ya da organik azot kullanırlar. NH_4^+ taşınım sistemiyle hücre içine alındıktan sonra direkt olarak indirgenmiş organik azota dönüştürülmekte, NO_3^- ise hücre içine alındıktan sonra ilave bir enzimatik reaksiyonla öncelikle NH_4^+ 'a dönüştürülmektedir. Oluşan indirgenmiş organik azot ise protein ve klorofil sentezinde kullanılmaktadır (Graham ve Wilcox, 2000). Yani alglerin bulundukları ortam şartlarına göre ihtiyaç duydukları maddeye erişmede doğal bir optimizasyon yetenekleri mevcuttur.

Alglerin koşula göre adaptasyon yeteneklerinin bir başka göstergesi mikсотrofi olarak da adlandırılan karma büyüme özelliğidir. Çok sayıda alg türü karma beslenme modunda, yani hem organik hem de inorganik karbon kaynağının varlığında yaşamını sürdürebilmektedir. Doğal sucul sistemlerde alg bolluğu ve fonksiyonelliğinin değerlendirilmesinde bu mikсотrofi sayesinde sucul ortamlara karşı adaptasyon yeteneklerinin etkisinin de dikkate alınması gereklidir (Graham ve Wilcox, 2000).

Fitoplankton popülasyon dinamiği genellikle iki kategori altında değerlendirilir (Graham ve Wilcox, 2000). İlki fotosentez ve nütrient alımını içeren büyüme süreçleri ve ikincisi rekabet, sıyrılma, sedimantasyon (çökme), asalaklık, sistemden yıkanma ve ölümü içeren kayıp süreçleridir. Fitoplanktonlar büyüme için en uygun ışığın olduğu epilimnion tabakası içinde farklı dikey katmanları veya bölgeleri işgal edebilir. Hareketli türler gün boyunca fotosentez için epilimnion üstüne kadar yolculuk ederler, geceleri besin elde etmek için karanlık dip seviyelere kadar dönerler.

Yüzen bir algin ileri hareketi iki şey tarafından engellenir. Bunlar yer değiştirmesi esnasında kendisi ile birlikte hareket eden akışkanın eylemsizlik dayanımı ve hareketli organizmanın karşılaştığı viskoz sürtünmedir. Viskoz sürtünme, organizma viskoz akışkan içinden geçerken akışkan moleküllerinin organizma yüzeyine yapışmasıyla uygulanan geri kuvvettir.


Popülasyonlar bir hacim kaplar, farklı seviyelerde hareketlilik gösterirler ve çok çeşitli zaman ve konum paternine yayılmış vaziyette bulunurlar (Şekil 2.1). Büyüme özelliklerine göre karakterize edilirler ki bu özellikler boyut ve yoğunluk (birim alandaki veya birim hacimdeki hücre sayısı) olarak ifade edilir. Büyüme hızı (biyokütledeki net değişim), üreme sonucu birey sayısındaki artış ile ölüm veya taşınım sonucu birey sayısındaki azalma arasındaki dengeyi gösterir (Graham ve Wilcox, 2000).

2.1.1. Alglerin büyüme karakteristiği

Bir biyokütlenin spesifik büyüme hızını, yani birim biyokütlenin büyüme hızını belirlemek için kesikli sistem deney sonuçlarından yararlanılır. Bu tür bir mikrobiyal büyüme Denklem 2.6'da gösterilen birinci dereceden kinetikle karakterize edilir (Reynolds, 2011).

$$\frac{dX}{dt} = \mu X \quad (2.6)$$

burada, dX/dt : birim zamanda biyokütle değişimi; X , biyokütle konsantrasyonu, mg/L; t , zaman; μ , spesifik büyüme hızı, 1/zaman'dır. Uygun sıcaklık ve aydınlatma koşullarında, yeterli CO₂ ve besin varlığında, kesikli sistemde elde edilebilecek tipik bir büyüme eğrisi Şekil 2.2'de gösterilmektedir.



Şekil 2.2. Bir algin toplu bir kültürü için tipik büyüme eğrisi (Lewin, 1970)

Düşük biyokütle konsantrasyonlarında (birbirini gölgelemenin ihmal edilebilir olduğu durumda), birim hacimde hücre miktarındaki artış logaritmiktir ve spesifik büyüme hızı sabittir ($dX/dt = \mu$). Yüksek aydınlana koşulları altında, hücreler ışık doygunluk seviyesinin üzerinde tutulduğu sürece, karşılıklı gölgelemeye rağmen logaritmik büyüme fazı devam edebilir. Hücre konsantrasyonu arttıkça ve absorplanan ışık oranı %100'e yaklaştıkça, kültürün bu enerji koşulları hücre miktarında doğrusal artışı devam ettirir, yani dX/dt sabit olur. Bundan sonra hücre miktarındaki daha fazla artış sadece bazal veya endojen metabolizmanın ihtiyaçlarını önemli derecede artırır. Aydınlatma düzeyi ne olursa olsun, etkin ışıklandırma sonunda büyüme dengeye ulaşacak ve kültürdeki hücre sayısı maksimuma yaklaşacaktır (Lewin, 1970).

Biyolojik büyüme yaygın olarak Monod modeli ile tarif edilmektedir ve bu modelde spesifik büyüme hızı substrat konsantrasyonunun (S) bir fonksiyonu olarak tanımlanmaktadır (Denklem 2.7).

$$\mu = \frac{\mu_{max}S}{K_s + S} \quad (2.7)$$

burada μ_{max} maksimum spesifik büyüme hızı (1/zaman) ve K_s substrat yarı doygunluk sabitidir (kütle/hacim).

Yeterli ışık ve azotun mevcut olduğu koşullar altında, alglerin büyüme hızı uygun inorganik karbon (toplam inorganik karbon ya da çözünmüş CO_2) miktarı ile sınırlanmaktadır. Çeşitli mikroalg türlerinin mikсотotrofik ve heterotrofik büyümesi birçok araştırmacı tarafından incelenmiştir (Cohen ve Post, 1993; Chen ve ark., 1997). Mikсотotrofik büyümede fotosentez ile organik karbonun oksidatif metabolizması aynı anda çalışır. Bazı mikroalgler de organik substratları karbon ve enerji kaynağı olarak kullanarak karanlıkta heterotrof büyüebilir (Kobayashi ve ark., 1992). Ayrıca bazı mikсотotrofik kültürlerde sürekli olarak heterotrofik baskınlığın fotoototrofik baskınlığa dönüşmesi de gözlenmektedir.

Algler sıvı atıklardaki organik ve inorganik maddeleri gidermek ve asimile etmek için ekstraselüler ve intraselüler enzimlerini kullanırlar. Azot, fosfor ve iz metaller enerji tüketimi ve hücre sentezinde kullanılmak üzere giderilir veya asimile edilir. Hücre duvarında bulunan ekstraselüler enzimler kompleks molekülleri küçük ve çözünebilen yan ürünlere parçalar. Parçalanma sonucu oluşan ürünler hücre içine alınarak intraselüler enzimler tarafından enerjiye dönüştürmek üzere kullanılır (Gürbüz ve ark., 2004).

2.1.2. Alg ve ışık

Işık, genellikle birim zamanda birim alana düşen enerji miktarı (W/m^2) ya da foton sayısı ($\mu\text{einstein}/m^2s$; 1 Einstein $\approx 6 \times 10^{23}$ foton) olarak ifade edilen ışıma ile ölçülür (Curtis ve ark., 1994). Fotosentetik canlılar olan alglerin yüksek miktardaki pigmentleri aynı zamanda ışığın hücre içine girişini de engelleyen unsurlardır. Alg biyokütlesi üretimi genellikle ışık ile sınırlıdır ve mikroalg büyümesindeki önemli problemlerden biri ışık toplama kapasitesi ve ışık zayıflamasıdır. Etraftaki ışık azaldıkça

algin büyüme için optimum koşulları zayıflamakta ve kültür bu yeni duruma adapte olma çabası göstermektedir.

Yüzeyin birkaç santimetre altında ışık zayıflar ve reaktör içinde ışık dağılımı homojen olmaz. Bu koşullarda yoğun mikroalg kültürlerinde alg ortama adapte ise gelen ışık şiddeti olarak sistemdeki ortalama ışık şiddeti dikkate alınır (Grima ve ark., 1994). Işık sıvı yüzeyinden içeri girince (penetrasyon) ışık şiddeti derinlikle logaritmik olarak azalır. Bu logaritmik değişim yapısı sayesinde oldukça büyük ışına salınımlarında bile ışık penetrasyonu derinliğinde çok az fark oluşturacaktır. Böylelikle birim alanda ışıkla sınırlanmış büyüme hızı yaklaşık olarak sabit kalacaktır (Buhr ve Miller, 1983).


2.1.3. Çevre koşullarındaki değişiklikler

Alg büyüme özellikleri üzerinde ışık yoğunluğu, sıcaklık ve sıvı kompozisyonundaki değişimlerin önemli etkileri vardır. Bu faktörler farklı metabolik faaliyetlerde fotorespirasyon, fotooksidasyon, fotoheterotrofi ve fotoinhibisyon gibi değişikliklere neden olur.

Fotorespirasyon oksijence zengin bir atmosferde ortaya çıkabilecek fotooksidatif hasardan hücreleri koruyabilecek olan enerjiyi yayar. CO₂ azaltma veya oksijen konsantrasyonunu artırma ile birlikte yüksek bir ışık ile fotorespirasyon sağlanabilir (Geider ve Osborne, 1992). Organik C kaynağı kullanan bazı mikсотrofik kültürlerde fotosentetik mekanizma ve C kaynağının oksidatif asimilasyonu birbirinden bağımsız davranır ve böylece hem CO₂ fotoasimilasyonu hem de oksidatif asimilasyonun ikisi de eşzamanlı devam eder (Fogg, 1975). Fotoheterotrofi çözünmüş organikleri çevresinden alan pigmentli bir algin ışığı alıp enerji kaynağı olarak kullandığı beslenme şeklidir. Fotoinhibisyon yüksek ışık şiddetinde fotosentez hızındaki azalmadır. Fotosentetik aktivitenin tersinir veya tersinir olmayan inaktivasyonunu içeren zamana bağlı bir süreçtir (Geider ve Osborne, 1992).

Mikroalg türleri farklı ışık, sıcaklık ve karbon koşulları altında farklı metabolik özelliklere sahiptirler. Bu özellikler belirli koşullar altında baskın türü belirler. Örneğin karma kültürlerde yüksek sıcaklık ve/veya yüksek ışık koşullarında yeşil algler baskın iken (Şekil 2.3a) soğuk ortamlarda ve/veya düşük ışık yoğunluğunda diatomlar baskındır (Şekil 2.3b) (Graham ve Wilcox, 2000). Bu baskınlık farklı koşullarda ortamdan besin giderim işlemini dengeler. Karma kültür kendini değişen koşullara

adapte edebilme yeteneğine sahiptir ve bu özelliği ile çok çeşitli koşullar altında besin tüketimini ve büyümeyi başarması mümkündür.



Şekil 2.3. Yeşil alg (a) ve diatom (b) hücreleri örnekleri (Lund and Lund, 1996)

3. MATERYAL VE YÖNTEM

3.1. Yapay Alg Algoritması (AAA)

Bu çalışma kapsamında geliştirilen yapay alg algoritması, alglerin karakteristikleri idealize edilerek geliştirilmiştir ve bu algorithma problem uzayındaki her bir çözüme bir yapay alg kolonisi karşılık gelmektedir. Yapay alg, gerçek yaşamdaki bir alg gibi, fotosentez yapabilmek için ışık kaynağına doğru hareket eder ve hareketi helisel yüzme şeklindedir, ortama adapte olup, baskın türü değiştirebilir ve mitoz bölünme ile çoğalabilir. Alglerin bu yaşam özellikleri dikkate alınarak geliştirilen algoritma “Evrimsel Süreç”, “Adaptasyon” ve “Helisel Hareket” adında 3 temel bölümden oluşmaktadır.

Alghitmada, alg temel türdür ve tüm popülasyon alg kolonilerinden meydana gelmektedir (Denklem 3.1). Bir alg kolonisi birlikte yaşayan alg hücrelerinin bir grubudur (Denklem 3.2). Tek bir alg hücresi, iki yeni alg hücresi üretmek için bölündüğü zaman yan yana yaşarlar. Bu iki alg hücresi bölündüğü zaman dört yeni alg hücresi de birlikte yaşar ve bu durum devam eder. Alg kolonileri tek bir hücre gibi davranır, birlikte hareket eder ve kolonideki hücreler uygun olmayan yaşam koşullarında ölür. Su-hücre ara fazında gerçekleşen bir kesme kuvveti gibi harici bir kuvvet veya hücre metabolizmasının yaşamını sürdürmesi için uygun olmayan koşullarda koloni dağılabilir ve dağılan her bir canlı hücre yaşam sürecinde uygun koşulları bulduğu yerde yeni bir koloni haline gelebilir. Optimum noktada bulunan koloni, optimumların kolonisi olarak adlandırılır ve optimum alg hücrelerinden oluşur.

$$\text{Alg Koloni Popülasyonu} = \begin{bmatrix} x_1^1 & \cdots & x_1^D \\ \vdots & \ddots & \vdots \\ x_N^1 & \cdots & x_N^D \end{bmatrix} \quad (3.1)$$

$$x_i = [x_i^1, x_i^2 \dots x_i^D] \quad i = 1, 2, \dots, N \quad (3.2)$$

burada x_i^j , i . alg kolonisinin j . boyuttaki alg hücresidir. Herbir alg kolonisindeki alg hücresi sayısı problem boyutuna eşittir. Her x_i , çözüm uzayında uygun bir çözümü ifade eder. Alg kolonisindeki tüm alg hücrelerinin çözüm uzayında uygun bir yere birlikte hareket ettiği düşünülür. Bir alg kolonisi ideal çözüme ulaştığında optimum elde edilmiş olur.

3.1.1. Evrimsel süreç

Yapay alg hücresi yeterli ışık aldığı takdirde gelişir büyür ve gerçek mitoz bölünmeye benzer şekilde kendisine benzeyen iki yapay alg hücresi oluşur. Aksine yeterli ışık alamayan yapay alg hücresi bir süreliğine yaşar ama sonuçta ölür. Alg kolonisinin büyüme kinetiği Denklem 2.7’de verilen Monod modeli temel alınarak hesaplanmıştır. Monod modelinde μ , i . yapay alg kolonisinin spesifik büyüme hızı, μ_{max} maksimum spesifik büyüme hızı, S , i . yapay alg kolonisinin besin konsantrasyonu yani t anındaki uygunluk değeri $f(x_i)$, K ise i . yapay alg kolonisinin yarı doygunluk sabitidir. μ_{max} 1 olarak kabul edilmiştir (Çünkü dönüştürülen maksimum biyokütle miktarı, kütlenin korunumu kanununa göre birim zamanda tüketilen substrat miktarına en fazla eşit olabilir). K büyüme oranı olarak t anında alg kolonisinin büyüklüğünün yarısı olarak hesaplanmıştır.

Monod eşitliğinden hareketle $t+1$ anındaki i . alg kolonisinin büyüklüğü aşağıdaki Denklem 3.3 ve 3.4 ile verilir;

$$\mu_i^t = \frac{\mu_{max} \times f^t(x_i)}{\left(\frac{G_i^t}{2}\right) + f^t(x_i)} \quad (3.3)$$

$$G_i^{t+1} = G_i^t + \mu_i^t G_i^t, \quad i = 1, 2, \dots, N \quad (3.4)$$

burada G_i^t , t anında i . alg kolonisinin büyüklüğü, N ise popülasyondaki alg koloni sayısıdır.

Başlangıçta tüm alg kolonilerinin büyüklükleri 1 (bir) olarak belirlenir. Helisel hareket çevriminde iyi çözümler sağlayan alg kolonisi aldığı besin miktarı yüksek olduğundan daha fazla büyür. Tüm alg kolonileri için bir çevrim tamamlandıktan sonra evrimsel süreç işletilir. Evrimsel süreçte en küçük alg kolonisinin ölen her bir alg hücresinin yerine en büyük alg kolonisinin bir alg hücresi kopyalanır. Bu süreç aşağıdaki gibi simüle edilir:

$$\text{biggest}^t = \arg \max \{size(x_i^t)\}, \quad i = 1, 2, \dots, N \quad (3.5)$$

$$\text{smallest}^t = \arg \min \{size(x_i^t)\}, \quad i = 1, 2, \dots, N \quad (3.6)$$

$$\text{smallest}_m^{t+1} = \text{biggest}_m^t, \quad m = 1, 2, \dots, D \quad (3.7)$$

burada, D problem boyutu, *biggest* en büyük alg kolonisi ve *smallest* en küçük alg kolonisini ifade etmektedir.

AAA da, alg kolonileri t anındaki büyüklüklerine (G) göre sıralanır. Rastgele seçilen bir boyutta (herbir boyuttaki parametre değeri bir alghücrelerini ifade eder) en küçük alg kolonisinin bir hücresi ölür ve en büyük alg kolonisinin bir hücresi onun yerine kopyalanır.

3.1.2. Adaptasyon

Bulunduğu ortamda yeterince büyüemeyen alg kolonisi hayatta kalmak için bulunduğu ortama adapte olmaya çalışır ve bunun sonucu olarak baskın türü değiştirir. Adaptasyon, hayatta kalan fakat yeterince büyüemeyen alg kolonisinin bulunduğu ortamdaki en büyük alg kolonisine benzemeye çalıştığı bir süreçtir. Bu süreç alg kolonilerinin açlık seviyelerine göre belirlenir. Başlangıçta tüm alg kolonilerinin açlık seviyeleri sıfır olarak kabul edilir. Her bir alg kolonisi helisel hareketi sonucu çözüm uzayında ya daha iyi bir yere (daha iyi bir çözüme) ya da daha kötü bir yere (daha kötü bir çözüme) gider. Daha iyi bir çözüm bulan alg kolonisinin açlık seviyesinde bir değişiklik olmaz fakat hareketi sonucu daha iyi bir çözüm bulamayan alg kolonisinin açlık seviyesi bir artar. Her bir helisel hareket çevrimi sonucu, yani tüm alg kolonileri hareketlerini tamamladıktan sonra, açlık seviyesi en yüksek olan alg kolonisi adaptasyon işlemine tabi tutulur. Fakat her çevrim sonucu adaptasyon sürecinin gerçekleşip gerçekleşmeyeceği başlangıçta verilen A_p parametresi ile belirlenir. A_p $[0,1]$ aralığında sabit bir sayıdır ve 0 ile 1 arasında rastgele üretilen gerçek değerli bir sayı A_p parametresinden küçük ise adaptasyon süreci gerçekleştirilir.


$$\text{starving}^t = \arg \max \{ \text{starvation}(x_i) \}, \quad i = 1, 2, \dots, N \quad (3.8)$$

$$\text{starving}^{t+1} = \text{starving}^t + (\text{biggest}^t - \text{starving}^t) \times \text{rand} \quad (3.9)$$

burada, $\text{starvation}(x_i)$ popülasyondaki alg kolonilerinin açlık seviyelerini, starving^t t anındaki açlık değeri en yüksek alg kolonisini, biggest^t t anındaki en büyük alg kolonisini ve rand 0 ile 1 arasında rastgele üretilen gerçek değerli bir sayıyı ifade eder.

3.1.3. Helisel hareket

Alg hücreleri ve kolonileri genellikle yüzer ve su yüzeyine yakın kalmaya çalışırlar. Çünkü hayatta kalabilmeleri için yeterli ışık orada mevcuttur. Onlar sıvı içerisinde kamçıları sayesinde (Şekil 3.1a) helisel şekilde yüzerler (Şekil 3.1b). Yüzen bir alg hücresinin ileri hareketi iki şey tarafından engellenir. Bunlar yerçekimi ve hareketli organizma hücresinin etrafındaki su ile arayüzünde gerçekleşen viskoz sürtünmedir.



Şekil 3.1. Alglerin kamçıları (a) ve hareket deseni (b) (Foto için kaynak: Lund and Lund, 1996)

Alg hücrelerinin sıvı içerisindeki hareketleri farklılık göstermektedir. Büyüyen alg hücrelerinin sürtünme yüzeyleri büyük olduğundan helisel hareketlerinin frekansı çok yüksek olur ve sıvı içerisinde daha yavaş hareket ederler. Bu durum yerel arama yeteneğini (sömürü) artırır. Küçük alg hücrelerinin ise tersine sürtünme yüzeyleri daha az olduğundan sıvı içerisinde hareket mesafeleri (çözüm uzayındaki adım büyüklükleri) daha büyüktür. Bundan dolayı global arama yetenekleri (keşif) daha fazladır.

Her alg kolonisi belirli bir enerjiye sahiptir. Alg kolonisinin her bir helisel hareket çevriminde, çözüm uzayında kaç kez yer değiştireceği (yeni çözüm arayacağı) bu enerji ile belirlenir. Her çevrim başlangıcında alg kolonilerinin büyüklüğü ile orantılı olarak (büyüklükleri 0 (sıfır) ile 1 (bir) arasında normalize edilerek) enerjileri

hesaplanır. Bunun amacı alg kolonilerinin enerjilerini sınırları bilinen ve kolay kıyaslanabilen değerlere dönüştürmektir. Alg kolonisinin her hareketi belirli bir enerji kaybına neden olur. Her harekette alg kolonisinin harcadığı enerji miktarı *enerji kaybı* parametresi ile belirlenir. Bu enerji kaybı alg kolonisinin hareketi sonucu çözüm uzayında daha iyi bir yere gitmesi durumunda farklılık gösterir. Daha iyi bir çözüm bulan alg kolonisi başlangıçta belirtilen *enerji kaybı* parametresinin yarısı ($e/2$) kadar enerji kaybına uğrar. İyi bir çözüm bulamayan alg kolonisi ise *enerji kaybı* parametresi (e) kadar enerji kaybına uğrar. Özetle alg kolonisinin t anındaki enerjisi t anında aldığı besin konsantrasyonu (çözüm kalitesi) ile doğru orantılıdır. Yani alg kolonisi ışığa ne kadar yakın olursa büyüklüğü ve dolayısıyla enerjisi artar ve sıvı içerisinde daha fazla hareket imkânı bulur. Işığa uzak olan alg kolonileri enerjileri oranında daha az hareket edebilirler.

AAA'da alg kolonilerinin hareketi gerçekte olduğu gibi helisel harekettir ve bu hareketi engelleyen yerçekimi 0 (sıfır) kabul edilmiş ve viskoz sürtünme de kesme kuvveti olarak gösterilmiştir. Viskoz sürtünme alg kolonisinin büyüklüğü ile orantılıdır. Hesaplama da alg kolonisini küre ve büyüklüğünü (G) de hacim olarak kabullendiğimizde sürtünme yüzeyi yarım kürenin yüzey alanı (τ) olur. Büyüklüğü (hacmi) bilinen bir alg kolonisinin yarıçapı, hacim formülünden elde edilerek Denklem 3.11'deki gibi kullanılır. Buradan hareketle;

$$\tau(x_i) = 2\pi r^2 \quad (3.10)$$

$$\tau(x_i) = 2\pi \left(\sqrt[3]{\frac{3G_i}{4\pi}} \right)^2 \quad (3.11)$$

burada $\tau(x_i)$, i . alg kolonisinin sürtünme yüzeyidir.

Alg kolonisinin helisel hareketi için rastgele üç boyut belirlenir. Bu boyutlardan biri doğrusal hareketi sağlar (Denklem 3.12) ve diğer iki boyut açısal hareketi sağlar (Denklem 3.13 ve 3.14). Denklem 3.12 tek boyutlu problemler için kullanılır ve alg hücresi/kolonisi doğrusal hareket sağlar. İki boyutlu problemlerde alg kolonisinin hareketi sinüzoidaldir ve bu yüzden denklem 3.12 ve 3.14 kullanılır. Problemin boyutunun 3 veya daha fazla olduğu durumlarda alg kolonisinin hareketi heliseldir ve denklem 3.12–3.14 kullanılır. Alg kolonisinin sürtünme yüzeyi ve ışık kaynağına olan uzaklığı hareketin adım büyüklüğünü belirler.

$$x_{im}^{t+1} = x_{im}^t + (x_{jm}^t - x_{im}^t)(\Delta - \tau^t(x_i))p \quad (3.12)$$

$$x_{ik}^{t+1} = x_{ik}^t + (x_{jk}^t - x_{ik}^t)(\Delta - \tau^t(x_i)) \cos \alpha \quad (3.13)$$

$$x_{il}^{t+1} = x_{il}^t + (x_{jl}^t - x_{il}^t)(\Delta - \tau^t(x_i)) \sin \beta \quad (3.14)$$

burada x_{im}^t , x_{ik}^t ve x_{il}^t i . alg kolonisinin t anında rastgele seçilen üç alg hücresi (problem boyutu); x_{jm}^t , x_{jk}^t ve x_{jl}^t ışık kaynağı olarak belirlenen popülasyondaki farklı bir alg kolonisinin seçilen boyutlardaki alg hücreleri; $\alpha, \beta \in [0, 2\pi]$; $p \in [-1, 1]$; Δ kesme kuvveti katsayısı; $\tau^t(x_i)$ ise i . alg kolonisinin t anındaki sürtünme yüzey alanıdır.

3.1.4. AAA'nın çalışma adımları

Algoritmanın çalışma adımları aşağıdaki gibidir;

1. Adım: Başlangıç

- 1.1. Problem parametrelerinin belirlenmesi (parametre sayısı (D), her bir boyut için üst ve alt sınır değerleri (UB , LB))
 - 1.2. Algoritmaya özgü parametrelerin belirlenmesi (kesme kuvveti (Δ), enerji kaybı (e), adaptasyon (A_p), popülasyondaki alg koloni sayısı (N) ve durdurma kriteri)
 - 1.3. Alg kolonilerinin rastgele çözümler ile başlatılması.
- $$x_{ij} = LB_j + (UB_j - LB_j) \times Rand \quad i = 1 \dots N ; j = 1 \dots D \quad (3.15)$$
- 1.4. Her bir alg kolonisinin büyüklüğünün 1, açlık değerinin 0 olarak belirlenmesi.
 - 1.5. Her bir alg kolonisinin uygunluk değerlerinin ($f(x)$) hesaplanması.

2. Adım: Ana bölüm. Bu bölüm durdurma kriteri sağlanıncaya kadar tekrar edilir.

- 2.1. Alg kolonilerinin büyüklüklerinin (G) hesaplanması
 - 2.1.1. Alg kolonilerinin büyüme oranlarının Denklem 3.3 ile hesaplanması
 - 2.1.2. Alg kolonilerinin yeni büyüklüklerinin Denklem 3.4 ile hesaplanması
- 2.2. Alg kolonilerinin sürtünme yüzeylerinin (τ) Denklem 3.11 ile hesaplanması
- 2.3. Alg kolonilerinin büyüklükleri normalize edilerek enerjilerinin hesaplanması

$$E^t = \text{norm}((\text{rank}(G^t))^2) \quad (3.16)$$

2.4. Her alg kolonisi için helisel hareket fazı

2.4.1. Amaç fonksiyon değerlerine göre turnuva metodu ile farklı bir alg koloni seçimi

2.4.2. Alg kolonisinden rastgele üç alg hücresinin (k , l ve m) seçimi

2.4.3. Denklemler 3.12–3.14 kullanılarak alg kolonisinin hareketinin hesaplanması.

2.4.4. Alg kolonisinin hareketten kaynaklı enerji kaybı ve hareket sonrası yeni çözümün (yeni koordinatın ışık kaynağının kalitesinin) hesaplanması.

$$E(x_i) = E(x_i) - \left(\frac{e}{2}\right) \quad (3.17)$$

2.4.5. Yeni çözüm daha iyi ise koloninin yeni pozisyona ilerlemesi değilse eski pozisyonunda kalması ve metabolizma kaynaklı enerji kaybına (Denklem 3.17) uğraması.

2.4.6. Alg kolonisinin enerjisi bitti ise sonraki adıma ilerlemesi, değilse 2.4.1. adımına gitmesi.

2.4.7. Alg kolonisi daha iyi bir çözüm bulamadığı takdirde açıklık seviyesinin artması.

2.5. Evrimsel faz

2.5.1. Denklem 3.5 ve 3.6 kullanılarak popülasyondaki *enbüyük* ve *enküçük* alg kolonisinin seçimi

2.5.2. Alg kolonisinden rastgele bir alg hücresinin (m) seçimi

2.5.3. Denklem 3.7 kullanılarak *enbüyük*'den *enküçük*'e alg hücresinin kopyalanması

2.6. Adaptasyon Fazı

2.6.1. Denklem 3.8 kullanılarak en aç alg kolonisinin seçimi

2.6.2. Denklem 3.9 kullanılarak seçilen alg kolonisinin adaptasyona uğraması

3. Adım: Son bölüm. En iyi çözümün çıktı olarak verilmesi

3.1.5. AAA'nın sözde kodu ve akış şeması

AAA'nın sözde kodu ve akış şeması sırasıyla Şekil 3.2 ve 3.3'de verilmektedir.

Yapay Alg Algoritması - Artificial Algae Algorithm (AAA)

Amaç fonksiyonu $f(x)$, $x = (x_1, x_2, \dots, x_d)$

Parametreleri belirle (kesme kuvveti Δ , enerji kaybı e ve adaptasyon parametresi A_p)

n adet alg kolonisinden oluşan popülasyonu rastgele çözümler ile başlat

Herbir alg kolonisinin büyüklüğünü 1 ve açlık değerini 0 olarak tanımla

Herbir alg kolonisinin amaç fonksiyon değerini ve büyüklüğünü (G) hesapla

While ($t < \text{MaksimumHesaplama}$)

Alg kolonilerinin enerji (E) ve sürtünme yüzeylerini (τ) hesapla

For $i=1:n$

$iStarve = 1$

While ($E(x_i) > 0$)

Amaç fonksiyon değerlerine göre turnuva yöntemi ile j alg kolonisini (ışık kaynağını) seç

Helisel hareket için rastgele üç boyut (alg hücresi) (k, l ve m) seç

$$x_{im}^{t+1} = x_{im}^t + (x_{jm}^t - x_{im}^t)(\Delta - \tau_i)p$$

$$x_{ik}^{t+1} = x_{ik}^t + (x_{jk}^t - x_{ik}^t)(\Delta - \tau_i) \cos \alpha$$

$$x_{il}^{t+1} = x_{il}^t + (x_{jl}^t - x_{il}^t)(\Delta - \tau_i) \sin \beta$$

$\alpha, \beta \in [0, 2\pi]$; $p \in [-1, 1]$;

Yeni çözümü hesapla

$E(x_i) = E(x_i) - (\frac{e}{2})$ hareket kaynaklı enerji kaybı

if yeni çözüm daha iyi, i alg kolonisini güncelle ve $iStarve = 0$

else $E(x_i) = E(x_i) - (\frac{e}{2})$ metabolizma kaynaklı enerji kaybı **end if**

end While

if $iStarve=1$, $A(x_i)$ açlık seviyesini bir arttır **end if**

end For

Alg kolonilerinin büyüklüklerini (G) hesapla

Rastgele belirlenen r boyutunda en büyük alg kolonisinin hücresini en küçük alg kolonisinin hücresine kopyala

$smallest_r^t = biggest_r^t$

En aç alg kolonisini seç

if $\text{rand} < A_p$


$$starving^{t+1} = starving^t + (biggest^t - starving^t) \times \text{rand}$$

end if

En iyi çözümü sakla

end While

Şekil 3.2. Yapay Alg Algoritmasının (AAA) sözde kodu



Şekil 3.3. AAA'nın genel akış şeması

3.2. Çoklu Işık Kaynağı ile Yapay Alg Algoritması (AAAML)

AAA'da, alg kolonileri helisel hareket ile tek bir ışık kaynağına 3 farklı boyutta yaklaşmaktadır. Işık kaynağının seçimi optimumu bulmada önem arz etmektedir. AAA'da, her bir alg kolonisi turnuva metodu ile popülasyondaki farklı bir alg kolonisinin bulunduğu yeri ışık kaynağı olarak belirler. Seçilen alg kolonisinin bulunduğu yerin global optimumdan uzak veya yerel optimuma yakın bir yer olma ihtimali bulunmaktadır. Bu durum alg kolonilerini optimuma yaklaşımda yavaşlatabilir veya yerel minimumlara takılmalarına neden olabilir.

AAA'nın arama yeteneklerini geliştirmek, yerel minimumlardan kaçınırken global optimuma daha hızlı ulaşmasını sağlamak için önerilen, geliştirilmiş yapay alg algoritması (AAAML) Evrimsel Algoritmalar (EAs) kullanılan "multi-parent recombination" yaklaşımını uyarlayarak çoklu-ışık kaynağı hareketi yaklaşımı üzerinde odaklanır. Çoğu evrimsel algoritma yeni bireyler üretmek için çoğunlukla çift ebeveynli bir çapraz gen oluşturma operatörü kullanır (Tsutsui ve ark., 1999). Bunun yanında literatürde çapraz gen oluşturma için ikiden fazla ebeveyn kullanan çalışmalar da vardır. Tek yönlü çaprazlama ile çoklu ebeveyn rekombinasyonu (Multi-parent recombination with simplex crossover – SPX) (Tsutsui ve ark., 1999), ebeveyn olarak üç bireyin seçilmesi ile üçgensel çaprazlama (Triangular crossover – TC) (Elfeky ve ark., 2008), tek-modlu dağıtım çaprazlama (Uni-modal distribution crossover – UNDX) (Kita ve ark., 1999) ve çoklu-ebeveyn çaprazlama (Multi-parent crossover – MPC) (Elsayed ve ark., 2011) ikiden fazla ebeveyn kullanan çalışmalara örnek olarak verilebilir. Evrimsel algoritmalar yapılan bu çalışmalar AAAML'nin geliştirilmesinde ilham kaynağı olmuştur.

3.2.1. Çoklu-ışık kaynağı hareketi (MLS)

AAA'da, çeşitlendirme (keşif) ve yoğunlaştırma (sömürü) helisel hareket ile yani alg kolonilerinin modifikasyonları ile sağlanır. Evrimsel süreç ve adaptasyon süreci yoğunlaştırmaya yardımcı olur. Yerel ve global arama yeteneği arasındaki denge optimizasyon probleminin çözümü için önemlidir. Alg kolonilerinin çözüm uzayındaki dağılımı çok geniş olursa global arama yeteneği artar ve global optimuma yakınsama hızı azalır (Elsayed ve ark., 2011). Aksine bu dağılım çok dar olursa yerel arama yeteneği artar ve erken yakınsama meydana gelir (Elsayed ve ark., 2011). Böylece

algoritmanın yerel ve global arama yeteneği arasındaki denge bozulur. Daha güçlü bir denge için helisel harekette değişime uğrayan her bir boyut için farklı bir ışık kaynağı seçimi önerilmektedir. Kullanılan bu yeni helisel hareket eşitlikleri aşağıdaki gibidir:

$$x_{im}^{t+1} = x_{jm}^t + (x_{rm}^t - x_{vm}^t)(\Delta - \tau^t(x_j))p \quad (3.18)$$

$$x_{ik}^{t+1} = x_{rk}^t + (x_{vk}^t - x_{jk}^t)(\Delta - \tau^t(x_r)) \cos \alpha \quad (3.19)$$

$$x_{il}^{t+1} = x_{vl}^t + (x_{jl}^t - x_{rl}^t)(\Delta - \tau^t(x_v)) \sin \beta \quad (3.20)$$

burada $i = 1, 2, \dots, N, i \neq j \neq r \neq v$; $m, k, l = 1, 2, \dots, D, m \neq k \neq l$; $\alpha, \beta \in [0, 2\pi]$; $p \in [-1, 1]$; Δ kesme kuvveti; $\tau^t(x_{j,r,v})$ alg kolonilerinin sürtünme yüzey alanlarıdır.

Denklemler 3.18–3.20, evrimsel algoritmalarda kullanılan çok-ebeveynli yeniden birleşme (multi-parent recombination) çalışmalarından (Kita ve ark., 1999; Tsutsui ve ark., 1999; Elfeky ve ark., 2008; Elsayed ve ark., 2011) esinlenilerek uyarlanmıştır. Denklemler 3.18–3.20’da kullanılan 3 ışık kaynağı (x_j, x_r ve x_v) turnuva metodu ile seçilmektedir ve her ışık kaynağı birbirinden farklıdır. Bu durum, arama uzayında her biri birbirinden farklı çözümler verir. Üç ışık kaynağından optimum değere en yakın olan ile modifikasyon yapılan boyutta çözüm uzayının daha iyi bölgelerine doğru ilerleme sağlanır. Uygunluk değeri en kötü olan ışık kaynağı ile çözüm uzayında çeşitlilik sağlanır. Diğer ışık kaynağı ise bu ikisi arasındaki dengeyi artırır. Bu yaklaşıma evrimsel algoritmalarındaki çok-ebeveynli yeniden birleşmenin karşılığı olarak çoklu-ışık kaynağı hareketi (MLS) ya da çoklu-ışık kaynağı helisel hareketi diyebiliriz.

3.2.2. Yeni adaptasyon operatörü


Adaptasyon süreci açlık seviyesi en yüksek olan alg kolonisinin arama uzayının daha iyi bölümlerine gitmesine yardımcı olur. AAA’da her bir alg kolonisinin açlık seviyeleri tutulmaktadır ve iyi çözümler bulamayan alg kolonilerinin bu açlık seviyeleri artmaktadır. Önerilen yeni adaptasyon operatörü ile adaptasyon sürecine maruz kalan alg kolonisinin açlık değeri sıfırlanır ve arama uzayında gittiği bölgede daha fazla yerel arama yapması sağlanır. İlaveten helisel hareket ile arama uzayında daha iyi yere giden alg kolonisinin açlık değeri artmadığı gibi aynı zamanda sıfırlanır. Bu yeni yaklaşım ile

alg kolonilerinin açlık değerleri çözüm uzayında bulundukları bölgedeki açlık değerlerini ifade etmektedir.

Yeni adaptasyon sürecinin adımları:

1. Denklem 3.8 kullanılarak en aç alg kolonisini seç (AAA ile benzer)
2. Denklem 3.9 kullanılarak seçilen alg kolonisini adaptasyona uğrat (AAA ile benzer)
3. Adaptasyona uğrayan koloninin uygunluğunu hesapla
4. Koloninin açlık seviyesini sıfırla.

AAA_{ML}'nin akış şeması Şekil 3.4'de verilmektedir.



Şekil 3.4. AAA_{ML}'nin genel akış şeması

3.3. Algoritmaların Test Edilmesi

Yeni önerilen bir optimizasyon algoritmasının başarısını birçok farklı özelliğe sahip problem üzerinde test etmek gerekir ve bu literatürde çok yaygın bir yaklaşımdır. Literatürde algoritmaların başarısını test etmek için çeşitli problem veya problem setleri üzerinde çalışmalar yapılmaktadır. Bu problemlere örnek olarak basınçlı tank tasarım optimizasyon problemi, dairesel anten dizisi tasarım problemi, uzay aracı yörünge problemi ve ekonomik yük dağıtım problemi gösterilebilir. Bu problemler parametre sayıları, eşitlik ve eşitsizlik kısıt fonksiyonları veya parametrelerinin sürekli ve/veya ayrık değerler alması açısından farklı özellikler taşıyabilmektedir. Bu özellikler problemlerin çözümlerini zorlaştırmaktadır ve algoritmaların daha iyi arama özelliklerine sahip olmalarını gerektirmektedir.

Bu problemlere ilaveten farklı özelliklerde test fonksiyonları da performans değerlendirmelerinde kullanılmaktadır. Bu fonksiyonlar farklı özelliklere sahiptirler ve algoritmaların farklı yeteneklerini test etmek için kullanılırlar. Bu özelliklerden en önemlisi fonksiyonun tek veya çok modlu olmasıdır. Tek-modlu fonksiyonlar yalnızca bir yerel minimuma sahip fonksiyonlardır. Bu tip fonksiyonlar algoritmaların optimum değere yakınsama hızını test etmek için kullanılırlar. Çok-modlu fonksiyonlar ise birden fazla yerel minimuma sahip fonksiyonlardır ve tek-modlu fonksiyonlara göre çözümleri daha zordur. Bu tip fonksiyonlar algoritmaların yerel minimumlardan kurtulabilme yeteneğini test etmek için kullanılır. Algoritmalar, keşif yetenekleri ne kadar güçlü ise çözüm uzayını o kadar iyi arar ve yerel minimumlardan kurtulabilir. Bir diğer özellik fonksiyonun ayrıştırılabilir veya ayrıştırılamaz olmasıdır. Ayrıştırılabilir d -değişkenli bir fonksiyon tek değişkenli d adet fonksiyon olarak ifade edilebilmektedir. Ayrıştırılamaz fonksiyonlar bu şekilde ifade edilemez ve değişkenler arasında bağımlılık vardır. Bu yüzden ayrıştırılamaz fonksiyonların çözümü ayrıştırılabilir fonksiyonlara göre daha zordur. Fonksiyonların bir başka özelliği ise değişken sayısı yani boyutudur. Fonksiyonun boyutu arttıkça çözümü de zorlaşmaktadır. Bunun iki nedeni vardır. Birincisi boyut arttıkça fonksiyonun karmaşıklığı artar. Düşük boyutlar için iyi bir arama stratejisi yüksek boyutlarda optimum çözümü bulma yeteneğine sahip olmayabilir. İkincisi boyut ile beraber fonksiyonun çözüm uzayının da katlanarak artmasıdır ve bu durum daha verimli bir arama stratejisi ile belirli bir sürede çözüm uzayındaki umut verici bölgelerin keşfedilmesini gerektirir.

Yeni veya geliştirilmiş bir algoritmanın başarısını test etmek için birçok gerçek dünya optimizasyon problemi ve test fonksiyonu mevcuttur. Fakat literatürde fikir birliğine varılmış bir test fonksiyon veya problem seti mevcut değildir. Bu çalışmada önerilen yeni algoritmalar AAA ve AAA_{ML}'nin performansını ve başarısını test etmek için her yıl düzenlenen elektrik ve elektronik mühendisleri enstitüsü (IEEE) evrimsel hesaplama kongrelerinde algoritmaların başarılarını doğrulamak amacıyla sunulan CEC'05 (2005 IEEE Evrimsel hesaplama kongresi) ve CEC'13 (2013 IEEE Evrimsel hesaplama kongresi) test fonksiyon setleri, CEC'11 (2011 IEEE Evrimsel hesaplama kongresi) gerçek dünya problem seti ve literatürde yaygın olarak tercih edilen ve bir gerçek dünya problemi olan basınçlı tank tasarım optimizasyon problemi kullanılmıştır.

3.3.1. Test Fonksiyonları

3.3.1.1. CEC'05 test fonksiyon seti

2005 yılında IEEE Evrimsel hesaplama kongresinde sunulan ve algoritmaların eşit şartlar altında performanslarını değerlendirmek için kullanılan CEC'05 test fonksiyon seti 25 adet fonksiyondan oluşmaktadır. Bu set tek-modlu (F1–F5) ve çok-modlu (F6–F25) olmak üzere kategorize edilmiş iki farklı sınıfta tanımlanan fonksiyon gruplarına sahiptir. Ayrıca çok-modlu grubuna ait F15–F25 arasındaki fonksiyonlar karma fonksiyon olarak tanımlanmıştır. Test fonksiyonlarının adı ve dâhil olduğu grup tanımları Çizelge 3.1'de gösterilmiştir. Bunun yanında fonksiyonlarla ilgili ayrıntılı bilgiler Suganthan ve ark. (2005) tarafından yapılan çalışmada verilmektedir. Bu çalışmada AAA ile ilk denemeler bu set üzerinde yapılmıştır. Yapılan testler sonucunda algoritmanın performansı literatürde iyi bilinen başarılı metotların ağırlıklı olarak temel halleri ile kıyaslanmıştır.

Çizelge 3.1. CEC'05 test fonksiyon seti

Fonksiyon Sınıfı	No.	Fonksiyon Adı
Tek-modlu	F1	Kaydırılmış Sphere Fonksiyonu
	F2	Kaydırılmış Schwefel's Problemi 1.2
	F3	Kaydırılmış Döndürülmüş Yüksek Dereceli Eliptik Fonksiyon
	F4	Gürültülü Kaydırılmış Schwefel's Problemi 1.2
	F5	Schwefel's Problem 2.6 Global Optimum Sınırlar Üzerinde
Çok-modlu	F6	Kaydırılmış Rosenbrock's Fonksiyonu
	F7	Parametre Sınırlamasız Kaydırılmış Döndürülmüş Griewank Fonksiyonu
	F8	Kaydırılmış Döndürülmüş Ackley's Fonksiyonu Optimum Sınırlar Üzerinde
	F9	Kaydırılmış Rastrigin's Fonksiyonu
	F10	Kaydırılmış Döndürülmüş Rastrigin's Fonksiyonu
	F11	Kaydırılmış Döndürülmüş Weierstrass Fonksiyonu
	F12	Schwefel's Problemi 2.13
	F13	Genişletilmiş Uzatılmış Griewank's + Rosenbrock's Fonksiyonu
	F14	Kaydırılmış Döndürülmüş Genişletilmiş Schaffer F6 Fonksiyonu
	F15	Karma Birleşim Fonksiyonu
	F16	Döndürülmüş Karma Birleşim Fonksiyonu
	F17	Gürültülü Döndürülmüş Karma Birleşim Fonksiyonu
	F18	Döndürülmüş Karma Birleşim Fonksiyonu
	F19	Global Optimumu Dar Alanda Olan Döndürülmüş Karma Birleşim Fonksiyonu
	F20	Döndürülmüş Karma Birleşim Fonksiyonu Global Optimum Sınırlar Üzerinde
	F21	Döndürülmüş Karma Birleşim Fonksiyonu
	F22	Yüksek Dereceli Döndürülmüş Karma Birleşim Fonksiyonu
	F23	Döndürülmüş Karma Birleşim Fonksiyonu
	F24	Döndürülmüş Karma Birleşim Fonksiyonu
	F25	Parametre Sınırlamasız Döndürülmüş Karma Birleşim Fonksiyonu

3.3.1.2. CEC'13 test fonksiyon seti

2013 IEEE Evrimsel hesaplama kongresinde (CEC'13) sunulan test fonksiyon seti, daha önceki yıllarda önerilen fonksiyonların geliştirilmiş ve bazı yeni test fonksiyonların eklenmiş halidir. Bu set 28 adet test fonksiyonundan oluşmaktadır (Çizelge 3.2). Fonksiyonlar hakkında ayrıntılı bilgiler Liang ve ark. (2013)'nın yaptığı çalışmada verilmektedir. AAA'nın CEC'05 test fonksiyon setinde elde ettiği başarılı sonuçların tutarlılığını göstermek ve AAA'nın geliştirilmiş sürümü AAA_{ML}'nin başarısını kanıtlamak için CEC'13 test fonksiyon seti üzerinde denemeler yapılmış ve bu denemelerde CEC'13 teknik raporunda (Liang ve ark., 2013) belirtilen kriterler kullanılmıştır. Ayrıca test sonuçları literatürde iyi bilinen metotların geliştirilmiş ve hibrit sürümleri ile kıyaslanmıştır.

Çizelge 3.2. CEC'13 test fonksiyon seti


Fonksiyon Sınıfı	No.	Fonksiyon Adı	Özellikler	$f_i=f_i(x^*)$
Tek-modlu	1	Sphere Fonksiyon	- Ayrıştırılabilir	-1400
	2	Rotated High Conditioned Elliptic Fonksiyon	- Ayrıştırılmaz - Uygunsuz kuadratik - Pürüzsüz yerel düzensizlikler	-1300
	3	Rotated Bent Cigar Fonksiyon	- Ayrıştırılmaz - Pürüzsüz fakat dar sırt	-1200
	4	Rotated Discus Fonksiyon	- Ayrıştırılmaz - Asimetrik - Pürüzsüz yerel düzensizlikler - Tek hassas yönlü	-1100
	5	Different Powers Fonksiyon	- Ayrıştırılabilir - z_i -değişken hassasiyetleri farklıdır	-1000
Temel Çok-modlu	6	Rotated Rosenbrock's Fonksiyon	- Ayrıştırılmaz - Yerel optimumdan global optimuma dar bir vadiye sahip	-900
	7	Rotated Schaffers Fonksiyon	- Ayrıştırılmaz - Asimetrik - Yerel optimum sayısı fazla	-800
	8	Rotated Ackley's Fonksiyon	- Ayrıştırılmaz - Asimetrik	-700
	9	Rotated Weierstrass Fonksiyon	- Ayrıştırılmaz - Asimetrik - Sürekli fakat sadece bir dizi noktada türevlenebilir	-600
	10	Rotated Griewank's Fonksiyon	- Döndürülmüş - Ayrıştırılmaz	-500
	11	Rastrigin's Fonksiyon	- Ayrıştırılabilir - Asimetrik - Yerel optimum sayısı fazla	-400
	12	Rotated Rastrigin's Fonksiyon	- Ayrıştırılmaz - Asimetrik - Yerel optimum sayısı fazla	-300
	13	Non-Continuous Rotated Rastrigin's Fonksiyon	- Döndürülmüş - Ayrıştırılmaz - Asimetrik - Yerel optimum sayısı fazla - Non-continuous	-200
	14	Schwefel's Fonksiyon	- Döndürülmüş - Ayrıştırılmaz - Asimetrik - Yerel optimum sayısı fazla ve ikinci en iyi yerel optimum global optimumdan uzak	-100
	15	Rotated Schwefel's Fonksiyon	- Ayrıştırılmaz - Asimetrik - Yerel optimum sayısı fazla ve ikinci en iyi yerel optimum global optimumdan uzak	100
	16	Rotated Katsuura Fonksiyon	- Ayrıştırılmaz - Asimetrik - Her yerde sürekli fakat hiçbir yerde türevlenemez	200
	17	Lunacek Bi_Rastrigin Fonksiyon	- Ayrıştırılmaz - Asimetrik - Her yerde sürekli fakat hiçbir yerde türevlenemez	300
	18	Rotated Lunacek Bi_Rastrigin Fonksiyon	- Ayrıştırılmaz - Asimetrik - Her yerde sürekli fakat hiçbir yerde türevlenemez	400

Birleşik	19	Expanded Griewank's plus Rosenbrock's Fonksiyon	- Ayırıştırılmaz	500
	20	Expanded Scaffer's F6 Fonksiyon	- Ayırıştırılmaz - Asimetrik	600
	21	Composition Fonksiyon 1 (n=5, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	700
	22	Composition Fonksiyon 2 (n=3, Unrotated)	- Ayırıştırılabilir - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	800
	23	Composition Fonksiyon 3 (n=3, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	900
	24	Composition Fonksiyon 4 (n=3, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	1000
	25	Composition Fonksiyon 5 (n=3, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	1100
	26	Composition Fonksiyon 6 (n=5, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	1200
	27	Composition Fonksiyon 7 (n=5, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	1300
	28	Composition Fonksiyon 8 (n=5, Rotated)	- Ayırıştırılmaz - Asimetrik - Farklı yerel optimumlar etrafında farklı özellikler	1400
Arama Uzayı Aralığı: [-100,100] ^P				

3.3.2. Gerçek Dünya Optimizasyon Problemleri

3.3.2.1. Basınçlı tank tasarım optimizasyon problemi

Basınçlı tank tasarım optimizasyon problemi temelde 750 ft^3 (21.24 m^3) hacim ve 3.000 psi (20.68 MPa) çalışma basıncına sahip sıkıştırılmış bir hava tankının en düşük maliyet ile üretilebilmesi için en uygun dizaynı bulma problemidir. Şekil 3.5’de gösterildiği gibi silindirik basınçlı tankın her iki ucu yarım daire şeklinde kapaklar ile kapalıdır. Problem, Şekil 3.5’de gösterilen dört adet tasarım değişkenine sahiptir. L ve R sürekli değer alan değişkenler, T_h ve T_s ise kesikli değer alan ayırık değişkenlerdir ve 0.0625 inch ’in (0.16 cm) katları olması beklenir (Onwubolu ve Babu, 2004).



Şekil 3.5. Basınçlı tank tasarım optimizasyon probleminin şematik görünümü: T_s (x_1): gövdenin kabuk kalınlığı; T_h (x_2): kapakların kabuk kalınlığı; R (x_3): iç yarıçap; ve L (x_4): tankın silindirik bölümünün uzunluğu (Onwubolu ve Babu, 2004)

Literatürde bu problemin sınırları, kısıtları farklı ve kesikli değer almayan değişkenlere sahip birkaç çeşidi üzerine de çalışmalar yapılmıştır (Eskandar ve ark., 2012; Yang, 2012). Bu çalışmada detayları Onwubolu ve Babu (2004) ve Clerc (2009) çalışmalarında verilen problem üzerine testler yapılmıştır.

Basınçlı tank tasarım optimizasyon problemi aşağıdaki gibi formüle edilmiştir;

Değişkenler:

$$x_1 \in [1.125, 12.5] \text{ tanecikli } 0.0625$$

$$x_2 \in [0.625, 12.5] \text{ tanecikli } 0.0625$$

$$x_3 \in [0, 240]$$

$$x_4 \in [0, 240]$$

Kısıtlar:

$$g_1(x) = 0.0193x_3 - x_1 \leq 0 \quad (3.21)$$

$$g_2(x) = 0.00954x_3 - x_2 \leq 0 \quad (3.22)$$

$$g_3(x) = 750.0 \times 1728.0 - \pi x_3^2 x_4 - \frac{4}{3} \pi x_3^3 \leq 0 \quad (3.23)$$

$$g_4(x) = x_4 - 240.0 \leq 0 \quad (3.24)$$

$$g_5(x) = 1.1 - x_1 \leq 0 \quad (3.25)$$

$$g_6(x) = 0.6 - x_2 \leq 0 \quad (3.26)$$

Amaç fonksiyonu:

$$f(x) = 0.6224x_1x_3x_4 + 1.7781x_2x_3^2 + 3.1611x_1^2x_4 + 19.84x_1^2x_3 \quad (3.27)$$

En uygun Değer ve parametreler:

$$f(x) = 7197.72893 \quad (3.28)$$

$$X = (x_1, x_2, x_3, x_4) = (1.125, 0.625, 58.2901554, 43.6926565) \quad (3.29)$$

burada, amaç fonksiyonu $f(x)$, basınçlı tankın imalat maliyetini göstermektedir.

3.3.2.2. CEC'11 gerçek dünya optimizasyon problem seti

CEC'11 problem seti literatürde kabul görmüş 22 adet gerçek dünya optimizasyon problemini barındırmaktadır. 2011 IEEE Evrimsel hesaplama kongresinde (CEC'11) sunulan bu problemlerle ilgili bilgiler Çizelge 3.3'de gösterilmiştir. Problemlerin daha kapsamlı açıklamaları Das ve Suganthan (2010) tarafından sunulan teknik raporda verilmektedir. Bu çalışmada sunulan algoritmalar, AAA ve AAA_{ML}, parametre sayıları ve kısıtları birbirinden farklı CEC'11 gerçek dünya problemleri üzerinde test edilmiş ve literatürde mevcut diğer başarılı metotlar ile kıyaslanmıştır.

Çizelge 3.3. Gerçek dünya optimizasyon problem seti

Problem	Boyut Sayısı	Kısıtlar
1. Parameter Estimation for Frequency-Modulated (FM) Sound Waves	6	Sınır kısıtlı
2. Lennard-Jones Potential Problem	$3 \times 10 = 30$ (10 atom problemi)	Sınır kısıtlı
3. The Bifunctional Catalyst Blend Optimal Control Problem	1	Sınır kısıtlı
4. Optimal Control of a Non-Linear Stirred Tank Reactor	1	Kısıtsız
5. Tersoff Potential for model Si (B)	$3 \times 10 = 30$	Sınır kısıtlı
6. Tersoff Potential for model Si (C)	(10 atom problemi)	
7. Spread Spectrum Radar Polly phase Code Design	20	Sınır kısıtlı
8. Transmission Network Expansion Planning (TNEP)	7	Eşitlik ve eşitsizlik kısıtlar
9. Large Scale Transmission Pricing Problem	$g \cdot d$ $g=6, d=21$	Doğrusal eşitlik kısıtlar
10. Circular Antenna Array Design Problem	12	Sınır kısıtlı
11.1 DED instance 1	120	Eşitsizlik kısıtlar
11.2 DED instance 2	216	Eşitsizlik kısıtlar
11.3 ELD Instance 1	6	Eşitsizlik kısıtlar
11.4 ELD Instance 2	13	Eşitsizlik kısıtlar
11.5 ELD Instance 3	15	Eşitsizlik kısıtlar
11.6 ELD Instance 4	40	Eşitsizlik kısıtlar
11.7 ELD Instance 5	140	Eşitsizlik kısıtlar
11.8 Hydrothermal Scheduling Instance 1	96	Eşitsizlik kısıtlar
11.9 Hydrothermal Scheduling Instance 2		
11.10 Hydrothermal Scheduling Instance 3		
12. Messenger: Spacecraft Trajectory Optimization Problem	26	Sınır kısıtlı
13. Cassini 2: Spacecraft Trajectory Optimization Problem	22	Sınır kısıtlı

3.4. Performans Değerlendirme Kriterleri

Literatüre yeni bir algoritma sunulduğu zaman bu yöntemin başarısını tarafsız bir şekilde ortaya koymak gereklidir. Farklı problem veya fonksiyon setleri üzerinde yapılan test çalışmaları sonrası elde edilen sonuçların değerlendirilmesi ve yorumlanması önemli bir konudur. Aynı veri kümesinden farklı ölçütler kullanılarak farklı sonuçlar ve çıkarımlar yapılabilir. Fakat bir sezgisel algoritmanın çözüme ne kadar hızlı ulaştığı, bulduğu çözümlerin kalitesi, birbirinden bağımsız çalışmalarda çözümlerin kalitesini koruyabilmesi ve farklı karakterlerdeki problemlerde başarısını sürdürebilmesi önemlidir. Yeni bir yöntem bu kriterlerden en az birini sağlamalıdır. Bunlara ek olarak algoritma basit (kodlanması ve geliştirilmesi kolay) ve adaptif (belirli bir problem veya problem türüne bağımlı olmayan) olmalıdır.

Bu çalışmada, algoritmanın performansını analiz etmeden önce kıyaslanan tüm yöntemlerin eşit şartlarda çalışması şu şekilde sağlanmıştır:

- Kıyaslanan algoritmalar aynı problem veya problem setleri üzerine uygulanmıştır.
- Uygulanan problemlerin özellikleri (maliyet fonksiyonları, çözüm uzayı sınırları, boyutları, eşitlik ve eşitsizlik kısıtları ve karar değişkenlerinin sürekli veya ayrık olmaları vb.) tüm testlerde aynı belirlenmiştir.
- Zaman verimliliği kıyaslaması yapıldığı durumlarda algoritmalar aynı bilgisayar konfigürasyonları ve yazılım platformlarında çalıştırılmıştır.
- Kıyaslanan algoritmalar eşit durdurma kriterlerinde (süre, eşik değerleri veya uygunluk fonksiyonu hesaplama sayıları vb.) çalıştırılmıştır.
- Algoritmaların birbirinden bağımsız çalıştırılma sayıları eşit alınmıştır.
- Her bir algoritma her bir bağımsız çalışmada çözüm uzayında rastgele değerler ile başlatılmıştır.
- Algoritmaların kendilerine özgü parametreleri problemlerden bağımsız tutulmuştur.

Geliştirilen AAA ve AAA_{ML} algoritmalarının çözüme ulaşma hızlarını değerlendirmek için;

- Algoritmanın başlangıcından durdurma kriterine ulaşıncaya kadar geçen süreler hesaplanmıştır.

- Algoritmanın başlangıcından itibaren düzenli aralıklar ile (veya belirli maliyet fonksiyonu hesaplama sayısında) bulunduğu çözümlerin gösterildiği yakınsama eğrileri oluşturulmuştur.

Geliştirilen AAA ve AAA_{ML} algoritmalarının buldukları çözümlerin kalitesini değerlendirmek için;

- Bilinen en iyi çözümler ile bulunan en iyi çözümler arasındaki farkların (hataların) gösterimi kullanılmıştır.
- Aynı problem için birbirinden bağımsız çalışmalarda bulunduğu çözümlerdeki başarı oranı kullanılmıştır.
- Algoritmaların tüm çalışmalarda ulaştığı çözümlerin en iyi, en kötü, ortalama ve standart sapma değerleri gibi istatistiki sonuçlar kullanılmıştır.
- Algoritmaların tüm çalışmalarda ulaştığı çözümlerin dağılımının daha ayrıntılı gösterildiği kutu ve bıyık diyagramları (box-plot) oluşturulmuştur.
- Ayrıca verilen tek bir problem için birbirinden bağımsız tüm çalışmalardan elde edilen çözümlerin kalitesini istatistiksel olarak kanıtlamak için tek problem analizi kullanılmıştır.

Tek problem analizi hesaplamalı zekâ deneylerinin problem çözme başarısının ikili karşılaştırması için kullanılabilir. Bu analiz verilen bir problem için algoritmanın birkaç farklı çalışmada elde edilen global optimum değerlerin sonuçlarını kullanır. Bu çalışmada ikili kıyaslamalar için Wilcoxon işaretli-sıralama testi kullanılmıştır. Test algoritmaların problem bazlı ikili karşılaştırmaları için tüm bağımsız çalışmalardan elde edilen global optimum değerler kullanılarak gerçekleştirilmiştir. Hipotez testi verilen sonuçlardan iki algoritma hakkında çıkarımlar yapmak için kullanılabilir. Bu amaç için H₀ (null hipotezi): 'İki algoritmanın sonuçları arasında anlamlı bir fark yoktur' ve H₁ (alternatif hipotez) ise tam tersidir. Bir hipotezi reddetmek için istatistiksel bir prosedür uygulandığı zaman, reddedilebilir hipotez düzeyini belirlemek için bir anlam seviyesi α kullanılır. Testlerde anlam seviyesi $\alpha=0.05$ olarak kullanılmıştır. p-değeri (p-value) hipotez doğru olduğunda H₀ hipotezini reddetmenin tahmini olasılığıdır. Küçük bir p-değeri null hipotezine karşı güçlü bir kanıtı işaret eder. R₊ değeri ilk algoritmanın ikinciden daha iyi olduğu sonuçlardaki sıralama değerlerinin toplamalarını ifade eder ve R₋ ise ikinci algoritmanın daha iyi olduğu sonuçlardaki sıralama değerlerinin

toplamlarını ifade eder. T ise bu toplamların küçüğünü temsil eder ($T=\min(R+,R-)$) (Derrac ve ark., 2011).

Geliştirilen AAA ve AAA_{ML} algoritmalarının farklı özelliklere sahip problemlerdeki başarılarını sürdürebilmeleri yani tutarlılıklarını değerlendirmek için;

- Kullanılan problem veya fonksiyon seti üzerinde sıralama seviyeleri (ranking) hesaplanmıştır.
- Kullanılan problem veya fonksiyon seti üzerinde bilinen en iyi çözüm ile ulaşılan en iyi çözümlerin farklarından (hatalarından) yola çıkarak Ortalama Karesel Hata (*Mean Square Error - MSE*), Kök Ortalama Karesel Hata (*Root Mean Square Error - RMSE*) ve Ortalama Mutlak Hata Yüzdesi (*Mean Absolute Percentage Error - MAPE*) yöntemleri ile algoritmaların genel performans değerleri hesaplanmıştır. MSE, RMSE ve MAPE değerleri Denklemler 3.30–3.32 ile hesaplanmıştır.

$$MSE = \frac{\sum_{f=1}^n (evaluated(f) - predicted(f))^2}{n} \quad (3.30)$$

$$RMSE = \sqrt{\frac{\sum_{f=1}^n (evaluated(f) - predicted(f))^2}{n}} \quad (3.31)$$

$$MAPE = \frac{\sum_{f=1}^n |evaluated(f) - predicted(f)| / evaluated(f)}{n} \quad (3.32)$$

burada, $evaluated(f)$ algoritmanın durdurma kriterine vardığında hesaplanan optimum değer, $predicted(f)$ algoritmadan beklenen global optimum değer ve n fonksiyon sayısıdır.

Her bir fonksiyon için beklenen değer ile hesaplanan değer arasındaki fark yani hata değeri algoritmanın çözüm kalitesini gösterir. Tüm fonksiyonlardaki hata değerlerinden yola çıkarak MSE, RMSE ve MAPE yöntemleri ile algoritmaların genel performans değerleri kıyaslanmıştır (Aydilek ve Arslan, 2013; Chen, 2013).

4. ARAŞTIRMA SONUÇLARI VE TARTIŞMA

Bu bölümde, önerilen yeni sezgisel metot AAA ve geliştirilmiş sürümü AAA_{ML}'nin performans testleri yapılmış ve literatürde var olan diğer sezgisel yöntemler ile kıyaslanmıştır. Bir önceki bölümde anlatılan test fonksiyon ve problem setleri ayrı ayrı ele alınıp değerlendirilmiştir. Yapılan test çalışmaları iki temel bölümde ele alınmıştır.

İlk olarak test fonksiyonları üzerinde yapılan çalışmaların sonuçları gösterilmektedir. İki farklı test fonksiyon seti (CEC'05 ve CEC'13) kullanılmıştır. CEC'05 seti üzerinde AAA'nın performansı, CEC'13 seti üzerinde AAA ve AAA_{ML}'nin performansı analiz edilmiştir.

İkinci olarak gerçek dünya problemleri üzerinde yapılan çalışmaların sonuçları gösterilmektedir. Gerçek dünya problemleri üzerinde yapılan çalışmalar iki ayrı bölümde sunulmuştur. Birincisi basınçlı tank tasarım optimizasyon problemi üzerinde AAA'nın performansı, ikinci ve son olarak da CEC'11 gerçek dünya optimizasyon problem seti üzerinde AAA ve AAA_{ML}'nin performansı analiz edilmiştir.

4.1. Test Fonksiyonlarında Performans Değerlendirmesi

4.1.1. CEC'05 test fonksiyonlarında AAA'nın performans değerlendirilmesi

CEC'05 test seti farklı özelliklere sahip kaydırılmış ve/veya döndürülmüş 25 adet fonksiyondan oluşmaktadır. Bu fonksiyonlar 10, 30 ve 50 boyutta çalıştırılmıştır. Kıyaslamalar için melez olmayan, temel, sürekli değer alan optimizasyon problemleri için uyarlanmış veya geliştirilmiş optimizasyon algoritmaları kullanılmıştır. Bu optimizasyon algoritmalarından, yapay arı kolonisi (ABC) algoritması (Karaboğa, 2005), arılar algoritması (BA) (Pham ve ark., 2006) ve sürekli etki alanı için karınca kolonisi optimizasyon (ACO_R) algoritması (Socha ve Dorigo, 2008) yaşayan bir organizmanın yiyecek toplama davranışını taklit etmeye ve modellemeye dayanır. Diferansiyel evrim (DE) algoritması (Storn ve Price, 1997), doğadaki evrimsel sürecin simülasyonuna dayanır. Popülasyon tabanlı harmoni arama (HS_{POP}) algoritması (Mukhopadhyay ve ark., 2008) ise müzisyenlerin müzik yaparken aralarındaki uyuma dayanır.

Kıyaslamalarda tüm metotlar için;

- El-Abd (2012) tarafından önerildiği gibi popülasyon sayısı 40 olarak ayarlanmıştır.
- Durdurma kriteri olarak fonksiyon hesaplama sayısı (hesaplama maliyeti) kullanılmıştır. CEC'05 teknik raporunda belirtilen kriterlere uygun olarak maksimum fonksiyon hesaplama sayısı her fonksiyon için 10, 30 ve 50 boyutta sırasıyla 100,000, 300,000 ve 500,000 olarak belirlenmiştir.
- Başlangıç aday çözümleri her bir fonksiyon için belirtilen alt ve üst sınırlar arasında rastgele olarak başlatılmıştır.
- Sezgisel algoritmalar doğaları gereği her çalışmada farklı sonuçlar verebilmektedir. Bu nedenle daha kesin sonuçlar verebilmek için her fonksiyon için 30 farklı çalışmanın sonuçları rapor edilmiştir.

Kıyaslamalarda kullanılan optimizasyon algoritmalarının ortak şartları ve parametrelerine ilaveten her bir algoritmaya özgü parametre ve şartlar ise El-Abd (2012) çalışmasında önerildiği gibi;

- ABC algoritması için *limit* parametresi gözcü arı sayısı ile problem boyutunun çarpımı olarak ayarlanmıştır.
- BA için, seçilen en iyi besin kaynakları (flower patches) sayısı, $m = 30$; seçilen elit besin kaynaklarının sayısı, $e = 10$; seçilen en iyi besin kaynakları etrafında görevlendirilen arıların sayısı, $n1 = 15$; seçilen elit besin kaynakları etrafında görevlendirilen arıların sayısı, $n2 = 30$ ve komşuluk aramak için besin kaynağı yarıçapı, $ngh = 1\%$ olarak ayarlanmıştır.
- DE algoritmasının parametreleri: adım büyüklüğü, $F_weight = 0.9$ ve çaprazlama olasılık sabiti, $F_CR = 0.1$ olarak ayarlanmıştır.
- HS_{POP} algoritması için, harmoni belleği dikkate alma oranı, $HMCR = 0.99$ ve perde ayarlama oranı, $PAR = 0.5$ olarak belirlenmiştir.
- ACO_R algoritması için, bir çevrimde kullanılan karıncaların sayısı, $m = 2$; bir arşiv boyutu $k = 50$; arama sürecinin yerelliği, $q = 0.0001$ ve yakınsama hızı, $\rho = 0.85$ olarak belirlenmiştir.
- AAA için, yapılan ön çalışmaların sonucu olarak, enerji kaybı, $e = 0.3$; kesme kuvveti, $\Delta = 2$ ve adaptasyon katsayısı, $A_p = 0.5$ olarak belirlenmiştir.

Yukarıda belirtilen şartlar altında kıyaslanan algoritmaların deneysel sonuçları Çizelge 4.1–4.9'da gösterilmiştir. Tek-modlu fonksiyonlar üzerinde yapılan çalışmaların Çizelge 4.1–4.3'de, çok-modlu fonksiyonların Çizelge 4.4–4.6'da ve karma fonksiyonların Çizelge 4.7–4.9'da sonuçları gösterilmiştir. Bu çizelgelerde

algoritmaların her bir fonksiyon için 30 kere bağımsız çalıştırılması sonucunda elde edilen en iyi değer, ortalama değer ve standart sapmaları gösterilmiştir. Her bir fonksiyon için bulunan en iyi ortalama değerler koyu renkler ile belirtilmiştir. Ayrıca algoritmaların sonuca ulaşma hızlarını değerlendirebilmek için bulunan sonuçların yakınsama eğrileri Şekil 4.1–4.3’de gösterilmiştir. Tek modlu fonksiyonlar için yakınsama eğrileri Şekil 4.1’de, çok-modlu fonksiyonlar için Şekil 4.2’de ve karma fonksiyonlar için Şekil 4.3’de gösterilmiştir. Yakınsama eğri grafiklerinde çözüm kalitesi açısından diğer algoritmalarından daha başarısız olan BA gösterilmemiştir.

Çizelge 4.1. 10 boyutlu tek-modlu CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri

		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F1	Eniyi	0.000E+00	0.000E+00	2.997E+00	0.000E+00	0.000E+00	0.000E+00
	Ort.	0.000E+00	1.895E-15	4.233E+03	0.000E+00	2.274E-14	0.000E+00
	Std.	0.000E+00	1.038E-14	3.812E+03	0.000E+00	3.533E-14	0.000E+00
F2	Eniyi	1.541E-08	3.077E-01	4.257E+00	5.013E+00	0.000E+00	4.607E-03
	Ort.	1.184E-06	3.322E+00	4.898E+03	1.403E+01	1.478E-13	2.774E+01
	Std.	1.757E-06	2.893E+00	3.547E+03	5.389E+00	1.263E-13	3.481E+01
F3	Eniyi	5.199E+04	1.860E+05	3.169E+05	3.482E+05	8.126E+04	3.230E+04
	Ort.	3.111E+05	7.224E+05	1.528E+07	1.753E+06	2.238E+06	2.196E+05
	Std.	2.441E+05	3.527E+05	1.959E+07	6.862E+05	2.689E+06	1.723E+05
F4	Eniyi	4.191E-05	2.894E+02	1.597E+03	5.814E+01	5.684E-14	8.339E-02
	Ort.	8.199E-03	1.327E+03	8.885E+03	1.483E+02	3.752E-13	5.989E+01
	Std.	9.187E-03	6.884E+02	4.665E+03	6.227E+01	3.221E-13	1.074E+02
F5	Eniyi	0.000E+00	8.169E+00	8.165E+02	1.206E-01	3.456E+01	1.855E-10
	Ort.	1.601E-11	7.750E+01	8.168E+03	3.384E+00	3.938E+02	5.555E+01
	Std.	3.433E-11	8.828E+01	3.946E+03	3.175E+00	4.884E+02	1.058E+02

Çizelge 4.2. 30 boyutlu tek-modlu CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri


		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F1	Eniyi	5.684E-14	1.137E-13	2.412E+01	5.684E-14	5.684E-14	0.000E+00
	Ort.	5.874E-14	1.213E-13	3.730E+04	5.684E-14	1.819E-13	0.000E+00
	Std.	1.038E-14	1.965E-14	2.362E+04	2.568E-29	9.605E-14	0.000E+00
F2	Eniyi	1.536E+00	3.035E+02	2.145E+02	1.518E+03	2.028E-06	1.100E+01
	Ort.	1.043E+01	2.256E+03	4.209E+04	2.966E+03	3.866E-03	2.030E+02
	Std.	7.792E+00	9.365E+02	2.298E+04	6.281E+02	7.647E-03	1.851E+02
F3	Eniyi	1.486E+06	3.800E+06	1.506E+07	1.463E+07	5.022E+07	1.502E+06
	Ort.	3.059E+06	7.514E+06	3.100E+08	2.782E+07	3.215E+08	3.319E+06
	Std.	9.623E+05	1.941E+06	3.166E+08	8.752E+06	1.833E+08	1.201E+06
F4	Eniyi	2.319E+03	2.880E+04	3.091E+04	9.640E+03	1.216E+01	2.294E+01
	Ort.	8.573E+03	4.251E+04	7.579E+04	1.474E+04	4.836E+02	2.147E+02
	Std.	3.766E+03	5.753E+03	1.638E+04	2.979E+03	7.762E+02	1.894E+02
F5	Eniyi	2.699E+03	6.775E+03	9.901E+03	3.988E+03	1.600E+03	1.056E+03
	Ort.	4.171E+03	9.508E+03	2.381E+04	5.516E+03	4.836E+03	2.088E+03
	Std.	9.825E+02	1.215E+03	7.818E+03	6.664E+02	2.130E+03	4.159E+02

Çizelge 4.3. 50 boyutlu tek-modlu CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri

		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F1	Eniyi	1.137E-13	2.274E-13	5.949E+01	5.684E-14	1.137E-13	0.000E+00
	Ort.	1.364E-13	2.785E-13	7.612E+04	1.080E-13	3.051E-13	1.426E-06
	Std.	3.202E-14	4.047E-14	5.591E+04	1.734E-14	1.526E-13	7.813E-06
F2	Eniyi	1.211E+02	8.099E+03	9.133E+02	2.083E+04	2.710E+03	5.239E+01
	Ort.	3.768E+02	1.551E+04	9.981E+04	2.765E+04	6.715E+04	2.998E+02
	Std.	1.769E+02	2.976E+03	7.231E+04	3.221E+03	6.757E+04	2.670E+02
F3	Eniyi	2.438E+06	8.639E+06	1.259E+07	5.499E+07	3.137E+08	2.283E+06
	Ort.	4.806E+06	1.439E+07	1.737E+09	1.015E+08	1.913E+09	4.213E+06
	Std.	1.217E+06	3.129E+06	1.538E+09	2.410E+07	1.167E+09	1.559E+06
F4	Eniyi	2.288E+04	9.732E+04	1.055E+05	4.510E+04	3.137E+04	7.575E+02
	Ort.	3.925E+04	1.194E+05	2.061E+05	6.063E+04	1.463E+05	2.417E+03
	Std.	1.045E+04	9.750E+03	4.876E+04	8.404E+03	9.059E+04	9.874E+02
F5	Eniyi	6.491E+03	1.895E+04	1.227E+04	1.114E+04	5.097E+03	2.045E+03
	Ort.	1.148E+04	2.365E+04	3.103E+04	1.328E+04	1.108E+04	3.426E+03
	Std.	1.717E+03	2.109E+03	9.531E+03	1.036E+03	3.916E+03	5.726E+02

Tek-modlu fonksiyonlar tek optimum nokta içeren ve geniş arama uzayına sahip problemlerdir. Bu fonksiyonlarda yerel minimumlara takılma problemi yoktur. Bu yüzden iyi sonuç bulan bireyleri harmoni belleğinde tutan ve diğer bireyleri bu harmoni belleğe göre uyarlayan HS_{POP} algoritması bu tip fonksiyonlarda yüksek başarı sağlamaktadır. AAA tek-modlu fonksiyonlar üzerinde genel olarak başarılı sonuçlar vermektedir (Çizelge 4.1–4.3). 10 boyutta F1 ve F5 fonksiyonlarında, 30 boyutta F3 fonksiyonunda diğer algoritmalar arasında en iyi değerlere ulaşmıştır. Diğer fonksiyonların (30 boyutta F4 fonksiyonu hariç) tümünde AAA'nın bulunan en iyi değerlere en yakın sonuçları verdiği gözlemlenmektedir. AAA ışık kaynağının seçiminde hafıza kullanmamasının ve helisel hareketi ile ışığa yavaş yaklaşmasının dezavantajını adaptasyon ve evrim süreci ile dengelemektedir. Bu denge en iyi veya en iyiye yakın sonuçlar vermesine neden olmaktadır.

Tek-modlu fonksiyonların yakınsama eğrilerinde (Şekil 4.1) algoritmaların genel olarak birbirlerine yakın sonuçlar verdiği fonksiyonlar seçilmiştir. Çizelge 4.1–4.3 ve Şekil 4.1 incelendiğinde AAA'nın hem çözüm kalitesi hem de yakınsama eğrileri açısından iyi sonuçlar verdiği gözlemlenmektedir. Şekil 4.1 her algoritmanın tek-modlu fonksiyonlar için bağımsız 30 çalışmanın ortalamalarının yakınsama eğrilerini gösterir. Yakınsama eğrileri AAA'nın düzenli olarak yerel optimumlardan kaçınarak global optimuma yakınsadığını göstermektedir. AAA'nın yakınsama oranları diğer algoritmalar ile kıyaslandığında, daha az fonksiyon hesaplama ile optimum çözümlere vardığı görülmektedir. Şekil 4.1'de gösterildiği gibi AAA farklı fonksiyon ve boyutlarda başarısını korumaktadır.



Şekil 4.1. Bazı tek-modlu CEC'05 fonksiyonları için AAA, ABC, DE, ACO_R ve HS_{POP} algoritmalarının yakınsama eğrileri

Çok-modlu fonksiyonlar birçok yerel optimum ve tek global optimum içeren fonksiyonlardır. Bu fonksiyonlar birçok yerel optimuma sahip oldukları için çözümü zor problem türleridir. AAA'nın performansı çok-modlu fonksiyonlarda daha fazla göze çarpmaktadır. AAA 10, 30 ve 50 boyutta yapılan 27 adet testin 14 tanesinde en iyi performansı sağlamıştır (Çizelge 4.4–4.6). F7 ve F9 fonksiyonunun 30 ve 50 boyutları hariç diğer testlerde ise en iyi sonuçlara çok yakın değerler bulmuştur. Algoritmanın ortalama değerlerdeki başarısı standart sapmaları ve Şekil 4.2'deki yakınsama hızları ile daha belirginleşmiştir. Önerilen algoritmanın bu başarısının sebebi yerel arama ve global arama arasındaki dengeyi iyi sağlamasıdır. Tek-modlu fonksiyonlarda dezavantaj gibi görünen ışık kaynağının seçilmesindeki yöntem ve helisel hareket modeli bu tip zor ve çok fazla yerel minimuma sahip problemlerde avantaj olmaktadır. Çünkü ışık kaynağının seçilmesinde güncel bilginin kullanılması yerel minimumlardan kaçınmayı sağlamaktadır. Ayrıca helisel hareket sayesinde arama uzayında daha verimli arama yapılmaktadır. Her bir alg kolonisi helisel hareket ile ışığa doğru doğrusal hareketinin yanı sıra açısal hareketleri ile rotasındaki global optimumları yakalama imkânı bulur.

Çizelge 4.4. 10 boyutlu çok-modlu CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri


		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F6	Eniyi	1.623E-06	5.465E-02	7.899E+02	3.020E-01	3.661E-06	5.533E-01
	Ort.	1.219E+00	1.491E+00	2.936E+08	3.033E+00	8.611E+01	2.709E+01
	Std.	1.491E+00	2.487E+00	4.188E+08	2.213E+00	4.412E+02	2.839E+01
F7	Eniyi	1.267E+03	1.267E+03	1.560E+02	2.363E-01	3.161E-01	1.267E+03
	Ort.	1.267E+03	1.267E+03	1.645E+03	4.106E-01	8.581E-01	1.267E+03
	Std.	3.288E-02	2.313E-13	7.414E+02	9.131E-02	2.913E-01	1.094E-02
F8	Eniyi	2.002E+01	2.019E+01	2.017E+01	2.021E+01	2.014E+01	2.018E+01
	Ort.	2.016E+01	2.033E+01	2.034E+01	2.040E+01	2.035E+01	2.033E+01
	Std.	8.695E-02	7.863E-02	7.941E-02	6.267E-02	8.296E-02	5.667E-02
F9	Eniyi	0.000E+00	0.000E+00	1.766E+01	0.000E+00	2.985E+00	0.000E+00
	Ort.	0.000E+00	0.000E+00	5.135E+01	0.000E+00	7.735E+00	2.801E-07
	Std.	0.000E+00	0.000E+00	1.820E+01	0.000E+00	3.603E+00	1.534E-06
F10	Eniyi	4.975E+00	1.008E+01	3.757E+01	1.144E+01	7.091E+00	1.751E+01
	Ort.	1.501E+01	2.518E+01	7.113E+01	1.911E+01	2.340E+01	2.193E+01
	Std.	5.593E+00	7.635E+00	2.512E+01	3.599E+00	7.573E+00	2.371E+00
F11	Eniyi	1.499E+00	4.175E+00	6.003E+00	4.875E+00	4.981E+00	8.113E+00
	Ort.	3.667E+00	5.415E+00	9.360E+00	6.102E+00	8.604E+00	9.221E+00
	Std.	9.292E-01	7.297E-01	1.518E+00	6.214E-01	9.727E-01	4.890E-01
F12	Eniyi	2.439E+00	8.504E+01	6.907E+03	1.715E+02	1.349E+04	4.466E+01
	Ort.	5.435E+02	3.070E+02	3.014E+04	4.341E+02	2.923E+04	3.168E+03
	Std.	7.766E+02	1.634E+02	8.858E+03	1.850E+02	6.722E+03	3.135E+03
F13	Eniyi	1.228E-01	3.125E-02	4.722E+00	7.506E-02	8.360E-01	2.048E-01
	Ort.	4.231E-01	2.241E-01	9.636E+00	2.936E-01	1.692E+00	8.897E-01
	Std.	1.329E-01	8.985E-02	3.494E+00	1.176E-01	5.347E-01	4.433E-01
F14	Eniyi	2.698E+00	2.992E+00	3.256E+00	3.174E+00	3.219E+00	1.170E+00
	Ort.	3.296E+00	3.412E+00	3.940E+00	3.459E+00	3.800E+00	2.485E+00
	Std.	2.823E-01	1.441E-01	2.307E-01	1.299E-01	2.861E-01	6.736E-01

Çizelge 4.5. 30 boyutlu çok-modlu CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri

		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F6	Eniyi	8.076E-04	5.616E-02	1.864E+04	2.240E+01	8.643E-05	2.718E+01
	Ort.	1.384E+01	5.506E+00	2.150E+10	3.970E+01	3.914E+01	1.306E+02
	Std.	2.177E+01	5.613E+00	1.786E+10	1.961E+01	7.112E+01	1.218E+02
F7	Eniyi	4.696E+03	4.696E+03	8.685E+02	9.916E-02	1.535E-12	4.696E+03
	Ort.	4.696E+03	4.696E+03	7.393E+03	1.922E-01	3.396E-01	4.696E+03
	Std.	0.000E+00	0.000E+00	2.896E+03	4.537E-02	3.252E-01	0.000E+00
F8	Eniyi	2.009E+01	2.080E+01	2.081E+01	2.074E+01	2.083E+01	2.080E+01
	Ort.	2.018E+01	2.091E+01	2.095E+01	2.095E+01	2.095E+01	2.094E+01
	Std.	7.323E-02	4.794E-02	4.464E-02	6.506E-02	4.525E-02	5.480E-02
F9	Eniyi	5.684E-14	5.684E-14	1.709E+02	5.684E-14	2.288E+01	0.000E+00
	Ort.	3.317E-02	9.853E-14	3.216E+02	5.684E-14	4.364E+01	1.088E+01
	Std.	1.817E-01	3.636E-14	8.604E+01	2.568E-29	2.285E+01	1.745E+01
F10	Eniyi	6.954E+01	2.021E+02	3.084E+02	1.294E+02	1.803E+02	1.487E+02
	Ort.	1.535E+02	3.018E+02	5.374E+02	1.642E+02	2.258E+02	1.628E+02
	Std.	3.947E+01	4.591E+01	1.017E+02	1.593E+01	2.190E+01	7.746E+00
F11	Eniyi	1.412E+01	2.451E+01	2.309E+01	2.468E+01	3.716E+01	3.597E+01
	Ort.	2.241E+01	2.763E+01	3.604E+01	2.814E+01	3.942E+01	3.961E+01
	Std.	2.976E+00	1.408E+00	5.183E+00	1.613E+00	9.357E-01	1.088E+00
F12	Eniyi	4.578E+02	1.022E+04	8.780E+05	1.955E+04	8.973E+05	3.525E+05
	Ort.	1.357E+04	1.822E+04	1.094E+06	3.657E+04	1.075E+06	5.266E+05
	Std.	1.171E+04	4.421E+03	1.093E+05	8.603E+03	7.674E+04	6.509E+04
F13	Eniyi	1.083E+00	1.008E+00	3.175E+01	1.948E+00	8.707E+00	7.379E+00
	Ort.	1.959E+00	1.264E+00	1.495E+02	2.474E+00	1.424E+01	1.163E+01
	Std.	5.224E-01	1.314E-01	1.491E+02	2.275E-01	2.461E+00	1.507E+00
F14	Eniyi	1.128E+01	1.229E+01	1.295E+01	1.252E+01	1.334E+01	1.286E+01
	Ort.	1.269E+01	1.293E+01	1.364E+01	1.291E+01	1.386E+01	1.329E+01
	Std.	4.711E-01	2.703E-01	2.936E-01	1.868E-01	1.873E-01	1.552E-01

Çizelge 4.6. 50 boyutlu çok-modlu CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri

		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F6	Eniyi	8.878E-02	3.708E-02	7.996E+04	4.092E+01	7.682E-05	4.154E+01
	Ort.	3.144E+01	9.970E+00	5.817E+10	6.137E+01	7.218E+02	1.421E+02
	Std.	3.893E+01	1.264E+01	3.598E+10	2.454E+01	2.154E+03	6.366E+01
F7	Eniyi	6.195E+03	6.195E+03	5.431E+02	1.577E-01	1.307E-12	6.195E+03
	Ort.	6.195E+03	6.195E+03	1.203E+04	2.302E-01	1.629E-01	6.195E+03
	Std.	9.250E-13	9.250E-13	3.545E+03	4.217E-02	3.218E-01	9.250E-13
F8	Eniyi	2.008E+01	2.103E+01	2.101E+01	2.104E+01	2.103E+01	2.106E+01
	Ort.	2.015E+01	2.111E+01	2.112E+01	2.114E+01	2.113E+01	2.115E+01
	Std.	4.601E-02	3.518E-02	4.434E-02	3.539E-02	3.592E-02	2.882E-02
F9	Eniyi	1.137E-13	1.705E-13	3.511E+02	1.137E-13	4.378E+01	5.684E-14
	Ort.	5.313E-01	3.676E-13	6.144E+02	1.137E-13	1.217E+02	8.765E+01
	Std.	6.787E-01	3.084E-13	1.720E+02	1.027E-28	6.944E+01	4.698E+01
F10	Eniyi	2.098E+02	7.532E+02	9.126E+02	3.223E+02	4.196E+02	3.037E+02
	Ort.	3.692E+02	9.341E+02	1.132E+03	4.070E+02	4.594E+02	3.312E+02
	Std.	7.344E+01	9.031E+01	1.438E+02	3.067E+01	3.348E+01	1.179E+01
F11	Eniyi	3.567E+01	5.044E+01	4.933E+01	5.677E+01	6.836E+01	6.885E+01
	Ort.	4.694E+01	5.507E+01	6.544E+01	6.181E+01	7.265E+01	7.237E+01
	Std.	4.579E+00	2.110E+00	8.736E+00	2.044E+00	1.392E+00	1.457E+00
F12	Eniyi	3.988E+03	5.012E+04	4.351E+06	2.864E+05	4.749E+06	2.209E+06
	Ort.	4.270E+04	8.320E+04	5.396E+06	3.284E+05	5.428E+06	2.544E+06
	Std.	2.830E+04	1.687E+04	5.832E+05	2.954E+04	3.783E+05	1.912E+05
F13	Eniyi	2.549E+00	2.020E+00	7.092E+01	6.816E+00	2.501E+01	2.325E+01
	Ort.	3.513E+00	2.466E+00	7.074E+02	8.111E+00	3.326E+01	2.674E+01
	Std.	6.883E-01	2.305E-01	6.084E+02	5.643E-01	4.138E+00	1.355E+00
F14	Eniyi	2.162E+01	2.225E+01	2.257E+01	2.282E+01	2.316E+01	2.290E+01
	Ort.	2.247E+01	2.267E+01	2.343E+01	2.316E+01	2.376E+01	2.315E+01
	Std.	3.836E-01	1.797E-01	2.832E-01	1.450E-01	1.821E-01	1.414E-01



Şekil 4.2. Bazı çok- modlu CEC'05 fonksiyonları için AAA, ABC, DE, ACO_R ve HS_{POP} algoritmalarının yakınsama eğrileri

AAA kıyaslanan diğer algoritmalara göre tek-modlu ve çok-modlu fonksiyonların yanı sıra karma fonksiyonlarda da başarılı sonuçlar üretmiştir. Genel olarak bakıldığında farklı tür ve karakterdeki problemlerde başarısını koruduğu ve kıyaslanan diğer algoritmalara karşı genel bir üstünlük kurduğu görülmektedir. Örneğin HS_{POP} algoritması tek-modlu fonksiyonlarda göstermiş olduğu başarıyı (Çizelge 4.1–4.3) çok-modlu (Çizelge 4.4–4.6) ve karma fonksiyonlarda (4.7–4.9) gösterememiştir. Benzer şekilde ACO_R algoritması karma fonksiyonlardaki başarısının yanında çok-modlu fonksiyonlarda iyi sonuçlar verememektedir. ABC algoritması ise çok modlu ve karma fonksiyonlarda AAA'ya yakın sonuçlar vermekle beraber tek-modlu fonksiyonlarda başarılı sonuçlar verememektedir.

Çizelge 4.7. 10 boyutlu karma CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri


		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F15	Eniyi	0.000E+00	0.000E+00	4.100E+02	4.867E-01	1.026E+02	0.000E+00
	Ort.	3.311E+01	7.329E-02	5.921E+02	1.653E+01	4.355E+02	2.782E+02
	Std.	3.778E+01	3.227E-01	9.820E+01	1.813E+01	1.876E+02	1.786E+02
F16	Eniyi	9.222E+01	1.238E+02	1.385E+02	1.107E+02	1.066E+02	1.159E+02
	Ort.	1.293E+02	1.476E+02	3.212E+02	1.443E+02	2.055E+02	1.380E+02
	Std.	1.596E+01	1.384E+01	7.830E+01	1.475E+01	1.178E+02	1.030E+01
F17	Eniyi	9.984E+01	1.404E+02	1.659E+02	1.384E+02	1.215E+02	1.285E+02
	Ort.	1.353E+02	1.694E+02	3.442E+02	1.730E+02	1.890E+02	1.507E+02
	Std.	1.825E+01	1.529E+01	8.931E+01	1.422E+01	5.524E+01	1.146E+01
F18	Eniyi	3.000E+02	4.035E+02	9.685E+02	5.114E+02	7.794E+02	6.269E+02
	Ort.	4.864E+02	5.086E+02	1.104E+03	7.459E+02	9.317E+02	8.541E+02
	Std.	2.242E+02	7.031E+01	5.856E+01	1.012E+02	9.863E+01	1.013E+02
F19	Eniyi	3.000E+02	4.349E+02	9.810E+02	3.740E+02	8.001E+02	3.002E+02
	Ort.	4.529E+02	5.213E+02	1.111E+03	6.980E+02	9.552E+02	8.265E+02
	Std.	1.993E+02	7.592E+01	6.753E+01	1.363E+02	6.679E+01	1.545E+02
F20	Eniyi	3.000E+02	5.000E+02	8.019E+02	5.007E+02	7.244E+02	5.375E+02
	Ort.	4.842E+02	5.430E+02	1.097E+03	7.536E+02	9.396E+02	8.674E+02
	Std.	2.135E+02	1.075E+02	8.884E+01	1.110E+02	9.376E+01	1.019E+02
F21	Eniyi	3.000E+02	2.035E+02	5.037E+02	2.270E+02	5.000E+02	5.000E+02
	Ort.	5.233E+02	3.459E+02	1.266E+03	4.642E+02	1.088E+03	1.038E+03
	Std.	1.006E+02	9.939E+01	1.574E+02	9.040E+01	2.130E+02	1.990E+02
F22	Eniyi	3.000E+02	2.008E+02	9.150E+02	7.760E+02	5.318E+02	7.574E+02
	Ort.	7.347E+02	7.084E+02	1.025E+03	7.941E+02	8.315E+02	7.873E+02
	Std.	1.196E+02	1.905E+02	6.621E+01	7.699E+00	1.010E+02	2.429E+01
F24	Eniyi	2.000E+02	2.000E+02	1.110E+03	2.000E+02	3.744E+02	2.000E+02
	Ort.	2.000E+02	2.000E+02	1.264E+03	2.000E+02	6.038E+02	2.400E+02
	Std.	0.000E+00	0.000E+00	5.919E+01	1.201E-02	2.904E+02	1.038E+02
F25	Eniyi	8.120E+02	6.176E+02	1.303E+03	8.183E+02	3.727E+02	2.000E+02
	Ort.	8.170E+02	7.689E+02	1.390E+03	8.272E+02	5.708E+02	3.196E+02
	Std.	2.464E+00	9.427E+01	4.070E+01	3.619E+00	2.967E+02	1.165E+02

Çizelge 4.8. 30 boyutlu karma CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri

		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F15	Eniyi	0.000E+00	1.791E-11	5.032E+02	1.278E+01	2.494E+02	2.000E+02
	Ort.	1.844E+02	9.010E+00	8.024E+02	6.952E+01	5.771E+02	3.000E+02
	Std.	1.646E+02	1.130E+01	1.972E+02	4.279E+01	1.718E+02	2.626E+01
F16	Eniyi	1.222E+02	2.160E+02	3.896E+02	1.646E+02	2.183E+02	1.671E+02
	Ort.	1.948E+02	3.221E+02	6.639E+02	2.114E+02	4.591E+02	2.635E+02
	Std.	6.580E+01	4.742E+01	1.208E+02	2.868E+01	1.870E+02	1.201E+02
F17	Eniyi	1.099E+02	2.660E+02	5.002E+02	2.135E+02	2.094E+02	1.763E+02
	Ort.	1.873E+02	4.057E+02	6.900E+02	2.726E+02	4.768E+02	2.933E+02
	Std.	6.640E+01	4.909E+01	1.010E+02	2.945E+01	1.079E+02	1.188E+02
F18	Eniyi	9.054E+02	8.002E+02	9.999E+02	8.858E+02	8.257E+02	9.049E+02
	Ort.	9.088E+02	9.139E+02	1.192E+03	9.084E+02	8.408E+02	9.099E+02
	Std.	1.927E+00	2.174E+01	7.621E+01	4.454E+00	4.592E+01	2.300E+00
F19	Eniyi	9.058E+02	8.002E+02	9.953E+02	9.066E+02	8.252E+02	9.053E+02
	Ort.	9.086E+02	9.085E+02	1.181E+03	9.091E+02	8.295E+02	9.099E+02
	Std.	1.779E+00	2.953E+01	8.459E+01	1.092E+00	3.450E+00	2.295E+00
F20	Eniyi	9.060E+02	4.037E+02	9.710E+02	9.065E+02	8.238E+02	9.047E+02
	Ort.	9.081E+02	8.924E+02	1.194E+03	9.093E+02	8.357E+02	9.099E+02
	Std.	1.627E+00	9.714E+01	9.034E+01	1.225E+00	3.126E+01	2.815E+00
F21	Eniyi	5.000E+02	5.000E+02	1.169E+03	5.000E+02	5.000E+02	5.000E+02
	Ort.	5.000E+02	5.000E+02	1.346E+03	5.000E+02	8.737E+02	5.000E+02
	Std.	2.313E-13	2.313E-13	7.248E+01	2.313E-13	9.199E+01	1.826E-06
F22	Eniyi	8.707E+02	9.540E+02	1.124E+03	9.046E+02	5.101E+02	8.588E+02
	Ort.	9.222E+02	1.062E+03	1.432E+03	9.421E+02	5.332E+02	8.894E+02
	Std.	2.742E+01	3.896E+01	9.213E+01	1.650E+01	1.985E+01	1.352E+01
F24	Eniyi	2.000E+02	2.007E+02	1.315E+03	2.000E+02	2.132E+02	2.000E+02
	Ort.	2.000E+02	8.118E+02	1.423E+03	2.034E+02	2.230E+02	2.000E+02
	Std.	0.000E+00	4.408E+02	3.858E+01	6.146E+00	2.482E+01	0.000E+00
F25	Eniyi	9.829E+02	1.274E+03	1.379E+03	9.875E+02	2.134E+02	2.000E+02
	Ort.	9.959E+02	1.330E+03	1.441E+03	9.967E+02	2.208E+02	2.245E+02
	Std.	7.025E+00	2.077E+01	2.920E+01	4.759E+00	5.544E+00	1.764E+01

Çizelge 4.9. 50 boyutlu karma CEC'05 fonksiyonları için 30 bağımsız çalışma üzerinden AAA, ABC, BA, DE, ACO_R ve HS_{POP} algoritmalarının ulaştıkları en iyi, ortalama ve standart sapma değerleri

		AAA	ABC	BA	DE	ACO _R	HS _{POP}
F15	Eniyi	7.032E+00	8.779E-11	4.261E+02	2.717E+01	4.000E+02	2.000E+02
	Ort.	3.086E+02	4.964E+00	9.253E+02	1.157E+02	7.732E+02	2.700E+02
	Std.	1.395E+02	8.595E+00	2.077E+02	6.206E+01	1.157E+02	7.022E+01
F16	Eniyi	1.756E+02	3.951E+02	6.637E+02	2.586E+02	2.837E+02	2.209E+02
	Ort.	3.362E+02	3.998E+02	8.267E+02	2.892E+02	5.189E+02	2.634E+02
	Std.	8.228E+01	8.871E-01	1.168E+02	1.708E+01	1.448E+02	5.230E+01
F17	Eniyi	1.442E+02	4.653E+02	7.278E+02	2.783E+02	3.275E+02	2.321E+02
	Ort.	2.735E+02	5.498E+02	9.639E+02	3.536E+02	5.683E+02	2.820E+02
	Std.	8.468E+01	2.650E+01	1.149E+02	2.360E+01	1.971E+02	4.906E+01
F18	Eniyi	9.213E+02	9.363E+02	1.159E+03	9.253E+02	8.419E+02	9.207E+02
	Ort.	9.306E+02	9.563E+02	1.305E+03	9.295E+02	8.464E+02	9.267E+02
	Std.	6.554E+00	1.058E+01	6.896E+01	2.910E+00	2.857E+00	7.408E+00
F19	Eniyi	9.193E+02	9.417E+02	1.132E+03	9.258E+02	8.407E+02	9.205E+02
	Ort.	9.287E+02	9.574E+02	1.287E+03	9.297E+02	8.621E+02	9.256E+02
	Std.	6.390E+00	7.776E+00	7.297E+01	2.530E+00	4.668E+01	3.555E+00
F20	Eniyi	9.189E+02	9.398E+02	1.088E+03	9.234E+02	8.428E+02	9.166E+02
	Ort.	9.278E+02	9.574E+02	1.264E+03	9.298E+02	8.602E+02	9.254E+02
	Std.	4.843E+00	1.110E+01	9.812E+01	3.026E+00	4.343E+01	3.819E+00
F21	Eniyi	5.000E+02	5.000E+02	1.195E+03	1.014E+03	7.237E+02	5.000E+02
	Ort.	5.687E+02	5.000E+02	1.392E+03	1.018E+03	7.291E+02	9.559E+02
	Std.	1.783E+02	1.734E-13	8.987E+01	1.842E+00	3.379E+00	1.546E+02
F22	Eniyi	9.241E+02	1.065E+03	1.419E+03	9.118E+02	5.032E+02	8.887E+02
	Ort.	9.816E+02	1.170E+03	1.550E+03	9.466E+02	5.303E+02	9.118E+02
	Std.	2.702E+01	3.140E+01	6.914E+01	1.511E+01	3.927E+01	1.471E+01
F24	Eniyi	2.000E+02	1.310E+03	1.443E+03	2.598E+02	2.290E+02	2.000E+02
	Ort.	8.150E+02	1.355E+03	1.546E+03	8.445E+02	2.869E+02	2.000E+02
	Std.	4.373E+02	2.423E+01	3.157E+01	2.485E+02	1.756E+02	1.095E-05
F25	Eniyi	1.259E+03	1.356E+03	1.461E+03	1.246E+03	2.338E+02	2.530E+02
	Ort.	1.278E+03	1.403E+03	1.533E+03	1.259E+03	3.884E+02	2.708E+02
	Std.	1.201E+01	1.839E+01	3.069E+01	6.973E+00	3.241E+02	1.308E+01



Şekil 4.3. Bazı karma CEC'05 fonksiyonları için AAA, ABC, DE, ACO_R ve HS_{POP} algoritmalarının yakınsama eğrileri

CEC'05 test fonksiyonları üzerinde yapılan test çalışmaları sonucunda AAA'nın çözüm kalitesini istatistiksel açıdan değerlendirmek için algoritmaların 30 bağımsız çalışma sonunda elde ettikleri global optimum değerleri kullanarak ikili kıyaslamalar yapılmıştır. İkili kıyaslamalar için Wilcoxon işaretli-sıralama testi kullanılmıştır (10, 30 ve 50 boyut için sırasıyla Çizelge 4.10, 4.11 ve 4.12). Bu testte T ve p-değerleri Matlab programı (R2010a sürümü) kullanılarak hesaplanmıştır. AAA tüm karşılaştırmalarda birinci algoritma olarak kullanılmıştır. Çizelge 4.10–4.12'de, '+' işareti null hipotezi yani H_0 'ın reddedildiğini ve AAA'nın %95 anlamlılık düzeyinde ($\alpha = 0.05$) probleme dayalı istatistiksel kıyaslama testlerinde daha üstün bir performans sergilediğini gösterir. '-' işareti null hipotezi yani H_0 'ın reddedildiğini ve AAA'nın diğer algoritmadan daha düşük bir performans sergilediğini gösterir. '=' problemin çözümünde iki algoritmanın başarısı arasında istatistiksel olarak anlamlı bir farkın olmadığını işaret eder. Çizelge 4.10–4.12'nin son satırları ikili karşılaştırmada üç istatistiksel anlam durumu ('+', '=' veya '-' ile işaretli) için toplam sayıları göstermektedir. Çizelge 4.10–4.12'den, AAA'nın %95 anlamlılık düzeyinde ($\alpha = 0.05$) kıyaslanan diğer algoritmalarından istatistiksel olarak daha iyi sonuçlar gerçekleştirdiği görülmektedir.

Çizelge 4.10. 10 boyutlu CEC'05 fonksiyonları için Wilcoxon işaretli-sıralama testinin sonuçları ($\alpha = 0.05$)

P	AAA – ABC			AAA – ACO _R			AAA – BA			AAA – DE			AAA – HS _{POP}		
	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W
F1	1.00E+00	0	=	1.95E-03	0	+	1.73E-06	0	+	1.00E+00	0	=	1.00E+00	0	=
F2	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F3	8.92E-05	42	+	8.19E-05	41	+	1.92E-06	1	+	1.73E-06	0	+	2.06E-01	171	=
F4	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F5	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F6	9.92E-01	232	=	7.19E-01	215	=	1.73E-06	0	+	6.16E-04	66	+	1.92E-06	1	+
F7	1.00E+00	0	=	1.73E-06	0	-	1.57E-02	115	+	1.73E-06	0	-	3.42E-02	12	-
F8	1.73E-06	0	+	6.98E-06	14	+	6.34E-06	13	+	1.73E-06	0	+	2.35E-06	3	+
F9	1.00E+00	0	=	1.72E-06	0	+	1.73E-06	0	+	1.00E+00	0	=	1.00E+00	0	=
F10	7.51E-05	40	+	9.71E-05	43	+	1.73E-06	0	+	4.39E-03	94	+	1.49E-05	22	+
F11	3.18E-06	6	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F12	8.61E-01	224	=	1.73E-06	0	+	1.73E-06	0	+	9.75E-01	231	=	2.22E-04	53	+
F13	6.98E-06	14	-	1.73E-06	0	+	1.73E-06	0	+	1.59E-03	79	-	9.71E-05	43	+
F14	8.97E-02	150	=	3.18E-06	6	+	3.18E-06	6	+	9.27E-03	106	+	1.80E-05	24	-
F15	1.08E-02	91	-	1.73E-06	0	+	1.73E-06	0	+	1.06E-01	154	=	1.34E-05	21	+
F16	3.88E-04	60	+	1.25E-04	46	+	1.73E-06	0	+	5.29E-04	64	+	1.11E-02	109	+
F17	6.34E-06	13	+	7.51E-05	40	+	1.73E-06	0	+	2.88E-06	5	+	2.58E-03	86	+
F18	7.97E-01	220	=	2.88E-06	5	+	1.73E-06	0	+	8.92E-05	42	+	4.73E-06	10	+
F19	1.65E-01	165	=	1.73E-06	0	+	1.73E-06	0	+	2.84E-05	29	+	1.36E-05	21	+
F20	4.28E-01	194	=	1.73E-06	0	+	1.73E-06	0	+	5.79E-05	37	+	3.18E-06	6	+
F21	1.19E-05	15	-	5.61E-06	0	+	1.73E-06	0	+	4.65E-01	197	=	2.42E-06	0	+
F22	1.20E-01	157	=	6.16E-04	66	+	1.73E-06	0	+	4.73E-06	10	+	2.86E-05	24	+
F24	1.00E+00	0	=	1.73E-06	0	+	1.73E-06	0	+	6.10E-05	0	+	1.25E-01	0	=
F25	9.75E-01	231	=	4.90E-04	63	-	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	-
+/-/-	9/12/3			19/1/4			24/0/0			17/5/2			17/4/3		

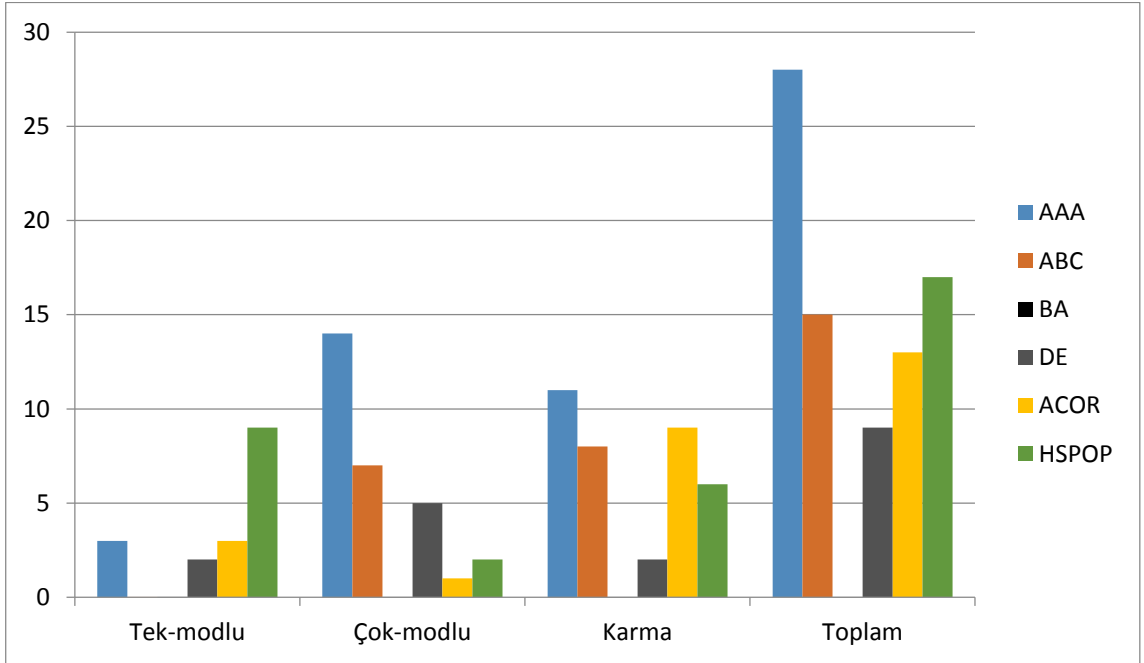
Çizelge 4.11. 30 boyutlu CEC'05 fonksiyonları için Wilcoxon işaretli-sıralama testinin sonuçları ($\alpha = 0.05$)

P	AAA – ABC			AAA – ACO _R			AAA – BA			AAA – DE			AAA – HS _{POP}		
	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W
F1	3.24E-07	0	+	1.04E-05	0	+	1.73E-06	0	+	1.00E+00	0	=	6.80E-08	0	-
F2	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F3	2.13E-06	2	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	3.71E-01	189	=
F4	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	1.13E-05	19	+	1.73E-06	0	-
F5	1.73E-06	0	+	1.11E-01	155	=	1.73E-06	0	+	8.92E-05	42	+	1.92E-06	1	-
F6	4.65E-01	197	=	4.78E-01	198	=	1.73E-06	0	+	3.06E-04	57	+	2.13E-06	2	+
F7	1.00E+00	0	=	1.72E-06	0	-	1.15E-04	45	+	1.73E-06	0	-	1.00E+00	0	=
F8	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F9	3.17E-03	28	-	1.73E-06	0	+	1.73E-06	0	+	1.25E-01	0	=	2.43E-02	105	+
F10	1.73E-06	0	+	2.13E-06	2	+	1.73E-06	0	+	1.31E-01	159	=	2.06E-01	171	=
F11	2.60E-06	4	+	1.73E-06	0	+	1.92E-06	1	+	1.73E-06	0	+	1.73E-06	0	+
F12	1.66E-02	116	+	1.73E-06	0	+	1.73E-06	0	+	6.98E-06	14	+	1.73E-06	0	+
F13	5.22E-06	11	-	1.73E-06	0	+	1.73E-06	0	+	8.19E-05	41	+	1.73E-06	0	+
F14	4.28E-02	134	+	1.73E-06	0	+	1.92E-06	1	+	9.78E-02	152	=	2.13E-06	2	+
F15	3.41E-05	31	-	1.73E-06	0	+	1.73E-06	0	+	4.68E-03	95	-	1.30E-03	50	+
F16	3.18E-06	6	+	1.73E-06	0	+	1.73E-06	0	+	2.43E-02	123	+	8.22E-03	104	+
F17	1.92E-06	1	+	2.13E-06	2	+	1.73E-06	0	+	2.84E-05	29	+	3.88E-04	60	+
F18	3.11E-05	30	+	3.11E-05	30	-	1.73E-06	0	+	7.81E-01	219	=	5.71E-02	140	=
F19	4.20E-04	61	-	1.73E-06	0	-	1.73E-06	0	+	1.53E-01	163	=	1.48E-02	114	+
F20	1.48E-02	114	-	3.11E-05	30	-	1.73E-06	0	+	1.48E-03	78	+	8.22E-03	104	+
F21	1.00E+00	0	=	2.56E-06	0	+	1.73E-06	0	+	1.00E+00	0	=	1.00E+00	0	=
F22	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	7.73E-03	103	+	2.16E-05	26	-
F24	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	8.86E-05	0	+	1.00E+00	0	=
F25	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	5.72E-01	205	=	1.73E-06	0	-
+/-/-	16/3/5			14/2/8			24/0/0			14/8/2			13/6/5		

Çizelge 4.12. 50 boyutlu CEC'05 fonksiyonları için Wilcoxon işaretli-sıralama testinin sonuçları ($\alpha = 0.05$)


P	AAA – ABC			AAA – ACO _R			AAA – BA			AAA – DE			AAA – HS _{POP}		
	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W	p-değeri	T	W
F1	1.40E-06	0	+	8.01E-06	16.5	+	1.73E-06	0	+	2.44E-04	0	-	2.48E-05	30	+
F2	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	2.07E-02	120	-
F3	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.02E-01	153	=
F4	1.73E-06	0	+	2.60E-06	4	+	1.73E-06	0	+	4.73E-06	10	+	1.73E-06	0	-
F5	1.73E-06	0	+	4.05E-01	192	=	1.92E-06	1	+	1.60E-04	49	+	1.73E-06	0	-
F6	2.85E-02	126	-	1.16E-01	156	=	1.73E-06	0	+	4.11E-03	93	+	2.60E-06	4	+
F7	1.00E+00	0	=	1.68E-06	0	-	6.34E-06	13	+	1.73E-06	0	-	1.00E+00	0	=
F8	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F9	1.02E-01	153	=	1.73E-06	0	+	1.73E-06	0	+	5.02E-05	0	-	1.92E-06	1	+
F10	1.73E-06	0	+	2.84E-05	29	+	1.73E-06	0	+	5.32E-03	97	+	1.66E-02	116	-
F11	3.88E-06	8	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F12	3.41E-05	31	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F13	1.73E-06	0	-	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F14	2.70E-02	125	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+	1.73E-06	0	+
F15	1.92E-06	1	-	2.56E-06	0	+	1.73E-06	0	+	1.97E-05	25	-	1.60E-01	121	=
F16	9.88E-05	10	+	1.49E-05	22	+	1.73E-06	0	+	2.96E-03	88	-	2.58E-03	86	-
F17	1.73E-06	0	+	6.34E-06	13	+	1.73E-06	0	+	2.22E-04	53	+	5.86E-01	206	=
F18	1.92E-06	1	+	1.73E-06	0	-	1.73E-06	0	+	5.86E-01	206	=	1.32E-02	112	-
F19	1.73E-06	0	+	3.72E-05	32	-	1.73E-06	0	+	3.82E-01	190	=	6.87E-02	144	=
F20	1.73E-06	0	+	3.72E-05	32	-	1.73E-06	0	+	8.59E-02	149	=	5.98E-02	141	=
F21	1.25E-01	0	=	1.48E-02	114	+	1.73E-06	0	+	1.92E-06	1	+	1.70E-05	10	+
F22	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	4.45E-05	34	-	1.73E-06	0	-
F24	1.73E-06	0	+	6.64E-04	67	-	1.73E-06	0	+	9.59E-01	230	=	5.96E-05	0	-
F25	1.73E-06	0	+	1.73E-06	0	-	1.73E-06	0	+	2.13E-06	2	-	1.73E-06	0	-
+/-/-	18/3/3			15/2/7			24/0/0			13/4/7			9/6/9		

CEC'05 test fonksiyon seti üzerinde yapılan testler, 24 test fonksiyonunda ve her bir fonksiyon için 3 farklı boyutta (10, 30 ve 50) gerçekleştirilmiştir. Toplamda 72 adet kıyaslama sonucu elde edilmiştir. Fonksiyon gruplarına göre algoritmaların başarı oranları Şekil 4.4'de gösterilmiştir. Şekil 4.4'de fonksiyon gruplarının (tek-modlu, çok-modlu ve karma) algoritmaların diğerlerinden daha başarılı olduğu fonksiyon sayıları gösterilmiştir. Bir fonksiyon için birden fazla algoritma aynı başarılı sonucu verdiği durumlarda, histogramda başarılı olan her algoritmanın başarılı olduğu fonksiyon sayısına ayrı ayrı eklenmiştir. Bu nedenle Şekil 4.4'deki toplam değer 72 yerine 82 olmuştur. AAA diğer algoritmalar ile karşılaştırıldığında daha başarılı sonuçlar ürettiği Şekil 4.4 ve 4.5'de görülmüştür.



Şekil 4.4. CEC'05 fonksiyon setinde gruplarına göre algoritmaların başarılı olduğu fonksiyon sayıları

Fonksiyon boyutları açısından algoritmaların başarı oranları Şekil 4.5'de kıyaslanmıştır. AAA'nın farklı boyutlu fonksiyonlarda başarılı ve dengeli sonuçlar verdiği görülmektedir. Bu sonuçlar, AAA'nın dengeli arama yeteneklerine sahip tutarlı bir algoritma olduğunu göstermektedir. Bunun birinci sebebi globale yaklaşmak için adaptasyon ve evrim süreçlerinin katkısı, ikinci sebebi ise yerel minimumlardan kaçınmak için ışık kaynağının seçilmesindeki yarı rastgele seçim ve helisel hareket yöntemlerinin birbirlerini dengelemeleridir.



Şekil 4.5. CEC'05 fonksiyon setinde boyutlarına göre algoritmaların başarılı olduğu fonksiyon sayıları

CEC'05 test fonksiyonları üzerinde yapılan çalışmada kullanılan farklı boyutlardaki 72 adet test fonksiyonunda global optimum sıfır (0)'dır ve amaç bu değerlere ulaşmaktır. Her bir algoritmanın durdurma kriterine ulaşınca kadar elde ettiği optimum değer ise hesaplanan global optimum değeridir ve bu değerler Çizelge 4.1–4.9'da gösterilmiştir.

Bu bölümde AAA ve diğer algoritmaların hesaplama hataları ve kıyaslamaları diğer bir genel performans değerlendirmesi ve kıyaslama yaklaşımı olarak gerçekleştirilmiştir.

Hesaplanan hata değerleri Çizelge 4.13'de verilmiştir. Genel hata değerlerindeki AAA'nın başarısı Şekil 4.4 ve 4.5'de verilen histogram sonuçlarını desteklemektedir. Bu yöntemler ile en düşük hata değeri AAA tarafından elde edilmiştir. HS_{POP} ise bu değerlendirmelere göre en başarılı ikinci algoritmadır.

Çizelge 4.13. Algoritmaların CEC'05 seti tüm fonksiyon ve boyutları için genel hata değerleri

Algoritma	MSE	RMSE	MAPE
AAA	4.522E+11	6.724E+05	1.157E+05
ABC	3.668E+12	1.915E+06	3.191E+05
BA	5.346E+19	7.312E+09	1.139E+09
DE	1.539E+14	1.240E+07	1.827E+06
ACO _R	5.226E+16	2.286E+08	3.116E+07
HS _{POP}	4.939E+11	7.028E+05	1.508E+05

4.1.2. CEC'13 test fonksiyonlarında AAA ve AAA_{ML}'nin performans değerlendirmesi

AAA'nın CEC'05 test seti üzerinde gösterdiği başarının tutarlılığını ve yeni değiştirilmiş ve geliştirilmiş sürümü AAA_{ML}'nin başarısını kanıtlamak için farklı bir test fonksiyon seti olan CEC'13 üzerinde çalışmalar yapılmıştır. Bu set 28 adet test fonksiyonunu içerir ve tüm fonksiyonlar minimizasyon problemidir.

Testler CEC'13 teknik raporunda belirtilen şartlar ve verilen parametrelere uygun olarak yapılmıştır. Her bir test fonksiyonu üç farklı boyutta (10, 30 ve 50) ve 51 kez çalıştırılmıştır. Maksimum uygunluk fonksiyonu hesaplama sayısı olarak $10.000 \times \text{boyut}$ (10 boyut için 100,000, 30 boyut için 300,000 ve 50 boyut için 500,000) ayarlanmıştır. Her bir fonksiyon için 51 kez yapılan çalıştırma için bulunan en uygun değerlere ilaveten her bir çalıştırma esnasında belirli adımlarda (0.01, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0) bilinen en uygun değerler ile algoritmanın bulmuş olduğu en uygun değer arasındaki farklar (hatalar) kayıt altına alınmıştır. Bulunan hata değerleri 10^{-8} den küçük olduğunda 0 (sıfır) olarak değerlendirilmiştir.

AAA ve AAA_{ML}'nin etkinliğini ve verimliliğini doğrulamak için, test sonuçları modern hibrit ve geliştirilmiş algoritmalarından SPSOABC, CDASA ve AMopGA ile kıyaslanmıştır.

SPSOABC yönteminde El-Abd (2013) çalışmasında önerdiği gibi sürü (popülasyon) sayısı olarak 40 belirlenmiştir ve w , c_1 , c_2 parametreleri sırasıyla 1.193, 1.193, 0.721 olarak ayarlanmıştır.

CDASA yöntemi beş parametre içerir. Bu parametreler, popülasyondaki karınca sayısı (m), feromon dağılma faktörü (p), küresel ölçekte artan faktör ($s+$), küresel ölçekte azalan faktör ($s-$) ve sıfırlama eşiği (α) dir. Bu metotta m , $s+$, $s-$, p ve α parametreleri için sırasıyla 27, 0.3865, 0.0178, 0.6878 ve 10^{-15} ayarlanmıştır (Korosec ve Silc, 2013).

AMopGA yönteminde popülasyon boyutu 10 olarak ayarlanmıştır. Diğer parametreler P_m , G_p ve P_i ise algoritmanın çalışması esnasında dinamik olarak ayarlanmıştır (Lim ve Ark., 2015).

AAA ve AAA_{ML} için parametre ayarları CEC'05 seti üzerinde yapılan çalışmalarda kullanılan enerji kaybı, $e = 0.3$; kesme kuvveti, $\Delta = 2$ ve adaptasyon katsayısı, $A_p = 0.5$ olarak kullanılmıştır. Tüm testler ve istatistiksel analizler Matlab programı (R2010a sürümü) kullanılarak yapılmıştır. CEC'13 test fonksiyonları ile

yapılan deneysel çalışmaların tamamında bilgisayar platformu olarak, Intel(R) Core(TM) i7 3.60GHZ işlemci, 16GB ram ve Microsoft Windows 8 işletim sistemi kullanılmıştır.

CEC'13 test fonksiyonları için, AMopGA, SPSOABC, CDASA, AAA ve AAA_{ML} algoritmalarının test sonuçları Çizelge 4.14–4.16'da gösterilmiştir. Bu çizelgelerde metotların her bir fonksiyon için buldukları en düşük hata değerlerinin 51 farklı çalışma için ortalama değerleri ve standart sapmaları gösterilmiştir. Bulunan en düşük ortalama hata değerleri koyu renklerle gösterilmiştir. Şekil 4.6–4.11'de algoritmaların 51 bağımsız çalıştırmada buldukları değerlerin ortalamaları kullanılarak optimum değere yakınsama eğrileri ve bu çalışmalarda buldukları optimum değerlerin dağılımlarının kutu ve bıyık diyagramları gösterilmiştir. Çizelge 4.14 test fonksiyonlarının 10 boyut için çalıştırıldığında elde edilen en düşük ortalama hata ve standart sapmalarını göstermektedir.

Çizelge 4.14. 10 Boyutlu CEC'13 fonksiyonları için 51 bağımsız çalışma üzerinden AMopGA, SPSOABC, CDASA, AAA ve AAA_{ML} algoritmalarının ulaştıkları en düşük hataların ortalama ve standart sapma değerleri

F	AMopGA	SPSOABC	CDASA	AAA	AAA _{ML}
1	3.140E-06±5.370E-06	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00
2	0.000E+00 ±0.000E+00	1.486E+05±1.646E+05	2.055E+06±1.306E+07	3.638E+05±3.323E+05	1.881E+05±1.366E+05
3	0.000E+00 ±0.000E+00	1.276E+05±6.223E+05	1.977E+11±1.401E+12	4.083E+04±8.881E+04	4.517E+05±2.126E+06
4	6.767E-04 ±7.804E-04	2.395E+03±1.534E+03	1.319E+03±9.366E+03	5.039E+03±2.825E+03	2.086E+03±1.542E+03
5	1.082E-04±1.076E-04	0.000E+00 ±0.000E+00	7.524E-06±6.870E-06	0.000E+00 ±3.087E-14	0.000E+00 ±0.000E+00
6	6.705E+00±1.327E+00	4.864E+00 ±4.765E+00	5.047E+00±5.655E+00	6.455E+00±4.404E+00	9.812E+00±5.960E-06
7	0.000E+00 ±0.000E+00	4.874E-01±8.218E-01	1.150E+02±3.461E+02	8.351E+00±9.396E+00	4.052E-02±8.554E-02
8	1.451E+01 ±9.014E+00	2.032E+01±8.856E-02	2.032E+01±1.168E-01	2.032E+01±8.370E-02	2.035E+01±7.339E-02
9	8.356E-02 ±3.434E-01	3.794E+00±9.617E-01	5.051E+00±2.391E+00	2.936E+00±1.295E+00	1.914E+00±1.306E+00
10	5.588E-01±4.628E-01	4.408E-02 ±2.113E-02	2.660E-01±1.390E-01	3.293E-01±1.834E-01	1.367E-01±1.241E-01
11	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	4.682E-01±7.539E-01	5.853E-02±2.364E-01	1.951E-02±1.393E-01
12	2.308E+01±2.134E+01	6.289E+00 ±2.436E+00	2.189E+01±7.456E+00	1.563E+01±7.475E+00	7.795E+00±3.439E+00
13	6.602E+00±7.437E+00	6.357E+00 ±3.028E+00	3.453E+01±1.218E+01	2.029E+01±7.647E+00	1.081E+01±6.741E+00
14	6.952E+01±7.891E+01	4.349E-01 ±8.173E-01	2.051E+02±1.482E+02	1.806E+00±4.204E+00	2.457E+00±5.729E+00
15	1.171E+03±3.607E+02	4.956E+02 ±1.365E+02	1.080E+03±3.805E+02	8.004E+02±2.464E+02	7.464E+02±2.787E+02
16	8.476E-01±4.660E-01	4.972E-01±1.250E-01	2.619E-01 ±2.175E-01	2.654E-01±1.186E-01	1.045E+00±2.787E-01
17	1.333E+01±2.835E+00	9.600E+00 ±1.957E+00	1.041E+01±3.255E+00	1.029E+01±2.272E-01	1.193E+01±1.708E+00
18	8.429E+01±2.460E+01	1.691E+01 ±1.948E+00	3.048E+01±1.078E+01	2.534E+01±5.339E+00	3.232E+01±5.827E+00
19	8.140E+00±3.490E+00	2.887E-01 ±5.207E-02	6.289E-01±2.420E-01	3.047E-01±2.056E-01	7.273E-01±3.288E-01
20	2.503E+00±1.859E+00	2.386E+00 ±4.821E-01	4.023E+00±7.619E-01	2.840E+00±4.230E-01	2.585E+00±5.259E-01
21	3.064E+02 ±2.180E-05	3.963E+02±2.803E+01	3.433E+02±9.653E+01	3.119E+02±1.014E+02	4.002E+02±5.167E-13
22	2.148E+02±7.472E+01	1.322E+01 ±5.476E+00	2.650E+02±1.689E+02	1.083E+02±6.345E+01	1.192E+02±5.256E+01
23	2.208E+02 ±8.012E+01	5.967E+02±1.811E+02	1.466E+03±4.770E+02	9.386E+02±2.695E+02	5.862E+02±2.766E+02
24	1.372E+02 ±1.776E+01	2.006E+02±2.331E+01	2.111E+02±4.533E+01	1.888E+02±3.790E+01	2.058E+02±1.498E+01
25	1.903E+02 ±1.830E+01	2.001E+02±2.158E+01	2.207E+02±2.818E+01	2.086E+02±1.129E+01	2.059E+02±1.248E+01
26	2.392E+02±7.972E+01	1.343E+02±3.989E+01	2.148E+02±8.928E+01	1.248E+02 ±2.094E+01	1.749E+02±4.134E+01
27	4.936E+02±7.679E+01	3.506E+02±7.132E+01	5.753E+02±1.736E+02	3.504E+02 ±6.088E+01	4.437E+02±8.400E+01
28	3.497E+02±7.680E-08	2.949E+02±7.012E+01	3.195E+02±8.047E+01	2.569E+02 ±8.308E+01	3.000E+02±0.000E+00

Çizelge 4.14’de görüldüğü gibi, AMopGA, F2, F3, F4, F7, F8, F9, F11, F21, F23, F24, F25 fonksiyonlarında, SPSOABC, F1, F5, F6, F10, F11, F12, F13, F14, F15, F17, F18, F19, F20, F22 fonksiyonlarında, CDASA, F1 ve F16 fonksiyonlarında, AAA, F1, F5, F26, F27, F28 fonksiyonlarında ve AAA_{ML} ise F1 ve F5 fonksiyonlarında en iyi ortalama hataya ulaşmaktadır. Tek modlu fonksiyonlarda, AAA, AAA_{ML} ve SPSOABC ayrışabilir fonksiyonlarda (F1 ve F5) en düşük ortalama hatalara ulaşırken, AMopGA ise ayrışamayan fonksiyonlarda (F2, F3 ve F4) en düşük ortalama hatalara ulaşmaktadır. F3 fonksiyonu hariç diğer tek-modlu fonksiyonlarda AAA_{ML}, AAA’ya eşit veya daha iyi sonuçlara ulaşmaktadır. Çok modlu fonksiyonlarda test sonuçları SPSOABC’nin

diğer algoritmalarından daha başarılı sonuçlar verdiği görülmektedir. Ancak AAA ve AAA_{ML} 15 çok-modlu fonksiyonun 11 tanesinde (F7, F8, F9, F10, F12, F14, F15, F16, F17, F18 ve F19) en iyi ikinci ortalama değerlere ulaşmaktadır. AAA ve AAA_{ML} çok-modlu fonksiyonlarda genel olarak birbirlerine yakın sonuçlar üretse de AAA_{ML} nispeten daha iyi sonuçlar vermektedir. Karma fonksiyonlarda, AMopGA ve AAA diğer algoritmalarından daha başarılı sonuçlar sağlamaktadırlar. AMopGA F21, F23, F24 ve F25 fonksiyonlarında, AAA F26, F27 ve F28 fonksiyonlarında, SPSOABC ise F22 fonksiyonunda en iyi sonuçları vermektedir. Bunun yanı sıra AAA, F21, F22, F23 ve F24 fonksiyonlarında en iyi ikinci sonuçlara ulaşmaktadır. 10 boyutlu fonksiyonlarda genel ortalama performansa bakıldığında SPSOABC diğer algoritmalarından daha başarılı olduğu görülmektedir.

Belirli problem gruplarında yüksek performans sağlamak algoritmanın karakteristiğine göre farklılıklar gösterebilmektedir. Problemlerin parametre sayıları, yerel minimum sayıları veya ayrışabilir olmaları gibi özellikleri algoritmaların performanslarını etkilediği gibi, algoritmaların karakteristikleri de başarıyı etkilemektedir. Örneğin yeni bir çözüm üretirken güncellenen parametre sayısı, güncelleme esnasında komşu veya ebeveyn seçimi, yeni bulunan aday çözüm ile eski çözüm arasındaki seçim mekanizmaları veya çeşitliliği ve sömürüyü arttırmak için kullanılan çeşitli operatörler farklı problem grupları için başarıyı etkileyen faktörlerdir. Fakat burada önemli olan algoritmanın mekanizmaları ile dengeli bir arama stratejisi oluşturmaktır. Bu dengeli arama stratejisi algoritmanın farklı problem grupları için kabul edilebilir kaliteli sonuçlar vermesini sağlar.

AAA ve AAA_{ML} de her bir yeni çözüm için alg kolonileri helisel hareket ile 3 farklı boyutta değişime uğrar. Problemin parametre sayısı azaldıkça üç boyutta işlem yapan helisel hareket tek boyutta işlem yapan metotlara göre global optimuma yakınsama hızı fazladır fakat yerel minimumlara takılma riski de aynı oranda fazladır. Özellikle birçok yerel minimuma sahip çok-modlu fonksiyonlardaki sonuçlar bu durumu açıkça göstermektedir. Problemin parametre sayısı arttıkça helisel hareketin üç boyutta işlem yapma özelliği algoritmanın başarısını arttırmaktadır (Çizelge 4.15 ve 4.16).

Çizelge 4.15. 30 Boyutlu CEC'13 fonksiyonları için 51 bağımsız çalışma üzerinden AMopGA, SPSOABC, CDASA, AAA ve AAA_{ML} algoritmalarının ulaştıkları en düşük hataların ortalama ve standart sapma değerleri

F	AMopGA	SPSOABC	CDASA	AAA	AAA _{ML}
1	5.076E-03±3.252E-03	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00
2	0.000E+00 ±0.000E+00	8.780E+05±1.685E+06	9.521E+05±4.434E+05	2.815E+06±1.271E+06	2.077E+06±1.135E+06
3	0.000E+00 ±0.000E+00	5.159E+07±8.004E+07	4.541E+07±6.433E+07	6.157E+07±9.828E+07	1.836E+07±1.786E+07
4	1.729E-01 ±1.602E-01	6.017E+03±2.304E+03	1.827E-01±5.538E-01	3.230E+04±7.615E+03	9.336E+03±2.866E+03
5	1.557E-02±6.597E-03	0.000E+00 ±0.000E+00	8.192E-06±3.230E-06	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00
6	2.901E+01±7.308E+00	1.090E+01 ±1.089E+01	3.538E+01±2.689E+01	1.825E+01±5.414E+00	1.575E+01±3.559E+00
7	6.836E+00 ±1.042E+01	5.115E+01±2.044E+01	6.945E+01±3.077E+01	8.129E+01±1.726E+01	2.262E+01±9.205E+00
8	2.001E+01 ±1.629E-02	2.092E+01±4.922E-02	2.090E+01±8.619E-02	2.092E+01±6.758E-02	2.095E+01±5.264E-02
9	4.004E+00 ±2.113E+00	2.950E+01±2.618E+00	2.345E+01±4.232E+00	2.107E+01±2.809E+00	1.368E+01±2.687E+00
10	9.023E-02±3.598E-02	1.322E-01±6.230E-02	3.546E-02 ±1.991E-02	2.160E-01±1.034E-01	2.425E-01±7.766E-02
11	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	1.171E+00±1.206E+00	0.000E+00 ±0.000E+00	2.536E-01±4.379E-01
12	1.576E+02±3.130E+01	6.441E+01±1.480E+01	1.174E+02±3.216E+01	1.279E+02±3.515E+01	3.968E+01 ±1.166E+01
13	5.282E+01 ±3.241E+01	1.147E+02±2.243E+01	1.857E+02±3.747E+01	1.599E+02±3.598E+01	8.130E+01±2.702E+01
14	3.916E+02±1.400E+02	1.551E+01 ±6.126E+00	6.638E+02±2.873E+02	4.974E+01±5.569E+01	1.473E+02±8.499E+01
15	4.834E+03±6.491E+02	3.550E+03±3.044E+02	3.875E+03±6.736E+02	3.622E+03±4.723E+02	3.161E+03 ±7.267E+02
16	1.510E+00±4.153E-01	1.028E+00±2.015E-01	3.257E-01 ±1.384E-01	5.374E-01±2.608E-01	1.532E+00±8.844E-01
17	8.566E+01±1.262E+01	3.091E+01±1.233E-01	3.397E+01±4.574E+00	3.081E+01 ±3.690E-01	4.141E+01±7.065E+00
18	5.765E+02±1.302E+02	9.006E+01±8.953E+00	1.960E+02±5.267E+01	1.324E+02±2.719E+01	5.963E+01 ±1.086E+01
19	6.648E+01±1.819E+01	1.709E+00±4.677E-01	2.104E+00±5.265E-01	1.310E+00 ±5.567E-01	1.517E+00±3.003E-01
20	1.289E+01±6.412E-01	1.106E+01±7.605E-01	1.476E+01±6.250E-01	1.221E+01±1.085E+00	1.076E+01 ±1.735E+00
21	3.168E+02±5.171E-04	3.185E+02±7.527E+01	2.768E+02 ±7.289E+01	2.948E+02±8.657E+01	3.089E+02±9.747E+01
22	5.594E+02±1.543E+02	8.412E+01 ±3.899E+01	4.892E+02±2.089E+02	1.793E+02±1.118E+02	2.054E+02±8.142E+01
23	5.953E+02 ±1.717E+02	4.184E+03±5.618E+02	5.409E+03±8.709E+02	4.283E+03±6.827E+02	3.230E+03±6.697E+02
24	3.266E+02±3.148E+01	2.509E+02±1.434E+01	2.982E+02±4.095E+01	2.657E+02±8.023E+00	2.410E+02 ±9.385E+00
25	3.001E+02±1.019E+01	2.752E+02±9.763E+00	3.153E+02±6.630E+00	2.789E+02±8.132E+00	2.558E+02 ±7.653E+00
26	2.853E+02±2.677E+01	2.600E+02±7.621E+01	2.906E+02±1.090E+02	2.002E+02±6.490E-02	2.001E+02 ±4.753E-02
27	1.242E+03±1.702E+02	9.103E+02±1.624E+02	1.084E+03±2.874E+02	9.094E+02±8.978E+01	6.880E+02 ±8.881E+01
28	3.499E+02±1.549E-04	3.332E+02±2.323E+02	3.870E+02±3.171E+02	2.961E+02 ±2.801E+01	3.000E+02±0.000E+00

Çizelge 4.15, 30 boyutlu problemler için kıyaslanan algoritmaların ulaştıkları en düşük hata değerlerinin ortalama ve standart sapmalarını göstermektedir. AAA_{ML} 30 boyutlu problemlerde global en iyi değerlere yakın sonuçlara ulaşma açısından diğer algoritmalarından daha iyi performans göstermektedir. AAA_{ML} F1, F5, F12, F15, F18, F20, F24, F25, F26 ve F27 fonksiyonlarında en iyi ortalama değerlere ulaşmaktadır. AAA ise 10 boyutlu fonksiyonlara göre 30 boyutlu fonksiyonlarda başarısını arttırmıştır.

30 boyutlu tek-modlu fonksiyonlardaki test sonuçları 10 boyutlu fonksiyonlar üzerindeki test sonuçları ile benzerdir. 30 boyutlu çok-modlu fonksiyonlarda, AAA_{ML}

F12, F15, F18 ve F20 de en iyi sonuçları vermektedir. İlaveten F6, F7, F9, F11, F13 ve F19 da ise en iyi ikinci performansı göstermektedir. AAA ise 30 boyutlu fonksiyonlarda hem en iyi olduğu fonksiyon sayısını arttırmakta hem de en iyi olmadığı durumlarda AAA_{ML} ye yakın değerler bulmaktadır. Sonuçlar göstermektedir ki, AAA ve AAA_{ML} 30 boyutlu fonksiyonlarda performanslarını arttırmaktadırlar. AAA_{ML}'nin 30 boyutlu fonksiyonlardaki başarısı AAA'ya kıyasla daha dikkat çekicidir.

30 boyutta, AAA ve AAA_{ML}'nin çok-modlu fonksiyonlarda olduğu gibi karma fonksiyonlarda da daha iyi sonuçlar verdikleri görülmektedir. AMopGA ise 10 boyutlu karma fonksiyonlarda gösterdiği başarıyı devam ettirememektedir. F24, F25, F26 ve F27 fonksiyonlarında AAA_{ML} kıyaslanan diğer metotlar arasında en yüksek başarıyı gösterirken F23 ve F28'de en iyi ikinci performansa sahip olmuştur. F21 fonksiyonunda CDASA en iyi, AAA ise en iyi ikinci sonuca ulaşmaktadır. F22 fonksiyonu için en iyi performansı sağlayan algoritma SPSOABC'dir ve AAA onu takip etmektedir. F28 fonksiyonunda ise en iyi performansa AAA ulaşmaktadır ve AAA_{ML} en iyi ikinci performansa ulaşan algoritmadır. Özetle 30 boyutlu 8 adet karma fonksiyonun 5 tanesinde (F24, F25, F26, F27 ve F28) AAA ve AAA_{ML} en iyi performansı göstermiştir. Diğer 3 fonksiyonda (F21, F22 ve F23) ise en iyi ikinci performansı göstermişlerdir.

Çizelge 4.16. 50 Boyutlu CEC'13 fonksiyonları için 51 bağımsız çalışma üzerinden AMopGA, SPSOABC, CDASA, AAA ve AAA_{ML} algoritmalarının ulaştıkları ortalama ve standart sapma değerleri


F	AMopGA	SPSOABC	CDASA	AAA	AAA _{ML}
1	2.024E-01±1.132E-01	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00
2	1.210E-07 ±1.240E-07	4.951E+05±1.476E+05	1.929E+06±6.667E+05	4.133E+06±1.352E+06	2.565E+06±9.138E+05
3	0.000E+00 ±0.000E+00	1.213E+08±1.179E+08	2.181E+08±2.073E+08	3.762E+08±5.480E+08	8.025E+07±7.621E+07
4	1.635E+00±8.841E-01	4.875E+03±1.204E+03	1.578E-02 ±3.990E-02	4.850E+04±1.144E+04	2.413E+04±6.103E+03
5	2.048E-01±8.801E-02	0.000E+00 ±0.000E+00	8.399E-06±2.102E-06	0.000E+00 ±0.000E+00	0.000E+00 ±0.000E+00
6	4.841E+01±7.302E-01	4.051E+01 ±2.283E+01	4.802E+01±1.500E+01	4.388E+01±9.367E-01	4.357E+01±8.012E-01
7	4.631E+00 ±4.481E+00	7.338E+01±1.166E+01	1.043E+02±1.747E+01	1.147E+02±1.704E+01	6.057E+01±1.249E+01
8	1.962E+01 ±2.802E+00	2.111E+01±3.420E-02	2.110E+01±7.172E-02	2.112E+01±5.892E-02	2.112E+01±4.380E-02
9	6.386E+00 ±3.286E+00	5.841E+01±3.920E+00	4.666E+01±4.858E+00	4.710E+01±4.738E+00	3.087E+01±3.397E+00
10	4.388E-01±1.132E-01	1.555E-01±8.097E-02	4.657E-02 ±2.748E-02	2.459E-01±1.127E-01	3.443E-01±1.423E-01
11	0.000E+00 ±0.000E+00	6.646E-02±2.390E-01	2.146E+00±1.633E+00	5.853E-02±2.364E-01	2.401E+00±1.975E+00
12	2.595E+02±4.529E+01	1.727E+02±3.231E+01	2.669E+02±6.120E+01	3.120E+02±6.456E+01	1.139E+02 ±2.521E+01
13	9.068E+01 ±5.116E+01	2.865E+02±3.937E+01	4.113E+02±5.148E+01	4.070E+02±5.593E+01	2.138E+02±4.117E+01
14	7.192E+02±1.770E+02	2.637E+01 ±8.031E+00	1.078E+03±3.775E+02	5.520E+01±3.166E+01	2.120E+02±9.611E+01
15	9.859E+03±1.008E+03	7.424E+03±5.463E+02	7.332E+03±8.162E+02	6.990E+03±8.258E+02	6.268E+03 ±1.124E+03
16	2.505E+00±6.703E-01	1.368E+00±1.875E-01	4.973E-01±1.496E-01	8.554E-01±2.555E-01	1.574E-01 ±8.360E-02
17	1.555E+02±1.929E+01	5.196E+01±2.405E-01	5.816E+01±7.435E+00	5.146E+01 ±5.350E-01	5.480E+01±3.328E+00
18	1.245E+03±2.176E+02	2.163E+02±2.629E+01	4.426E+02±1.020E+02	3.082E+02±6.411E+01	1.273E+02 ±1.944E+01
19	1.352E+02±3.764E+01	5.186E+00±1.413E+00	3.692E+00±7.126E-01	2.499E+00 ±8.509E-01	2.591E+00±3.918E-01
20	1.997E+01±1.322E+00	1.982E+01±6.784E-01	2.429E+01±9.979E-01	2.224E+01±1.306E+00	1.978E+01 ±1.176E+00
21	3.072E+02 ±6.079E-03	8.961E+02±2.901E+02	6.864E+02±3.825E+02	4.980E+02±3.896E+02	6.309E+02±4.364E+02
22	9.081E+02±2.282E+02	5.109E+01 ±1.395E+01	7.319E+02±2.821E+02	1.003E+02±7.232E+01	3.626E+02±1.197E+02
23	9.010E+02 ±2.023E+02	9.044E+03±7.813E+02	1.014E+04±1.324E+03	8.579E+03±1.138E+03	6.946E+03±1.224E+03
24	5.060E+02±4.276E+01	3.082E+02±2.133E+01	3.739E+02±6.651E+01	3.362E+02±1.301E+01	2.843E+02 ±1.184E+01
25	3.788E+02±1.142E+01	3.650E+02±1.864E+01	4.036E+02±6.230E+00	3.629E+02±1.329E+01	3.195E+02 ±1.278E+01
26	3.237E+02±5.095E+01	3.969E+02±9.873E+01	3.436E+02±1.092E+02	2.004E+02±1.449E-01	2.003E+02 ±1.200E-01
27	2.277E+03±2.966E+02	1.630E+03±1.995E+02	1.599E+03±3.107E+02	1.600E+03±1.202E+02	1.137E+03 ±1.156E+02
28	3.496E+02 ±5.060E-03	8.520E+02±1.146E+03	1.035E+03±1.300E+03	4.000E+02±0.000E+00	4.594E+02±4.244E+02

Fonksiyon setinin 50 boyutta yapılan testlerinin sonuçları Çizelge 4.16'da gösterilmektedir. Tek-modlu fonksiyonların ayrışabilir F1 ve F5 fonksiyonlarında 10 ve 30 boyutlu testlerde olduğu gibi AAA ve AAA_{ML} başarılı sonuçlar vermektedir. Ayrışamayan fonksiyonlarda AMopGA diğer algoritmalarla göre daha yüksek başarı göstermiştir. Çok-modlu fonksiyonlarda en iyi ortalama sonuca ulaştıkları fonksiyon sayısı açısından AAA_{ML} ve AMopGA eşittir. AAA_{ML}, F12, F15, F16, F18 ve F20 fonksiyonlarında en iyi sonuca ulaşmaktadır. AMopGA ise F7, F8, F9, F11 ve F13 fonksiyonlarında en iyi sonuca ulaşmaktadır. Fakat geriye kalan diğer çok-modlu fonksiyonların (F6, F10, F14, F17 ve F19) hepsinde AAA_{ML}, AMopGA'dan daha

başarılıdır. Karma fonksiyonlarda AAA_{ML} diğer metotlara göre daha iyi performans göstermektedir ve problem boyutu arttıkça performansı da artmaktadır.


Çizelge 4.14, 4.15 ve 4.16 incelendiğinde, hem AAA hem de AAA_{ML} 'nin genel ortalama başarısını korudukları görülmektedir. Üstelik fonksiyonların boyutları arttıkça hem AAA hem de AAA_{ML} 'nin başarı oranları da artmaktadır. Bunun yanında, AAA_{ML} , AAA'ya göre yüksek boyutlarda daha iyi sonuçlar vermektedir. Bu durum çoklu ışık kaynağı hareketinin (MLS) başarıya katkısını göstermektedir. Elde edilen bu sonuçlar hem AAA hem de AAA_{ML} 'nin kararlı, tutarlı ve dengeli algoritmalar olduğunu kanıtlamaktadır.

Şekil 4.6–4.11 algoritmaların performanslarını kıyaslamak için fonksiyon seti içerisinde bazı fonksiyonların 10, 30 ve 50 boyutta test sonuçlarının yakınsama eğrileri ile kutu ve bıyık diyagramlarını gösterir. Kutu ve bıyık diyagramlarında: kutunun merkezindeki çizgi ortancadır; kutunun kenarları 51 çalışmanın %25 ile %75 lik yüzdeliğini ifade eder; bıyıklar aykırı noktalar olarak değerlendirilmeyen fakat en aşırı veri noktalarına kadar uzanan çizgilerdir ve aykırı değerler ise diyagramda ayrı ayrı kırmızı artı işareti ile gösterilir.




Şekil 4.6. 10, 30 ve 50 boyutta CEC'13 F3 fonksiyonu için AMOpGA, SPSOABC, CDASA, AAA ve AAAML algoritmalarının kutu ve bıyık diyagramları ile yakınsama eğrileri

Şekil 4.6, F3 fonksiyonu için 10, 30 ve 50 boyutta kıyaslanan 5 algoritmanın performanslarını göstermektedir. F3 fonksiyonu üzerinde yapılan en düşük ortalama hata ve standart sapma analizlerinde AMOpGA metodunun başarısı yüksektir. AMOpGA'nın bu başarısı kutu ve bıyık diyagramlarında ve yakınsama eğrilerinde de açıkça görülmektedir. F3 fonksiyonu için 10 boyutta AAA, 30 ve 50 boyutta ise AAAML optimuma yakınsama eğrileri ve ulaştıkları en iyi sonuçların dağılımları açısından AMOpGA'dan sonra gelen en başarılı algoritmalarıdır.




Şekil 4.7. 10, 30 ve 50 boyutta CEC'13 F5 fonksiyonu için AMopGA, SPSOABC, CDASA, AAA ve AAAML algoritmalarının kutu ve bıyık diyagramları ile yakınsama eğrileri

Şekil 4.7, F5 fonksiyonu için 10, 30 ve 50 boyutta kıyaslanan 5 algoritmanın performanslarını göstermektedir. AAA ve AAAML 51 çalışma sonucu buldukları değerlerin dağılımı ve ortanca değerleri açısından birbirleriyle benzerdirler. İlaveten yakınsama eğrileri, AAA ve AAAML'nin global optimuma diğer algoritmalarından daha hızlı ulaştığını göstermektedir.




Şekil 4.8. 10, 30 ve 50 boyutta CEC'13 F9 fonksiyonu için AMopGA, SPSOABC, CDASA, AAA ve AA_{ML} algoritmalarının kutu ve büyük diyagramları ile yakınsama eğrileri

Çok-modlu F9 fonksiyonu için kıyaslanan algoritmaların yakınsama eğrileri ve kutu ve büyük diyagramları Şekil 4.8'de gösterilmektedir. F9 fonksiyonunda AMopGA diğer algoritmalarla kıyasla daha başarılı sonuçlara ulaşmaktadır ve AA_{ML} onu takip etmektedir. Bunun yanı sıra AA_{ML} düşük dağılım göstermektedir ve hiç aykırı değere sahip değildir. Bu durum AA_{ML}'nin tutarlılığını gösterir.



Şekil 4.9. 10, 30 ve 50 boyutta CEC'13 F15 fonksiyonu için AMopGA, SPSOABC, CDASA, AAA ve AAA_{ML} algoritmalarının kutu ve büyük diyagramları ile yakınsama eğrileri


Şekil 4.9'da görüldüğü gibi, 10 boyutlu F15 fonksiyonunda SPSOABC en iyi sonuçları sağlamaktadır ve AAA ile AAA_{ML} onu takip etmektedir. 30 ve 50 boyutlarda AAA_{ML} hem kutu ve büyük diyagramlarında hem de yakınsama eğrilerinde iyi sonuçlar göstermektedir. AAA ise AAA_{ML}'yi takip etmektedir. SPSOABC metodu 30 ve 50 boyutlarda başarısını koruyamamıştır.



Şekil 4.10. 10, 30 ve 50 boyutta CEC'13 F26 fonksiyonu için AMopGA, SPSOABC, CDASA, AAA ve AA_{ML} algoritmalarının kutu ve büyük diyagramları ile yakınsama eğrileri

Şekil 4.10'da görüldüğü gibi, F26 fonksiyonu için AAA ve AA_{ML} en düşük ortalama hataya sahip algoritmalarlardır. Aynı zamanda en tutarlı sonuçları da vermektedirler. CDASA F26 fonksiyonunda özellikle 50 boyutta oldukça düzensiz sonuçlar göstermiştir. 10 boyut için en düşük dağılım ve en hızlı yakınsamayı AAA

sağlamaktadır. 30 ve 50 boyut için AAA ve AAA_{ML}, birbirlerine son derece yakın ve iyi değerler vermektedir.



Şekil 4.11. 10, 30 ve 50 boyutta CEC'13 F27 fonksiyonu için AMopGA, SPSOABC, CDASA, AAA ve AAA_{ML} algoritmalarının kutu ve büyük diyagramları ile yakınsama eğrileri

F27 karma fonksiyonunda 10 boyutta AAA ve SPSOABC metotlarının, 30 ve 50 boyutta ise AAA_{ML} metodunun başarısı Şekil 4.11'de açıkça görülmektedir. AAA ve AAA_{ML} diğer metotlardan daha düzenli ve tutarlı sonuçlar vermektedir ve 51 kere

bağımsız çalışma sonucunda elde ettikleri en düşük ortalama hata değerleri içinde diğer metotlar kadar aykırı değerleri bulunmamaktadır.

Özetle, gösterilen kutu ve bıyık diyagramları ile yakınsama eğrileri AAA ve AAA_{ML} metotlarının ortalama başarılarını, tutarlılıklarını ve yüksek boyutlardaki yüksek başarılarını kanıtlamaktadır.

CEC'13 test fonksiyon seti üzerinde yapılan basit istatistiki (en düşük ortalama hata ve standart sapma) analizler, bıyık ve kutu diyagramları ve yakınsama eğrileri üzerinden yapılan analizlere ek olarak metotların problem çözme başarılarını daha ayrıntılı analiz etmek için Wilcoxon işaretli sıralama testi kullanılmıştır. Bu testte algoritmalar ikili olarak problem temelli kıyaslanmaktadır. Her ikili kıyaslamada algoritmaların 51 bağımsız çalışma sonucu elde ettikleri global minimum değerleri kullanılmıştır.

Çizelge 4.17–4.19'da, CEC'13 seti üzerinde yapılan testlerin sonuçları kullanılarak Wilcoxon işaretli sıralama testi ile AAA_{ML} ve diğer algoritmalar arasındaki kıyaslama sonuçları gösterilmektedir. Çizelgelerin son satırları ikili kıyaslama için üç istatistiki belirleyici durumu ifade eden (+/=/-) formatında toplam sayıları gösterir. Çizelge 4.17–4.19'da, AAA_{ML}'nin %95 anlamlılık düzeyinde ($\alpha = 0.05$) kıyaslanan diğer algoritmalarından istatistiksel olarak daha iyi sonuçlar gerçekleştirdiği görülmektedir.

Çizelge 4.17. 10 boyutlu CEC'13 fonksiyonları için Wilcoxon işaretli-sıralama testinin sonuçları ($\alpha = 0.05$)

P	AAA _{ML} – AAA			AAA _{ML} – CDASA			AAA _{ML} – SPSOABC			AAA _{ML} – AMopGA		
	p-Değeri	T	W	p-Değeri	T	W	p-Değeri	T	W	p-Değeri	T	W
F1	1.00E+00	0	=	1.00E+00	0	=	1.00E+00	0	=	7.56E-10	0	+
F2	1.48E-03	324	+	4.57E-06	1152	+	9.34E-02	842	=	5.15E-10	1326	-
F3	1.86E-01	522	=	1.00E-04	248	+	1.86E-01	522	=	5.15E-10	1326	-
F4	5.43E-08	83	+	9.66E-09	1275	-	1.34E-01	503	=	5.15E-10	1326	-
F5	1.25E-01	0	=	5.15E-10	0	+	1.00E+00	0	=	5.15E-10	0	+
F6	1.44E-01	819	=	7.65E-04	1022	-	5.15E-10	1326	-	5.15E-10	1326	-
F7	5.15E-10	0	+	5.15E-10	0	+	1.61E-07	104	+	5.15E-10	1326	-
F8	9.90E-02	839	=	1.44E-01	819	=	1.11E-01	833	=	5.15E-10	1326	-
F9	4.24E-04	287	+	1.97E-08	64	+	2.32E-08	67	+	3.33E-09	1294	-
F10	1.04E-06	142	+	6.02E-05	235	+	3.95E-08	1249	-	7.83E-08	90	+
F11	6.25E-01	2.5	=	2.15E-06	16	+	1.00E+00	1	=	1.00E+00	1	=
F12	8.65E-08	83	+	7.35E-10	6	+	4.01E-02	882	-	2.67E-05	215	+
F13	1.04E-06	142	+	9.87E-10	11	+	6.02E-05	1091	-	6.38E-03	954	-
F14	9.13E-02	723.5	=	6.53E-10	4	+	2.02E-01	799	=	7.80E-10	7	+
F15	2.94E-01	551	=	4.37E-05	227	+	4.18E-06	1154	-	9.03E-07	139	+
F16	5.46E-10	1325	-	6.93E-10	1321	-	8.77E-10	1317	-	8.68E-03	943	-
F17	7.06E-08	1238	-	1.08E-02	935	-	2.50E-09	1299	-	1.07E-03	314	+
F18	1.75E-06	1173	-	2.69E-01	781	=	6.53E-10	1322	-	5.15E-10	0	+
F19	1.58E-08	1266	-	1.22E-01	828	=	4.94E-09	1287	-	5.15E-10	0	+
F20	6.20E-03	371	+	3.52E-09	33	+	5.71E-02	866	=	7.08E-01	703	=
F21	5.04E-06	276	-	1.22E-04	105	-	6.49E-11	51	-	4.28E-10	1326	-
F22	2.11E-01	710	=	8.61E-07	138	+	3.33E-09	1294	-	8.27E-10	8	+
F23	6.36E-08	86	+	1.40E-09	17	+	7.64E-01	631	=	4.94E-09	1287	-
F24	3.30E-01	767	=	2.39E-02	422	+	3.49E-01	763	=	5.46E-10	1325	-
F25	4.51E-03	360	+	1.83E-06	154	+	6.21E-02	862	=	3.25E-07	1208	-
F26	5.71E-06	1147	-	9.17E-03	385	+	7.61E-06	1140.5	-	5.35E-05	232	+
F27	2.68E-05	1111	-	3.29E-05	220	+	3.29E-05	1106	-	4.13E-03	357	+
F28	9.77E-04	66	-	2.50E-08	45	+	7.34E-01	26	=	9.24E-13	0	+
+/-/-	10/10/8			19/4/5			2/13/13			13/2/13		

(p-Değeri: Null (H0) hipotezini tahmini reddetme olasılığı; T: İşaretli sıralamaların toplamalarının en küçüğü; W: Kazanan (Winner))

Çizelge 4.18. 30 boyutlu CEC’13 fonksiyonları için Wilcoxon işaretli-sıralama testinin sonuçları ($\alpha = 0.05$)

P	AAA _{ML} – AAA			AAA _{ML} – CDASA			AAA _{ML} – SPSOABC			AAA _{ML} – AMopGA		
	p-Değeri	T	W	p-Değeri	T	W	p-Değeri	T	W	p-Değeri	T	W
F1	1.25E-01	0	=	4.26E-12	1176	-	4.26E-12	1176	-	5.15E-10	0	+
F2	1.04E-03	313	+	4.64E-08	1246	-	1.25E-05	1129	-	5.15E-10	1326	-
F3	7.92E-04	305	+	9.42E-03	386	+	1.30E-02	398	+	5.15E-10	1326	-
F4	5.15E-10	0	+	5.15E-10	1326	-	2.94E-07	1210	-	5.15E-10	1326	-
F5	1.98E-10	0	+	5.15E-10	0	+	1.74E-11	1326	-	5.15E-10	0	+
F6	1.01E-05	192	+	5.00E-06	176	+	3.82E-06	1156	-	5.80E-10	2	+
F7	5.15E-10	0	+	6.93E-10	5	+	3.52E-09	33	+	9.14E-09	1276	-
F8	4.13E-03	969	-	4.51E-03	966	-	2.11E-03	991	-	5.15E-10	1326	-
F9	6.15E-10	3	+	6.93E-10	5	+	5.15E-10	0	+	5.15E-10	1326	-
F10	1.24E-01	827	=	5.15E-10	1326	-	3.20E-08	1253	-	5.46E-10	1325	-
F11	4.66E-03	195	-	7.73E-07	80	+	3.39E-10	1128	-	3.39E-10	1128	-
F12	5.46E-10	1	+	5.15E-10	0	+	2.10E-09	24	+	5.15E-10	0	+
F13	5.46E-10	1	+	5.15E-10	0	+	1.45E-06	149	+	3.16E-05	1107	-
F14	1.31E-07	1226	-	5.46E-10	1	+	6.53E-10	1322	-	1.05E-09	12	+
F15	1.53E-04	259	+	6.82E-06	183	+	1.44E-03	323	+	9.87E-10	11	+
F16	1.45E-07	1224	-	2.44E-08	1258	-	3.82E-04	1042	-	8.22E-01	687	=
F17	5.15E-10	1326	-	1.87E-07	1219	-	5.15E-10	1326	-	5.15E-10	0	+
F18	5.46E-10	1	+	5.15E-10	0	+	6.15E-10	3	+	5.15E-10	0	+
F19	7.99E-03	946	-	1.42E-08	58	+	1.60E-02	406	+	5.15E-10	0	+
F20	7.06E-05	239	+	2.24E-09	5	+	6.08E-02	463	=	3.95E-08	77	+
F21	3.22E-01	335	=	5.50E-02	525	=	9.94E-01	351	=	9.78E-01	660	=
F22	9.52E-02	841	=	3.52E-09	33	+	1.99E-09	1303	-	5.46E-10	1	+
F23	8.25E-08	91	+	6.93E-10	5	+	7.43E-08	89	+	5.15E-10	1326	-
F24	5.15E-10	0	+	5.23E-09	40	+	9.69E-04	311	+	5.15E-10	0	+
F25	6.15E-10	3	+	5.15E-10	0	+	1.25E-09	15	+	5.15E-10	0	+
F26	3.58E-07	120	+	8.92E-05	245	+	8.80E-02	481	=	5.15E-10	0	+
F27	6.93E-10	5	+	5.80E-10	2	+	5.43E-08	83	+	5.15E-10	0	+
F28	1.00E+00	1	=	7.81E-02	3	=	8.13E-01	6	=	5.12E-10	0	+
+/=-	17/5/6			19/2/7			12/4/12			16/2/10		

Çizelge 4.19. 50 boyutlu CEC'13 fonksiyonları için Wilcoxon işaretli-sıralama testinin sonuçları ($\alpha = 0.05$)

P	AAA _{ML} – AAA			AAA _{ML} – CDASA			AAA _{ML} – SPSOABC			AAA _{ML} – AMopGA		
	p-Değeri	T	W	p-Değeri	T	W	p-Değeri	T	W	p-Değeri	T	W
F1	1.50E-08	0	+	2.84E-11	1326	-	2.84E-11	1326	-	5.15E-10	0	+
F2	3.41E-07	119	+	6.91E-04	1025	-	5.15E-10	1326	-	5.15E-10	1326	-
F3	6.52E-05	237	+	9.28E-05	246	+	1.49E-01	509	=	5.15E-10	1326	-
F4	6.93E-10	5	+	5.15E-10	1326	-	5.15E-10	1326	-	5.15E-10	1326	-
F5	4.89E-09	0	+	5.15E-10	0	+	1.19E-10	1326	-	5.15E-10	0	+
F6	1.40E-06	90	+	3.58E-07	120	+	1.66E-02	918	-	5.46E-10	1	+
F7	6.15E-10	3	+	5.46E-10	1	+	5.46E-06	178	+	5.15E-10	1326	-
F8	4.82E-01	588	=	2.27E-01	792	=	4.15E-01	750	=	5.15E-10	1326	-
F9	5.15E-10	0	+	5.46E-10	1	+	5.15E-10	0	+	5.15E-10	1326	-
F10	7.15E-04	1024	-	5.15E-10	1326	-	7.06E-08	1238	-	2.54E-03	341	+
F11	1.93E-09	1215	-	7.90E-01	451	=	1.46E-09	1308	-	4.25E-10	1326	-
F12	5.15E-10	0	+	5.15E-10	0	+	2.10E-09	24	+	5.15E-10	0	+
F13	5.15E-10	0	+	5.15E-10	0	+	3.73E-09	34	+	5.46E-10	1325	-
F14	1.18E-09	1312	-	5.15E-10	0	+	5.15E-10	1326	-	5.46E-10	1	+
F15	8.76E-04	308	+	1.75E-06	153	+	1.26E-06	146	+	5.15E-10	0	+
F16	5.15E-10	0	+	5.15E-10	0	+	5.15E-10	0	+	5.15E-10	0	+
F17	5.15E-10	1326	-	1.38E-07	101	+	5.15E-10	1326	-	5.15E-10	0	+
F18	5.15E-10	0	+	5.15E-10	0	+	5.46E-10	1	+	5.15E-10	0	+
F19	3.11E-01	771	=	3.94E-09	35	+	5.15E-10	0	+	5.15E-10	0	+
F20	1.14E-08	54	+	5.46E-10	1	+	6.39E-01	613	=	3.03E-01	553	=
F21	6.05E-02	301.5	=	2.90E-01	331.5	=	8.73E-04	199	+	1.53E-03	1001	-
F22	6.93E-10	1321	-	2.08E-08	65	+	5.15E-10	1326	-	6.53E-10	4	+
F23	1.12E-07	97	+	1.49E-09	18	+	9.66E-09	51	+	5.15E-10	1326	-
F24	5.15E-10	0	+	5.15E-10	0	+	3.20E-08	73	+	5.15E-10	0	+
F25	6.15E-10	3	+	5.15E-10	0	+	6.53E-10	4	+	5.15E-10	0	+
F26	4.24E-04	287	+	1.45E-07	102	+	1.20E-08	55	+	5.15E-10	0	+
F27	5.15E-10	0	+	5.46E-10	1	+	7.80E-10	7	+	5.15E-10	0	+
F28	1.00E+00	1	=	1.95E-03	1	+	1.56E-02	1	+	5.15E-10	1326	-
+/-/-	19/4/5			21/3/4			15/3/10			16/1/11		

Çizelge 4.17’de görüldüğü gibi, 10 boyutlu fonksiyonlarda AAA_{ML} metodu SPSOABC hariç diğer algoritmalarından daha iyi veya eşit sonuçlar sağlamaktadır. 10 boyutlu fonksiyonlar için AAA_{ML} istatistiksel olarak AAA ve AMopGA ile eşit ve yakın sonuçlar vermektedir, CDASA’dan ise istatistiksel olarak daha iyidir. 30 boyutlu fonksiyonlar için istatistiksel sonuçların gösterildiği Çizelge 4.18’de AAA_{ML}’nin performansının arttığı istatistiksel olarak kanıtlanmaktadır. Bu çizelgede AAA_{ML}’nin AAA, CDASA ve AMopGA’dan daha iyi olduğu ve SPSOABC ile istatistiksel olarak eşit olduğu görülmektedir. 50 boyutlu fonksiyonlarda AAA_{ML}’nin kıyaslanan tüm algoritmalarından istatistiksel olarak daha iyi olduğu Çizelge 4.19’da açıkça görülmektedir.

4.2. Gerçek Dünya Optimizasyon Problemlerinde Performans Değerlendirmesi

Bu bölümde, önceki bölümde test fonksiyon setleri üzerinde yapılan denemelere ilaveten AAA ve AAA_{ML}’nin gerçek dünya optimizasyon problemleri üzerindeki performanslarını görmek için de testler yapılmıştır. İlk olarak temel AAA metodunun performansını değerlendirmek için basınçlı tank tasarım optimizasyon problemi üzerinde testler yapılmıştır. İkinci olarak da CEC’11 gerçek dünya optimizasyon problemleri olarak bilinen 22 adet problemten oluşan set üzerinde hem AAA hem de AAA_{ML}’nin başarısını doğrulamak için testler yapılmıştır.

4.2.1. Basınçlı tank tasarım optimizasyon probleminde AAA’nın performans değerlendirilmesi

Bu bölümde AAA’nın başarısı basınçlı tank tasarım optimizasyon problemi (Onwubolu ve Babu, 2004; Clerc, 2009) üzerinde test edilmiş ve test sonuçları ABC ve SPSO (versiyon 2011) algoritmaları ile kıyaslanmıştır. Kıyaslamalar algoritmaların çözüm kaliteleri ve çözüme ulaşma hızları (zamanları) açısından değerlendirilmiştir.

Kıyaslanan algoritmalar için ortak olarak kullanılan parametreler;

- AAA, SPSO ve ABC için popülasyon boyutu 40 olarak ayarlanmıştır.
- Tüm algoritmalar için durdurma kriteri olarak fonksiyon hesaplama sayısı (hesaplama maliyeti) kullanılmıştır. Maksimum fonksiyon hesaplama sayıları üç farklı test çalışması için sırayla 10,000, 20,000 ve 30,000 olarak belirlenmiştir.

- Başlangıç aday çözümleri homojen bir dağılım ile problemin alt ve üst limitleri arasında rastgele olarak başlatılmıştır.
- Algoritmaların test sonuçları 30 bağımsız çalıştırmanın sonuçlarının ortalamaları alınarak rapor edilmiştir.

Algoritmalara özgü parametreler;

- ABC algoritması için *limit* parametresi gözcü arı sayısı çarpı problem boyutu olarak ayarlanmıştır.
- SPSO algoritması için atalet ağırlığı, $w = 1/(2*\log(2))$ ve öğrenme faktörleri (sosyal ve kavramsal parametreler) $c_1=c_2=0.5+\log(2)$ olarak ayarlanmıştır.
- AAA için, yapılan ön çalışmaların sonucu olarak, enerji kaybı, $e = 0.3$; kesme kuvveti, $\Delta = 2$ ve adaptasyon katsayısı, $A_p = 1$ olarak belirlenmiştir.

Basınçlı tank tasarım optimizasyon probleminde kıyaslanan algoritmaların 30,000 fonksiyon hesaplama ile 30 bağımsız çalışma sonucunda buldukları en iyi parametre değerleri ve en iyi çözümleri Çizelge 4.20’de verilmektedir. Çizelgede verilen çözüm değerleri algoritmaların problem tanımında belirtilen kısıtlara takılmadan buldukları en iyi çözümlerdir. Problemin kısıtlarının üstesinden gelmek için tüm algoritmalarda statik penaltı metodu kullanılmıştır. Algoritmaların buldukları her bir çözüm için bulunan değerlerin sağlamadıkları her bir kısıt fonksiyonu için çözüme sabit bir penaltı (ceza) değeri eklenmiştir. Ayrıca Çizelgedeki y_1 ve y_2 parametreleri, problemin x_1 (T_s) ve x_2 (T_h) parametrelerinin kesikli değerlere dönüştürülmüş halleridir. Bu dönüştürme işlemi algoritmanın bulduğu x_1 ve x_2 parametrelerinin en yakın kesikli değere set edilmesi ile gerçekleştirilmiş ve uygunluk fonksiyonunun hesaplanmasında T_s ve T_h parametreleri için sırasıyla y_1 ve y_2 değerleri kullanılmıştır.

Çizelge 4.20. Basınçlı tank tasarım optimizasyon problemi için AAA, SPSO ve ABC algoritmalarının ulaştıkları en iyi çözüm ve buldukları parametre değerleri

	AAA	SPSO	ABC
$x_1(T_s)$	1.13905470	1.13168647	1.12500000
$x_2(T_h)$	0.625000000	0.629557446	0.62500000
$x_3(R)$	58.2901554	57.9589752	58.1960902
$x_4(L)$	43.6926565	45.5276803	44.2348349
y_1	1.125	1.125	1.125
y_2	0.625	0.625	0.625
g_1	-7.79999842E-10	-6.39177864E-03	-1.81545914E-03
g_2	-6.89119175E-02	-7.20713766E-02	-6.98092995E-02
g_3	-4.15554037E-04	-2.07786023E+01	-2.54823623E+02
g_4	-1.96307344E+02	-1.94472320E+02	-1.95765165E+02
g_5	-2.50000000E-02	-2.50000000E-02	-2.50000000E-02
g_6	-2.50000000E-02	-2.50000000E-02	-2.50000000E-02
$f(x)$	7197.72893	7218.30817	7204.57448

Uygulanan algoritmaların performanslarını daha iyi analiz edebilmek için, üç farklı test yapılmış ve her bir test için durdurma kriteri sırasıyla 10,000, 20,000 ve 30,000 olarak ayarlanmıştır. Her bir testte 30 bağımsız çalışma sonucunun ortalama, en iyi, en kötü ve standart sapma değerleri ile ortalama çalışma zamanları ve çalışma zamanlarının standart sapmaları Çizelge 4.21’de gösterilmektedir. Çizelgede gösterilen sonuçlar kıyaslamamanın adil olması için tüm algoritmaların aynı bilgisayar ve işletim sistemi üzerinde çalıştırılmasıyla elde edilmiştir.

Çizelge 4.21. Basınçlı tank tasarım optimizasyon problemi için 30 bağımsız çalışma üzerinden AAA, SPSO ve ABC algoritmalarının ulaştıkları ortalama, en iyi, en kötü, standart sapma, ortalama süre ve sürelerin standart sapma değerleri

NFEs	Algoritma	Ortalama	En iyi	En kötü	Std.	Ortalama Süre	Süre Std.
10,000	AAA	7199.64315	7197.81176	7204.81608	1.433E+00	3.642E-01	1.372E-02
	SPSO	7787.81825	7307.80230	8703.37492	3.377E+02	2.495E+00	1.921E-01
	ABC	7467.07005	7216.87872	7903.67565	1.757E+02	1.669E+00	5.725E-02
20,000	AAA	7197.75025	7197.73086	7197.88922	3.305E-02	7.245E-01	1.939E-02
	SPSO	7755.77219	7215.65815	8903.28015	3.551E+02	4.404E+00	2.028E-01
	ABC	7700.73753	7294.37680	7903.67564	2.400E+02	3.405E+00	8.433E-02
30,000	AAA	7197.72909	7197.72893	7197.73117	4.153E-04	1.119E+00	3.959E-02
	SPSO	7709.40529	7218.30817	8470.96724	3.073E+02	7.230E+00	4.242E-01
	ABC	7463.02094	7204.57448	7903.67564	2.315E+02	5.134E+00	9.521E-02

(NFEs: Fonksiyon hesaplama sayısı; Std.: Standart Sapma)

Çizelge 4.21’de hesaplanan her bir istatistiki değerin en iyisi koyu belirtilmiştir. Çizelgeden de görüldüğü gibi AAA en iyi sonuçları vermektedir. AAA bulduğu en iyi değerler ile çözüm kalitesi açısından başarısını kanıtlamaktadır. Ayrıca bulduğu en iyi ortalama ve standart sapma değerleri ile bağımsız çalışmalar sonucunda çözüm kalitesini koruyabildiği ve tutarlı bir algoritma olduğu görülmektedir. İlaveten Çizelge 4.21’de görüldüğü gibi, en düşük çalışma zamanları ile kaliteli çözüm bulan tutarlı bir algoritma olmasının yanı sıra AAA kıyaslanan diğer algoritmalara göre daha hızlı bir algoritmadır.

4.2.2. CEC’11 gerçek dünya optimizasyon problem setinde AAA ve AAA_{ML}’nin performans değerlendirmesi

Bu bölümde, AAA ve AAA_{ML}’nin etkinlik ve tutarlılıklarını analiz etmek amacıyla CEC’11 gerçek dünya optimizasyon problemleri üzerinde performans testleri gerçekleştirilmiştir. Test çalışmaları IEEE-CEC’11 teknik raporunda belirtilen hesaplama kriterlerine uygun olarak yapılmıştır. Her bir problem için, her bir algoritma 150,000 maksimum amaç (uygunluk) fonksiyonu hesaplama sayısı ile 25 bağımsız çalışma üzerinden elde edilen en iyi amaç fonksiyon değerlerinin ortalamaları ve standart sapmaları hesaplanmıştır. Her bir problem için tanımlı çözüm uzayında rastgele başlatma kullanılmıştır.

AAA ve AAA_{ML}’nin performanslarını kıyaslayabilmek için literatürde güncel, geliştirilmiş ve hibrit algoritmalar ED-DE, EPSDE ve AdaptDE algoritmaları kullanılmıştır. Tüm algoritmalar için aynı durdurma kriterleri kullanılmıştır. Kıyaslamalarda kullanılan ED-DE, EPSDE ve AdaptDE algoritmalarının test sonuçları direkt olarak Asafuddoula ve ark. (2011), Mallipeddi ve Suganthan (2011) ve Wang ve ark. (2011)’deki çalışmalardan alınmıştır.

Kıyaslanan algoritmaların CEC’11 gerçek dünya optimizasyon problemleri üzerindeki test sonuçları Çizelge 4.22’de gösterilmiştir. Çizelge 4.22’de her bir problem için algoritmaların en iyi ortalama değerleri, standart sapmaları ve sıralama değerleri (kıyaslanan algoritmalar içindeki en iyi ortalama değerlerine göre başarı sıraları) gösterilmiştir. Her bir problem için en iyi ortalama değerine ulaşan algoritmanın sonucu koyu olarak gösterilmiştir. Çizelge 4.22’nin son satırı, toplam sıralama değeri ve parantez içinde toplam sıralamanın her bir problem için ortalamasını göstermektedir.

Çizelge 4.22. CEC'11 Gerçek dünya optimizasyon problemlerinde 25 bağımsız çalışma üzerinden ED-DE, EPSDE, AdaptDE, AAA ve AAA_{ML} algoritmalarının ulaştıkları ortalama, standart sapma ve başarı sıralama değerleri

		ED-DE	EPSDE	AdaptDE	AAA	AAA _{ML}
P1	Hata	0.00E+00 ±0.00E+00	1.78E+00±4.18E+00	3.85E+00±5.69E+00	7.10E+00±6.69E+00	3.80E+00±5.81E+00
	Sıra	1	2	4	5	3
P2	Hata	-2.62E+01±2.82E+00	-1.83E+01±1.65E+00	-2.68E+01 ±1.97E+00	-2.32E+01±4.42E+00	-2.54E+01±3.63E+00
	Sıra	2	5	1	4	3
P3	Hata	1.15E-05 ±1.35E-19	1.15E-05 ±1.52E-19	1.15E-05 ±3.80E-19	1.15E-05 ±1.73E-21	1.15E-05 ±1.73E-21
	Sıra	1	1	1	1	1
P4	Hata	1.38E+01 ±1.69E-02	1.67E+01±3.26E+00	1.83E+01±2.92E+00	1.77E+01±3.50E+00	1.95E+01±2.95E+00
	Sıra	1	2	4	3	5
P5	Hata	-3.37E+01±1.96E+00	-2.90E+01±1.84E+00	-3.38E+01±1.43E+00	-3.50E+01 ±8.33E-01	-3.47E+01±1.29E+00
	Sıra	4	5	3	1	2
P6	Hata	-2.68E+01±2.38E+00	-1.70E+01±2.68E+00	-2.58E+01±2.99E+00	-2.79E+01±1.73E+00	-2.88E+01 ±7.09E-01
	Sıra	3	5	4	2	1
P7	Hata	1.19E+00±2.83E-01	1.42E+00±7.38E-02	5.00E-01 ±0.00E+00	9.27E-01±1.65E-01	8.62E-01±1.58E-01
	Sıra	4	5	1	3	2
P8	Hata	2.20E+02 ±0.00E+00	2.20E+02 ±0.00E+00	2.20E+02 ±0.00E+00	2.20E+02 ±0.00E+00	2.20E+02 ±0.00E+00
	Sıra	1	1	1	1	1
P9	Hata	3.55E+05±1.01E+04	2.53E+03±1.33E+03	1.93E+01 ±5.69E+00	2.07E+03±8.52E+02	1.08E+03±5.14E+02
	Sıra	5	4	1	3	2
P10	Hata	-2.14E+01 ±3.09E-01	-1.56E+01±3.79E+00	-2.10E+01±1.90E+00	-2.00E+01±2.60E+00	-2.00E+01±1.92E+00
	Sıra	1	5	2	3	3
P11.1	Hata	5.21E+04 ±3.66E+02	5.22E+04±7.24E+02	5.42E+04±4.87E+03	5.43E+04±2.64E+03	5.21E+04 ±4.43E+02
	Sıra	1	3	4	5	1
P11.2	Hata	1.08E+06±2.73E+04	1.07E+06 ±2.13E+03	1.09E+06±4.46E+03	1.08E+06±6.46E+03	1.07E+06 ±2.12E+03
	Sıra	3	1	5	3	1
P11.3	Hata	1.54E+04 ±9.10E+00	1.55E+04±1.55E+01	1.55E+04±3.05E+01	1.55E+04±2.02E+01	1.55E+04±1.58E+01
	Sıra	1	2	2	2	2
P11.4	Hata	1.83E+04±8.70E+01	1.81E+04 ±4.39E+01	1.86E+04±1.42E+02	1.91E+04±2.07E+02	1.91E+04±1.53E+02
	Sıra	2	1	3	4	4
P11.5	Hata	3.29E+04±5.95E+01	3.27E+04 ±3.59E+01	3.29E+04±6.84E+01	3.29E+04±5.50E+01	3.28E+04±4.65E+01
	Sıra	3	1	3	3	2
P11.6	Hata	1.33E+05±1.94E+03	1.31E+05±2.47E+03	1.26E+05 ±8.36E+02	1.35E+05±2.93E+03	1.35E+05±2.13E+03
	Sıra	3	2	1	4	4
P11.7	Hata	1.91E+06 ±9.10E+03	1.92E+06±1.18E+04	1.93E+06±2.34E+04	1.97E+06±9.14E+04	1.94E+06±1.36E+04
	Sıra	1	2	3	5	4
P11.8	Hata	9.41E+05±1.60E+03	9.43E+05±2.63E+03	9.31E+05 ±3.50E+03	9.50E+05±1.04E+04	9.43E+05±2.59E+03
	Sıra	2	3	1	5	3
P11.9	Hata	1.10E+06±6.43E+04	9.90E+05±4.14E+04	9.93E+05±1.96E+05	1.08E+06±8.03E+04	9.44E+05 ±3.25E+03
	Sıra	5	2	3	4	1
P11.10	Hata	9.41E+05±1.60E+03	9.43E+05±2.63E+03	9.31E+05 ±3.06E+03	9.52E+05±1.06E+04	9.44E+05±3.06E+03
	Sıra	2	3	1	5	4
P12	Hata	1.44E+01±1.95E+00	1.88E+01±1.67E+00	2.12E+01±5.91E+00	1.47E+01±2.60E+00	1.42E+01 ±2.37E+00
	Sıra	2	4	5	3	1
P13	Hata	1.62E+01±1.83E+00	1.39E+01±4.08E+00	1.25E+01 ±2.47E+00	1.59E+01±3.12E+00	1.37E+01±1.94E+00
	Sıra	5	3	1	4	2
Toplam Sıra		53	62	54	73	52
(Ortalama Sıra)		(2.41)	(2.82)	(2.45)	(3.32)	(2.36)

Çizelge 4.22’de görüldüğü gibi AAA_{ML} P3, P6, P8, P11.1, P11.2, P11.9 ve P12 problemlerinde en iyi ortalama değere ulaşmaktadır. 22 problem içinde en iyi ortalama değere ulaşma sayıları açısından AdaptDE metodu en başarılı algoritma olarak göze çarpmaktadır. AdaptDE P2, P3, P7, P8, P9, P11.6, P11.8, P11.10 ve P13 problemlerinde ortalama en iyi değere ulaşmaktadır. Fakat sıralama değerlerine bakıldığında AAA_{ML} metodunun AdaptDE’den daha başarılı olduğu görülür. AAA_{ML} ve AdaptDe’nin ortalama sıralama değerleri sırasıyla 2.36 ve 2.45 dir. Bunun sebebi AAA_{ML} en iyi değere ulaşmadığı problemlerde en iyi değerlere yakın kaliteli sonuçlar ürettiği için sıralama değerleri genel olarak diğer algoritmalarından daha iyidir. Bu durum AAA_{ML}’nin genel başarısı yüksek ve tutarlı sonuçlar veren bir algoritma olduğunu göstermektedir.

5. SONUÇLAR VE ÖNERİLER

5.1. Sonuçlar

Optimizasyon, en uygun çözümü bulma işlemidir. Bir probleme en uygun çözümü bulmak için tarih boyunca çeşitli teknikler kullanılmıştır. Deneme yanılma ile en uygun çözümü bulmak en eski tekniklerden biridir. Daha sonra matematiksel araçların kullanımı optimizasyon problemlerinin çözümünde çok yaygın olarak kullanılmış ve halen kullanılmaya devam etmektedir. Matematiksel model yaklaşımları problemlere kesin çözümler bulmaktadır fakat günümüz optimizasyon problemlerinin zorluğu, karmaşıklığı ve kaynakların kısıtlı olması matematiksel model yaklaşımlarının çözüm üretmede zorlanmasına veya çözüm için çok zaman harcamasına neden olmaktadır. Bunun üstesinden gelmek için sezgisel yaklaşımlar ortaya çıkmıştır. Sezgisel yaklaşımlar, karmaşık problemler için kesin çözüm garantisi vermeden daha kısa sürede kaliteli çözümler sunmuştur. Sezgisel yaklaşımların bu başarısı araştırmacıların bu alana ilgisini arttırmıştır. Sezgisel yaklaşımların başarısını arttırmak için birçok disiplinden ilham alınarak çeşitli yöntemler önerilmiştir. Özellikle son dönemlerde biyolojiden ilham alınarak geliştirilen sezgisel yöntemler büyük başarı sağlamıştır.

Sezgisel metotlar üzerine yapılan çalışmalar, genel amaçlı, farklı problemlere kolay uyarlanabilen, kaliteli çözümleri çok daha az zamanda bulabilen yöntemler geliştirmeyi amaçlar. Bu amaç için biyolojiden esinlenilerek birçok yöntem önerilmiştir. Yeni önerilen yöntemlere ilaveten var olan yöntemlerin geliştirilmesi üzerine de birçok çalışma yapılmıştır. Bu tez çalışmasında alglerin yaşam davranışlarından esinlenilerek yeni bir biyolojik ilhamlı yapay alg algoritması sunulmuş ve detaylı performans analizi yapılmıştır.

Yapay alg algoritması temelde üç bölümden oluşmaktadır. Birincisi helisel harekettir. Helisel hareket fazının modellenmesi, alglerin gerçek yaşamda kamçıları sayesinde sıvı içerisinde helisel şekilde yüzmeleri ve sürekli ışığa yakın kalma çabaları esasına dayanır. İkincisi, evrimsel süreçtir. Işığa yakın olan ve yeterli besin alan alglerin mitoz bölünme ile çoğalmaları aksi takdirde bir süre yaşayıp sonra ölmeleri temel alınarak modellenmiştir. Üçüncü bölüm adaptasyondur. Bulunduğu sıvı içerisinde yeterince büyüemeyen alglerin hayatta kalmak için ortama adapte olmaya çalışması temeline dayanır.

AAA üç kontrol parametresine (enerji kaybı, adaptasyon ve kesme kuvveti) sahiptir. Enerji kaybı her bir çevrimde (iterasyonda) alg kolonisinin yeni aday çözüm üretme sayısını belirler. Her bir alg kolonisi enerjisi (bir önceki çevrimden elde ettiği başarısı) ile doğru orantılı olarak yeni aday çözümler üretebilir. Düşük enerji kaybı algoritmanın yerel arama yeteneğini artırır fakat bu yerel minimumlara takılmaya neden olur. Aksine bu parametrenin yüksek belirlenmesi algoritmanın global arama yeteneğini (çözüm uzayının daha iyi keşfedilmesini) artırır fakat global en iyiye yakınsama hızını düşürür. Adaptasyon iyi çözümler bulamayan alg kolonisinin ortamdaki en iyi alg kolonisine kendisini benzetme sürecinin hızını belirler. Adaptasyon parametresinin artışı global en iyiye yakınsama hızını artırır, hesaplama maliyetini ve süresini azaltır. Fakat aynı zamanda algoritmanın daha fazla yerel minimumlara takılmasına neden olur. Kesme kuvveti alg kolonilerinin büyüklükleri ile ters orantılı olarak yeni aday çözümlerin üretiminde çözüm uzayının sınırlarını belirler.

AAA'da yeni aday çözümler üretmek için helisel hareket uygulanır. AAA yeni bir aday çözüm üretmek için, alg kolonisinin turnuva metodu ile seçilen farklı bir alg kolonisine rastgele seçilmiş üç farklı boyutta büyüklüğü ile ters orantılı olarak hareket eder. AAA var olan çözüm ile yeni aday çözüm arasında açgözlü seçim uygular. Helisel hareket üç yeteneği barındırır: birincisi, turnuva metodu ile çeşitliliği artırır, ikincisi alg kolonilerinin büyüklüklerine göre farklı adım büyüklükleri ile hassasiyeti artırır ve üçüncü olarak, açgözlü seçim yöntemi ile yakınsama hızını artırır. AAA_{ML} yönteminde yapılan geliştirme ile helisel harekete MLS eklenmiştir. MLS ile her ışık kaynağı birbirinden farklı seçilmektedir. Bu durum arama uzayında her biri birbirinden farklı çözümler verir. Üç ışık kaynağından optimum değere en yakın olan ile modifikasyon yapılan boyutta çözüm uzayının daha iyi bölgelerine doğru ilerleme sağlanır. Uygunluk değeri en kötü olan ışık kaynağı ile çözüm uzayında çeşitlilik sağlanır. Diğer ışık kaynağı ise bu ikisi arasındaki dengeyi artırır. MLS algoritmanın çeşitlilik ile yoğunlaşma özellikleri arasındaki dengeyi arttırmaktadır.

AAA_{ML} yönteminde yapılan diğer geliştirme adaptasyon sürecidir. Bu yeni süreç ile adaptasyona uğrayan alg kolonisinin kendisini geliştirebilmesi (daha iyi çözümler bulabilmesi) için daha fazla şans verilmektedir. Evrimsel süreçte büyüyen alg kolonisinin bir hücrelerini yeterince büyüemeyen alg kolonisinin bir hücresinin yerine kopyalamasıdır. Bu süreç global en iyiyi bulmak için hassas aramayı güçlendirir.

İlk performans testleri CEC'05 test fonksiyonları üzerinde gerçekleştirilmiştir. Bu testte birbirinden farklı karakteristiğe sahip 24 adet fonksiyon üç farklı (10, 30 ve

50) boyutta kullanılmıştır. Sonuçlar ABC, BA, ACO_R, DE ve HS_{POP} yöntemleri ile kıyaslanmıştır. Tek-modlu fonksiyonlarda HS_{POP} algoritmasının başarısı göze çarpmaktadır. AAA ise tek-modlu fonksiyonlarda HS_{POP}'dan sonra en iyi performansı sağlamıştır. Çok-modlu fonksiyonlarda AAA'nın performansı kıyaslanan diğer algoritmalarla göre daha iyidir. Karma fonksiyonlarda AAA çok-modlu fonksiyonlarda göstermiş olduğu başarıyı devam ettirmektedir. Ayrıca karma fonksiyonlarda ACO_R algoritması da başarılı sonuçlar vermiştir. Tüm boyutlarda ve türlerde yapılan testlerin sonuçları incelendiği zaman kıyaslanan diğer algoritmaların başarılarını genele yayamadıkları fakat AAA'nın en iyi veya en iyiye yakın sonuçlar üreterek başarılı bir performans sergilediği görülmektedir.

İkinci performans testi CEC'13 test fonksiyonları üzerinde yapılmıştır. Bu testlerde AAA'nın yanısıra geliştirilmiş AAA_{ML} sürümü de kullanılmıştır. Sonuçlar son dönemde geliştirilmiş veya hibrit yöntemlerden SPSOABC, CDASA ve AMopGA ile kıyaslanmıştır. CEC'13 test fonksiyonlarında yapılan testler göstermiştir ki, 10 boyutlu çok-modlu fonksiyonlarda SPSOABC, karma fonksiyonlarda AMopGA diğer yöntemlere göre daha başarılı sonuçlar üretmiştir. AAA ve AAA_{ML} birbirlerine yakın sonuçlar üretmekle beraber genel olarak en iyi ikinci sonuçlara ulaşmışlardır. 30 ve 50 boyutlu fonksiyonlarda AAA ve AAA_{ML}'nin performansı artmıştır. Özellikle AAA_{ML} diğer algoritmalarla daha üstün performans göstermiştir. CEC'05 ve CEC'13 test sonuçları AAA'nın dengeli ve tutarlı sonuçlar verdiğini göstermiştir.

Gerçek dünya problemleri üzerinde yapılan ilk test basınçlı tank tasarım optimizasyon problemi üzerinde yapılmıştır. Temel AAA'nın sonuçları SPSO ve ABC algoritmaları ile kıyaslanmıştır. AAA hem çözüm kalitesi açısından hem de çözüme ulaşma süreleri açısından diğer yöntemlerden daha başarılı sonuçlar vermiştir.

Gerçek dünya problemleri üzerinde yapılan ikinci test CEC'11 gerçek dünya problem seti üzerinde gerçekleştirilmiştir. CEC'11 setinde AAA ve AAA_{ML} yöntemleri test edilmiştir. Sonuçlar güncel, geliştirilmiş ve hibrit algoritmalarla ED-DE, EPSDE ve AdaptDE algoritmaları ile kıyaslanmıştır. En iyi sonuca ulaştığı problem sayıları göz önüne alındığında AdaptDE diğer yöntemlerden başarılı görünmektedir. Tüm problem seti üzerinde herbir problemdeki başarı sıralamaları açısından AAA_{ML} diğer yöntemlerden daha başarılıdır.

Gerçekleştirilen 4 farklı test AAA ve AAA_{ML}'nin belirli bir türdeki problemlerden ziyade genel başarısı yüksek yöntemler olduğunu göstermektedir. Bunun sebebi her iki yönteminde yoğunlaşma ve çeşitliliği sağlayan özellikleri arasında güçlü

bir dengeye sahip olmalarıdır. Bu denge yerel minimumlardan kaçmayı sağlarken global en iyiye yakınsamayı hızlandırmaktadır.

Bu çalışma ile AAA ve çoklu ışık kaynağı uygulanarak geliştirilmiş sürümü olan AAA_{ML} adında iki yeni biyolojik ilhamlı sezgisel algoritma önerilmiştir. Bu yeni yöntemlerin sürekli değer alan optimizasyon problemleri üzerinde başarısı ortaya konmuştur. AAA ve AAA_{ML}, parametreleri sürekli ve reel değerler alan optimizasyon problemlerinin çözümünde makul zamanda kaliteli çözümler sunabilir, zaman ve kaynak tasarrufu sağlayabilir.

5.2. Öneriler

AAA ve AAA_{ML}'nin sürekli değer alan tek amaçlı optimizasyon problemlerinde göstermiş olduğu başarı bu çalışma ile kanıtlanmıştır. Bu çalışmanın devamında, önerilen AAA ve AAA_{ML} algoritmalarının başarılarını arttırmak için farklı özelliklere sahip diğer yöntemler ile hibrit çalışmalar yapılabilir.

Sürekli değer alan optimizasyon problemlerinin yanı sıra kombinasyonel tipte ve çok amaçlı gerçek dünya problemleri de bulunmaktadır. Bu tip problemlerin çözümü için AAA ve AAA_{ML} uyarlanabilir.

Bu tez sunulduğu sırada yazar her iki algoritmada aynı olan kontrol parametrelerini adaptif hale getirerek AAA ve AAA_{ML} yöntemlerinde ayrı ayrı geliştirme üzerine çalışmalar yapmaktadır.

KAYNAKLAR

- Arceivala, S. J., Lokshminarayana, J. S. S., Alegersamy, S. R., Sastry, C. A., 1970, Mechanism of treatment and role of algae and bacteria, in Waste Stabilisation ponds Design, Construction & Operation in India, *Central Public Health Engineering Research Institute Nogpur*, India.
- Asafuddoula, M., Ray, T. ve Sarker, R., 2011, An adaptive differential evolution algorithm and its performance on real world optimization problems, in *Proceedings of the IEEE Congress on Evolutionary Computation*, New Orleans, USA, 1057–1062.
- Aydilek, I. B. ve Arslan, A., 2013, A hybrid method for imputation of missing values using optimized fuzzy c-means with support vector regression and a genetic algorithm, *Information Sciences*, 233, 25–35.
- Blum, C. ve Roli, A., 2003, Metaheuristics in combinatorial optimization: Overview and conceptual comparison, *ACM Computing Surveys (CSUR)*, 35(3), 268–308.
- Brownlee, J., 2011, *Clever Algorithms: Nature-Inspired Programming Recipes*, LuLu, Melbourne, 29–312.
- Buhr, H. O., Miller, S. B., 1983, A dynamic model of the high-rate algal-bacterial wastewater treatment pond, *Water Res.*, 17, 29–37.
- Chen, F., Chen, H. ve Gong, X., 1997, Mixotrophic and Heterotrophic growth of *Haematococcus Lacustris* and rheological behaviour of the cell suspensions, *Bioresource Technology*, 62, 19–24.
- Chen, T ve Chi, T., 2010, On the improvements of the particle swarm optimization algorithm, *Advances in Engineering Software*, 41(2), 229–239.
- Chen, M. Y., 2013, A hybrid ANFIS model for business failure prediction utilizing particle swarm optimization and subtractive clustering, *Information Sciences*, 220, 180–195.
- Clerc, M., 2009, A Method to improve Standard PSO, *MC2009-03-13*, France.
- Clerc M., 2010, Beyond Standard Particle Swarm Optimisation, *International Journal of Swarm Intelligence Research*, 4, 46–66.
- Clerc M., 2012, Standard Particle Swarm Optimisation [online], *Open access archive HAL*, http://clerc.maurice.free.fr/ps/SPSO_descriptions.pdf [Ziyaret Tarihi: 29 Ekim 2015].
- Cohen, I., Post, A. F., 1993, The heterotrophic connection in a photoautotrophic *Chlorella vulgaris* dominant in wastewater oxidation ponds, *Water Science and Technology*, 27(7-8), 151–155.

- Curtis, T. P., Mara, D. D., Dixo, N. G. H., Silva S. A., 1994, Light penetration in waste stabilization ponds, *Water Res.*, 28 (5), 1031–1038.
- Dang, J., Brabazon, A., O'Neill, M. ve Edelman, D., 2008, Option Model Calibration Using a Bacterial Foraging Optimization Algorithm, *Lecture Notes in Computer Science*, 4974, 113–122.
- Das, S., ve Suganthan, P. N., 2010, Problem definitions and evaluation criteria for CEC 2011 competition on testing evolutionary algorithms on real world optimization problems, *Jadavpur University, Nanyang Technological University*, Kolkata, India.
- Dasgupta, D., 1999, Artificial Immune Systems and Their Applications, *Springer-Verlag*, Berlin - Heidelberg, 3–21.
- Derrac, J., Garcia, S., Molina, D. ve Herrera, F., 2011, A practical tutorial on the use of non-parametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms, *Swarm and Evolutionary Computation*, 1, 3–18.
- Dorigo, M., 1992, Optimization, Learning and Natural Algorithms, *PhD thesis*, Politecnico di Milano, Italy.
- Duman, E., Uysal, M. ve Alkaya, A.F., 2012, Migrating birds optimization: a new meta-heuristic approach and its performance on quadratic assignment problem, *Information Sciences*, 217, 65–77.
- El-Abd, M., 2012, Performance assessment of foraging algorithms vs. evolutionary algorithms, *Information Sciences*, 182(1), 243–263.
- El-Abd, M., 2013, Testing a Particle Swarm Optimization and Artificial Bee Colony Hybrid algorithm on the CEC13 benchmarks, in *Proceedings of the IEEE Congress on Evolutionary Computation*, Cancun, Mexico, 2215–2220.
- Elfeky, E., Sarker, R. ve Essam, D., 2008, Analyzing the simple ranking and selection process for constrained evolutionary optimization, *Computer Science and Technology*, 23, 19–34.
- Elsayed, S. M., Sarker, R. A. ve Essam, D. L., 2011, GA with a new multiparent crossover for solving IEEE-CEC2011 competition problems, in: *proceeding IEEE Congress on Evolutionary Computation*, New Orleans, USA, 1034–1040.
- Eskandar, H., Sadollah, A., Bahreininejad, A. ve Hamdi, M., 2012, Water cycle algorithm—a novel metaheuristic optimization method for solving constrained engineering optimization problems, *Comput. Struct.*, 110–111, 151–166.
- Farmer, J.D., Packard, N. ve Perelson, A., 1986, The immune system, adaptation and machine learning, *Physica D: Nonlinear Phenomena*, 22, 187–204.
- Fogg, G.E., 1975, Algal Cultures and Phytoplankton Ecology, *The Univ. of Wisconsin Press*, Wisconsin.

- Gandomi, A.H. ve Alavi, A.H., 2012, Krill Herd: a new bio-inspired optimization algorithm, *Communications in Nonlinear Science and Numerical Simulation*, 17, 4831–4845.
- Gao, S., 2012, Bio-Inspired Computational Algorithms and Their Applications, *InTech*, Croatia, 3–18.
- Geem, Z.W., Kim J. H. ve Loganathan, G. V., 2001, A New Heuristic Optimization: Harmony Search, *Simulation*, 76(2), 60–68.
- Geider, R. J. ve Osborne, B. A., 1992, Algal Photosynthesis-The Measurement of Algal Gas Exchange, Chapman and Hall Inc., NY.
- Glover, F. ve Laguna, M., 1997, Tabu Search, *Kluwer Academic Publishers*, Boston.
- Graham, L.F., Wilcox, L.W., 2000, Algae, *Prentice-Hall*, USA.
- Grima, E. M., Camacho, F. G., Pérez, J. A. S., Sevilla, J. M. F., Fernandez, F. G. A. ve Gomez, A. C., 1994, A mathematical model of microalgal growth in light-limited chemostat culture, *J. Chem. Technol. Biotechnol.*, 61, 167–173.
- Gürbüz, F., Çiftçi, H., Akçıl, A. ve Karahan, A. G., 2004, Microbial Detoxification of Cyanide Solutions: A New Biotechnological Approach Using Algae, *Hydrometallurgy*, 72, 167–176.
- Holland, J., 1975, Adaptation in Natural and Artificial systems, *University of Michigan Press*, Ann Arbor.
- Karaboğa, D., 2004, Yapay Zekâ Optimizasyon Algoritmaları, *Atlas Yayınları*, İstanbul, Türkiye, 1–19.
- Karaboğa, D., 2005, An İdea Based on Honey Bee Swarm for Numerical Optimization, Technical Report-TR06, *Erciyes University*, Kayseri.
- Kennedy, J. ve Eberhart, R., 1995, Particle swarm optimization, in: *Proc. of the IEEE Int. Conf. on Neural Networks*, Piscataway NJ, 1942–1948.
- Kephart, J. O., 1994, A Biologically Inspired Immune System For Computers, *Proceedings of Artificial Life IV: The Fourth International Workshop on the Synthesis and Simulation of Living Systems*, MIT Press, Cambridge, 130–139.
- Kirkpatrick, S., Gelatt, C. D. ve Vecchi, M. P., 1983, Optimization by simulated annealing, *Science*, 220, 671-680.
- Kita, H., Ono, I. ve Kobayashi, S., 1999, Multi-parental extension of the unimodal normal distribution crossover for real-coded genetic algorithms, in: *Proceedings of the Congress on Evolutionary Computation*, Orlando, Florida, 1581–1587.

- Kobayashi, M., Kakizono, T., Yamaguchi, K., Nishio, N. ve Nagai, S., 1992, Growth and astaxanthin formation of *Haematococcus pluvialis* in heterotrophic and mixotrophic conditions, *J. Fermentation and Bioeng.*, 74(1), 17–20.
- Korosec, P., Silc, J. ve Filipic, B., 2012, The differential ant-stigmergy algorithm, *Information Sciences*, 192, 82–97.
- Korosec, P. ve Silc, J., 2013, The continuous differential ant-stigmergy algorithm applied on real-parameter single objective optimization problems, in *Proceedings of the IEEE Congress on Evolutionary Computation*, Cancun, Mexico, 1658–1663.
- Lewin, R.A., 1970, *Physiology and Biochemistry of Algae*, 3rd ed. New York, *Academic Press*, USA.
- Liang, J., Qu, B., Suganthan, P., Hernández-Daz, A. G., 2013, Problem definitions and evaluation criteria for the CEC 2013 special session on real-parameter optimization, *Computational Intelligence Laboratory, Zhengzhou University, Zhengzhou, China and Nanyang Technological University*, Singapore, Technical Report 201212.
- Lim, T. Y. ve Khader, A. T., 2013, Monogamous pairs genetic algorithm (MopGA), *International Journal of Engineering and Advanced Technology (IJEAT)*, 2 (5), 143–149.
- Lim, T. Y., Al-Betar, M. A. ve Khader, A. T., 2015, Adaptive pair bonds in genetic algorithm: An application to real-parameter optimization, *Applied Mathematics and Computation*, 252, 503–519.
- Liua, B., Wanga, L., Jina, Y-H., Tangb, F. ve Huang D-X., 2005, Improved particle swarm optimization combined with chaos, *Chaos, Solitons & Fractals*, 25(5), 1261–1271.
- Lund, H. C. ve Lund, J. W. G., 1996, *Freshwater Algae-Their microscopic world explored*, *Biopress Limited*, Bristol, England.
- Mallipeddi, R. ve Suganthan, P. N., 2011, Ensemble differential evolution algorithm for CEC2011 problems, in *Proceedings of the IEEE Congress on Evolutionary Computation*, New Orleans, USA, 1557–1564.
- Mukhopadhyay, A., Roy, A., Das, S., Das, S. ve Abraham, A., 2008, Population-variance and explorative power of harmony search: an analysis, in: *Third International Conference on Digital Information Management (ICDIM 2008)*, London, 775–781.
- Onwubolu, G. C. ve Babu, B. V., 2004, *New Optimization Techniques in Engineering*, *Springer*, Berlin, Germany, 638–644.
- Pan, W. T., 2012, A new fruit fly optimization algorithm: taking the financial distress model as an example, *Knowledge-Based Systems*, 26, 69–74.

- Passino, K.M., 2002, Biomimicry of Bacterial Foraging for Distributed Optimization and Control, *IEEE Control Systems Magazine*, 5 (3), 52–67.
- Pham, D. T., Ghanbarzadeh, A., Koc, E., Otri, S., Rahim, S. ve Zaidi, M., 2006, The bees algorithm—a novel tool for complex optimization problems, in *Proc 2nd Int Virtual Conf on Intelligent Production Machines and Systems (IPROMS)*, Oxford, 454–461.
- Qin, A. K., Huang, V. L. ve Suganthan, P. N., 2009, Differential Evolution Algorithm With Strategy Adaptation for Global Numerical Optimization, *IEEE Transactions on Evolutionary Computation*, 13(2), 398–417.
- Rashedi, E., Nezamabadi-pour, H. ve Sarayzdi, S., 2009, GSA: A Gravitational Search Algorithm, *Information Sciences*, 179, 2232–2248.
- Reynolds, T. D. ve Richards, P. A., 2011, Çevre Mühendisliğinde Temel İşlemler ve Süreçler, Ülker Bakır Öğütveren, *Efil Yayınevi*, Ankara, Türkiye.
- Sarker, R.A. ve Newton, C.S., 2007, Optimization Modelling: A Practical Approach, *CRC Press*, Boca Raton, 3–15.
- Socha, K., Dorigo, M., 2008, Ant colony optimization for continuous domains, *European Journal of Operational Research*, 185 (3), 1155–1173.
- Storn, R. ve Price, K., 1997, Differential evolution—a simple and efficient heuristic for global optimization over continuous spaces, *Journal of Global Optimization*, 11(4), 341–359.
- Suganthan, P. N., Hansen, N., Liang, J. J., Deb, K., Chen, Y. P., Auger, A. ve Tiwari, S., 2005, Problem definitions and evaluation criteria for the CEC 2005 special session on real-parameter optimization [online], *Nanyang Technological University (NTU)*, Singapore, in: Technical Report, <https://www.lri.fr/~hansen/Tech-Report-May-30-05.pdf> [Ziyaret Tarihi: 15 Ekim 2015].
- Tsutsui, S., Yamamura, M. ve Higuchi, T., 1999, Multi-parent recombination with simplex crossover in real coded genetic algorithms, In: *Proceedings of the Genetic Evolutionary Computation Conference*, Orlando, Florida, 657–664.
- Wang, G-G., Deb, S. ve Cui, Z., 2015, Monarch butterfly optimization, *Neural Computing and Applications*, 1–20.
- Wang, Y. ve Li, B., 2009, A Self-adaptive Mixed Distribution Based Univariate Estimation of Distribution Algorithm for Large Scale Global Optimization, in book: *Nature-Inspired Algorithms for Optimization*, in series: *Studies in Computational Intelligence*, vol. 193 Raymond Chiong(Ed), *Springer-Verlag*, Poland, 171–198.

- Wang, Y., Li, B. ve Zhang, K., 2011, Estimation of distribution and differential evolution cooperation for real-world numerical optimization problems, *in Proceedings of the IEEE Congress on Evolutionary Computation*, New Orleans, USA, 1315–1321.
- Wolpert, D. H. ve Macready, W. G., 1997, No Free Lunch Theorems For Optimization, *IEEE Transaction on Evolutionary Computation*, 1, 67-82.
- Yang, X. S., 2008, Nature-Inspired Metaheuristic Algorithms, *Luniver Press*, United Kingdom, 79–91.
- Yang, X. S. ve Deb, S., 2009, Cuckoo search via Lévy flights, World Congress on Nature & Biologically Inspired Computing (NaBIC 2009), *IEEE Publications*, USA, 210–214.
- Yang, X. S., 2010, Nature-Inspired Metaheuristic Algorithms Second Edition, *Luniver Press*, United Kingdom, 1–9.
- Yang, X. S., 2012, Flower pollination algorithm for global optimization, *in: Unconventional Computation and Natural Computation 2012*, Lecture Notes in Computer Science, 7445, 240–249.
- Yang, X. S., Cui, Z., Xiao, R., Gandomi, A. H. ve Karamanoğlu, M., 2013, Swarm Intelligence and Bio-inspired computation Theory and Application, *Elsevier Inc.*, London NW, 1–25.
- Yu, J. J. Q. ve Li, V. O. K., 2015, A social spider algorithm for global optimization, *Applied Soft Computing*, 30, 614–627.
- Zambrano-Bigiarini, M., Clerc, M., Rojas, R., 2013, Standard Particle Swarm Optimisation 2011 at CEC-2013: A baseline for future PSO improvements, *in Proceedings of the IEEE Congress on Evolutionary Computation*, Cancun, Mexico, 2337–2344.

ÖZGEÇMİŞ

KİŞİSEL BİLGİLER

Adı Soyadı : Sait Ali UYMAZ
Uyruğu : T.C.
Doğum Yeri ve Tarihi : ELAZIĞ 10.01.1979
Telefon : 0533 506 95 69
Faks :
e-mail : aliuymaz@selcuk.edu.tr, sauymaz@hotmail.com

EĞİTİM

Derece	Adı, İlçe, İl	Bitirme Yılı
Lise	: Elazığ Lisesi, Merkez, ELAZIĞ	1995
Üniversite	: Selçuk Üniversitesi, Selçuklu, KONYA	2000
Yüksek Lisans	: Selçuk Üniversitesi, Selçuklu, KONYA	2007
Doktora	: Selçuk Üniversitesi, Selçuklu, KONYA	

İŞ DENEYİMLERİ

Yıl	Kurum	Görevi
2003–	Selçuk Üniversitesi Bilgi İşlem Merkezi, Konya	Uzman
2000–2001	GAP Elektrik Dağıtım A.Ş. , İstanbul–Elazığ–Malatya	Sistem Mühendisi
1999–1999	Selçuk Üniversitesi Meram Tıp Fakültesi Bilgi İşlem Merkezi, Konya	Bilgi İşlem Personeli

UZMANLIK ALANI

Yazılım, Veritabanı, Optimizasyon.

YABANCI DİLLER

İngilizce

YAYINLAR

Uymaz, S.A., Tezel, G., Yel, E., 2015, Artificial algae algorithm (AAA) for nonlinear global optimization, *Applied Soft Computing*, 31, 153-171. (Doktora tezinden yapılmıştır)

Uymaz, S.A., Tezel, G., Yel, E., 2015, Artificial Algae Algorithm with Multi-Light Source For Numerical Optimization and Applications, *Biosystems*, 138, 25–38. (Doktora tezinden yapılmıştır)